

Apostila de 3 dias — Domínio total do TF

“Caracterização Informacional do Envelhecimento e do Ruído em Sensores de *Slack* Embarcados para Gerenciamento do Ciclo de Vida de Silício”

TIP7266 — Teoria da Informação, PGETI/UFC, 2026.1

Material de estudo autocontido, ancorado em `results.json` e `tier1_pipeline.py`

19 de agosto de 2026

Resumo

Esta apostila conduz, em três dias de dedicação integral, do conhecimento superficial ao domínio completo do Trabalho Final: a teoria que sustenta cada seção do artigo, o que foi feito e *por que cada solução surgiu*, o que foi obtido, o que não foi, e como defender cada fronteira. Todo o conteúdo teórico necessário está derivado aqui dentro; os números são os reais do `results.json`; os trechos de código são extraídos *verbatim* do `tier1_pipeline.py`; as figuras foram regeradas a partir dos escalares do pipeline e de reconstruções analíticas exatas de suas fórmulas. Leituras externas aparecem apenas como “se sobrar tempo”.

Sumário

Como usar esta apostila	2
Mapa dos números do trabalho	2
DIA 1 — Problema, medidas de informação, ponte Gaussiana	3
1 Bloco 1.1 — O problema físico como canal de comunicação (1,5 h)	3
1.1 O modelo de sinal	3
1.2 A tradução para canal ruidoso	3
1.3 As duas falhas do R^2 (a lacuna que motivou tudo)	3
2 Bloco 1.2 — Entropia, condicional, MI e KL (3 h)	4
2.1 Autoinformação e por que o logaritmo	4
2.2 Entropia	5
2.3 Conjunta, condicional e regra da cadeia	5
2.4 Informação mútua — a peça central	5
2.5 Divergência de Kullback–Leibler	6
3 Bloco 1.3 — Entropia diferencial e a ponte Gaussiana (2,5 h)	6
3.1 Entropia diferencial e suas armadilhas	7
3.2 A Gaussiana como máxima entropia	7
3.3 ★ A derivação do quadro nº 1: $I_{Gauss} = -\frac{1}{2} \log_2(1 - R^2)$	7
3.4 A letra miúda da ponte (que o artigo usa a seu favor)	7
4 Gabarito do Dia 1	8
DIA 2 — Estimar MI de dados reais; canal; estimação	10

5	Bloco 2.1 — Estimar MI de série autocorrelacionada (3,5 h)	10
5.1	O estimador plug-in, seu viés e Miller–Madow	10
5.2	O estimador KSG (verificação cruzada independente)	10
5.3	★★ n_{eff} : por que 768 884 amostras “valem” 1 224 — <i>com a resposta da tarefa crítica</i>	11
5.4	Bootstrap em blocos: ICs que respeitam a dependência	12
5.5	O piso nulo surrogate: dependência real vs. viés	12
5.6	★★ As “duas ameaças distintas” — o parágrafo mais importante do artigo	12
5.7	Sensibilidade de bins (a pergunta fácil de derrubar)	14
6	Bloco 2.2 — Canal: codificação de fonte, BSC, capacidade (2 h)	14
6.1	Codificação de fonte — usada só como cota	14
6.2	BSC — derive a capacidade em 4 linhas	14
6.3	Capacidade Gaussiana — derive em 5 linhas	15
7	Bloco 2.3 — Estimação: OLS, CRLB, Bayes, MDL (3 h)	15
7.1	A escada de estimadores da correção PVT	16
7.2	★ CRLB da inclinação — derivação do quadro nº 2	16
7.3	A rota Bayesiana (concordância entre paradigmas)	16
7.4	MDL: Kolmogorov computável e o veredito “linear”	17
8	Gabarito do Dia 2	18
	DIA 3 — ICA; Wiener/Kalman; genealogia; fronteiras; arguição	19
9	Bloco 3.1 — ICA, negentropia e separação cega (1,5 h)	19
9.1	A ideia em um parágrafo (o argumento do TCL invertido)	19
9.2	O que foi obtido — e a leitura precisa	19
10	Bloco 3.2 — KL entre bancadas: fechando o quadro (0,5 h)	19
11	Bloco 3.3 — Wiener, Kalman/RTS e RUL como distribuição (2 h)	20
11.1	Por que uma segunda rota	20
11.2	O modelo em uma linha	20
11.3	O ajuste e os três achados	20
11.4	RUL como distribuição: primeira passagem Gaussiana-inversa	21
12	Bloco 3.4 — A genealogia das soluções (1 h)	22
13	Bloco 3.5 — As 6 fronteiras e a frase defensável de cada (1 h)	22
14	Bloco 3.6 — Simulado de arguição com respostas-modelo (2 h)	23
15	Critério final de conclusão dos 3 dias	24
A	results.json completo, agrupado	25
B	Mapa função do pipeline → seção do artigo	26

Como usar esta apostila

- **Carga:** $\approx 8\text{--}9$ h/dia úteis por 3 dias. Cada bloco indica sua duração.
- **Método:** ler $\rightarrow$ amarrar à seção do artigo $\rightarrow$ recomputar o número $\rightarrow$ responder o autoteste *de memória, por escrito* $\rightarrow$ só então conferir o gabarito. Autoteste reprovado = reler o bloco antes de avançar.
- **Notação:** S = slack (contagens inteiras; 1 contagem = 19.85 ps), T = temperatura do die, V = tensão do core, t = tempo. Logaritmos em base 2 (bits), salvo indicação.
- **Números-âncora** aparecem como **destacados**: cada um deve ser reconhecível de vista ao final dos 3 dias. Todos vêm do `results.json` (Apêndice A).
- **Código:** os trechos citados são extratos *verbatim* do `tier1_pipeline.py` (735 linhas). O Apêndice B mapeia cada função à seção do artigo que ela alimenta.

Ideia-chave

O artigo tem uma única espinha lógica: (1) o sensor é um canal ruidoso; (2) a contaminação ambiental é informação mútua, não R^2 ; (3) estimar MI de série autocorrelacionada exige honestidade estatística (n_{eff} , surrogates); (4) a correção PVT é denoising que expõe o envelhecimento; (5) capacidade/BSC dizem o que o sensor resolve; (6) CRLB/Bayes/Wiener dizem quando e com que distribuição o envelhecimento é detectável. Os três dias percorrem exatamente essa espinha.

Mapa dos números do trabalho (mantenha à mão)

Grandeza	Onde no artigo	Valor
Duração / amostras pós-soak	§5	214.6 h / 768 884
$\tau_{\text{int}} / n_{\text{eff}}$	§6.1, §6.5	314 s / 1 224
$H(S)$ (27 níveis, 267–300)	§5, §6.1	3.43 bits
$H(S T, V)$	§6.1	2.30 bits
$I(S; T) / I(S; V) / I(S; T, V)$	§6.1	1.087 / 0.113 / 1.132 bits
KSG (verificação cruzada)	§6.1	1.221 bits
IC 95% binned / KSG	§6.1	[1.091, 1.176] / [1.156, 1.275]
R^2 bruto $\rightarrow$ equiv. Gaussiano	§5, §6.1	0.738 $\rightarrow$ 0.967 bits
Excesso bruto (binned/KSG)	§6.1	+17% / +26% (envelope ICs 13–32%)
Piso surrogate (média / p95)	§6.1	0.069 / 0.097 bits (12 $\times$ abaixo do medido)
R^2 detrend. $\rightarrow$ equiv.	§6.1	0.640 $\rightarrow$ 0.736 bits
MI detrend. binned / KSG	§6.1	0.596 / 0.656 bits (déficit –19/–11%)
Correção PVT (reversível)	§6.2	0.656 $\rightarrow$ 0.046 bits (93% removidos)
MDL/BIC (lin vs não-lin)	§6.2	–404.7 vs –394.1 $\Rightarrow$ linear
$\text{corr}(S, t)$ bruto $\rightarrow$ corrigido	§6.2	–0.35 $\rightarrow$ –0.73
$\sigma_{\text{noise}} / \sigma_{\text{sig}} / \text{SNR}$	§6.4	0.84 / 1.29 / 2.36
Capacidade / estados	§6.4	0.87 bits / 1.8
BSC: $p(1\text{h}) / p(24\text{h}) / C(24\text{h})$	§6.4	0.49 / 0.0011 / 0.99 bits
CRLB: sd / taxa mín. / tempo mín.	§6.5	0.39 / 1.2 m-cnt/h / 34 h
Taxa medida (OLS corrigido)	§6.5	–18.3 m-cnt/h (15 $\times$ o piso)
Bayes: inclinação / CrI / MOT	§6.5	–18.2 / [–19.2, –17.2] / [33, 36] h
Wiener: σ_B / taxa suavizada	§6.6	0.403 cnt/ $\sqrt{h}$ / –15.9 m-cnt/h
IG: média/mediana em $D=\sigma_{\text{noise}}$	§6.6	52.9 h / 8.0 h
IG: média/mediana em $D=\sigma_{\text{sig}}$	§6.6	81.3 h / 17.5 h
KL(SBCCI PID) / inverso / JS	§6.3	1.94 / 1.01 / 0.279 bits
ICA: corr / curtoses / MI resid.	§6.7	0.834 / +5.8, +29.9 / 0.571 bits

DIA 1 — O problema, as medidas de informação e a ponte Gaussiana

1 Bloco 1.1 — O problema físico como canal de comunicação (1,5 h)

1.1 O modelo de sinal

Tudo deriva de uma única equação, herdada dos três trabalhos anteriores (sensor SBCCI2025; fidelidade térmica SBCCI2026; plataforma TCC):

$$S(t) = S_{aged}(t) - \Delta_{PVT}(T, V) + \varepsilon_q. \quad (1)$$

O que o sensor *reporta* é a soma de três coisas de natureza distinta:

1. $S_{aged}(t)$ — componente **permanente**, de deriva lenta: o envelhecimento real (BTI/NBTI, portadores quentes). É o que interessa ao SLM. Monotônico, escala de dias.
2. $\Delta_{PVT}(T, V)$ — componente **reversível**: flutuação instantânea do ambiente. Sobe $T \rightarrow$ caminho mais lento $\rightarrow$ menos slack (daí **corr**(S, T) = **-0.859**); sobe $V \rightarrow$ mais rápido $\rightarrow$ mais slack (**corr**(S, V) = **+0.213**). Some quando o ambiente volta.
3. ε_q — ruído de **quantização**: saída inteira, LSB de 19.85 ps. Piso irreduzível.

1.2 A tradução para canal ruidoso

A jogada conceitual do TF inteiro é ler a Eq. (1) como um **canal de comunicação**:

Papel no canal	Objeto físico
Transmissor (mensagem)	$S_{aged}(t)$ — estado latente de degradação
Canal (ruído)	$\Delta_{PVT}(T, V) + \varepsilon_q$ — reversível + quantização
Receptor	o estimador de RUL, que recupera a trajetória lenta

Assim que o problema é um canal, as figuras de mérito naturais deixam de ser variâncias e passam a ser **entropia** (incerteza da saída), **informação mútua** (quanto o ambiente “escreve” na leitura), **capacidade** (quantos estados o receptor distingue) e **estimação** (quando a mensagem emerge do ruído). Cada seção de resultados do artigo responde uma dessas perguntas.

1.3 As duas falhas do R^2 (a lacuna que motivou tudo)

O trabalho anterior mede a contaminação com o R^2 da regressão linear de S em (T, V) : **0.738** na campanha nova (0.592 no PID anterior, 0.921 no bang-bang).

Falha 1 — só vê dependência linear. R^2 é função da covariância de Pearson, e covariância zero caracteriza apenas ausência de *associação linear*. Contraexemplo canônico (decore — cai em arguição): $Y = X^2$ com X simétrico em torno de 0. Então

$$\text{Cov}(X, Y) = E[X \cdot X^2] - E[X] E[X^2] = E[X^3] - 0 = 0$$

por simetria — mas Y é função *determinística* de X : dependência total, correlação nula (Fig. 1). Um R^2 pode ler como “quase independente” uma variável inteiramente determinada pelas entradas por um mapa não-linear. E o risco é real neste domínio: BTI é super-linear em V , Arrhenius é exponencial em $1/T$.

Falha 2 — sem unidade transferível. “Fração de variância explicada” é dependente do modelo e não responde às perguntas do SLM: quantos estados de envelhecimento o sensor resolve? Quão cedo uma tendência é detectável? Quanta informação de envelhecimento uma bancada preserva? Bits respondem às três na mesma moeda.




Figura 1: Ilustração do ponto cego estrutural: $Y = X^2$ tem covariância ≈ 0 com X apesar da dependência determinística. $I(X; Y)$, construída da lei conjunta completa, não tem esse ponto cego: $I = 0 \iff$ independência.

Ideia-chave

A tese do trabalho: substituir R^2 por $I(S; T, V)$ — que é zero *se e somente se* houver independência, sem hipótese de forma funcional — e deixar entropia, capacidade e estimação derivarem o resto.

Autoteste 1.1 — responda por escrito, sem consultar

- Escreva o modelo de sinal e diga o que cada termo vira no vocabulário de canal.
- Prove que $\text{Cov}(X, X^2) = 0$ para X simétrico e explique em uma frase o que isso demonstra sobre R^2 .
- Quais são as três perguntas do SLM que “variância explicada” não responde?

2 Bloco 1.2 — Entropia, condicional, MI e KL (3 h)

Corresponde a §3.1–§3.2 do artigo. Fonte externa opcional: Cover & Thomas cap. 2 — mas o essencial está derivado aqui.

2.1 Autoinformação e por que o logaritmo

Para fonte discreta com símbolos s_k e probabilidades p_k :

$$I(s_k) = -\log_2 p_k \quad [\text{bits}].$$

Raro = surpreendente = informativo. **Por que log?** Queremos aditividade sob independência: $P(s_k, s_j) = p_k p_j$ deve dar $I(s_k s_j) = I(s_k) + I(s_j)$, e o log é a única função contínua que transforma produto em soma. (Resposta de 30 segundos para “por que essa definição”.)

2.2 Entropia

$$H(S) = - \sum_k p_k \log_2 p_k = E\{I(S)\}. \quad (2)$$

É a incerteza média — o número esperado de bits para descrever uma leitura. Propriedades a saber justificar: $0 \leq H(S) \leq \log_2 K$; zero quando um símbolo é certo, máximo na equiprobabilidade (prova por Jensen ou Lagrange).

No trabalho: slack ocupa **27** níveis (267–300), $H(S) = 3.43$ bits; teto $\log_2 27 = 4.75$. A distribuição real está longe da uniforme, e 3.43 bits é o **orçamento total de incerteza** que o resto do trabalho fatia em (ambiente removível) + (envelhecimento recuperável) + (piso de quantização). No pipeline, o cálculo é o histograma dos níveis inteiros nativos com correção de Miller–Madow (Dia 2):

Listing 1: `tier1_pipeline.py` — entropia plug-in + Miller–Madow.

```

1 def entropy_counts(counts):
2     """Plug-in entropy (bits) and Miller-Madow-corrected entropy."""
3     counts = counts[counts > 0]
4     N = counts.sum()
5     p = counts / N
6     H = -np.sum(p * np.log2(p))
7     m = len(counts) # occupied cells
8     H_mm = H + (m - 1) / (2.0 * N) * math.log2(math.e) # MM (bits)
9     return H, H_mm
10
11 # no driver:
12 s_levels, s_codes = np.unique(S.astype(int), return_inverse=True)
13 H_plugin, H_mm = entropy_counts(np.bincount(s_codes))

```

Saída real: $H_S_plugin = 3.4296$, $H_S_mm = 3.4296$ (com $n = 768\,884$ e $m = 27$ a correção é $\sim 2.4 \times 10^{-5}$ bits — desprezível aqui, decisiva nas células conjuntas do Dia 2).

2.3 Conjunta, condicional e regra da cadeia

$$H(S, T, V) = H(T, V) + H(S | T, V), \quad H(S | T, V) = - \sum_{s,t,v} p(s, t, v) \log_2 p(s | t, v).$$

$H(S | T, V)$ é a incerteza *residual* conhecido o ambiente: **2.30 bits**. A diferença $H(S) - H(S | T, V) = 3.43 - 2.30 = 1.13$ é a “informação ambiental” — formalizada a seguir.

2.4 Informação mútua — a peça central

$$I(S; T, V) = H(S) - H(S | T, V) = \sum p(s, t, v) \log_2 \frac{p(s, t, v)}{p(s) p(t, v)}. \quad (3)$$

Três leituras equivalentes (saiba as três):

1. **Redução de incerteza:** bits de incerteza sobre S que somem ao conhecer (T, V) .
2. **Divergência da independência:** a KL entre a conjunta e o produto das marginais; daí $I = 0 \iff$ independência, *sem* hipótese de forma funcional. É isto que o R^2 não tem.
3. **Simetria (Venn):** $I(S; T, V) = H(T, V) - H(T, V | S)$ — interseção dos círculos de entropia.

Números: $I(S; T, V) = 1.132$, $I(S; T) = 1.087$, $I(S; V) = 0.113$ bits — temperatura domina, agora com unidade transferível. A **fração de informação** $I/H(S) = 0.330$ é o análogo informacional do R^2 : 33% dos bits de cada leitura são ambiente.




Figura 2: Reconstrução da Figura 1 do artigo a partir do `results.json`: MI por canal e conjunta, referenciadas ao equivalente Gaussiano do R^2 (tracejado) e ao piso nulo surrogate (pontilhado).

2.5 Divergência de Kullback–Leibler

$$D_{KL}(p \| g) = \sum_x p(x) \log_2 \frac{p(x)}{g(x)}. \quad (4)$$

Leitura operacional: **custo em bits/símbolo de assumir a lei errada** — codificar dados de p com código ótimo para g .

Prova de $D_{KL} \geq 0$ (2 linhas; saiba reproduzir). $-\log_2(\cdot)$ é convexa; por Jensen,

$$D_{KL}(p \| g) = E_p \left[-\log_2 \frac{g(x)}{p(x)} \right] \geq -\log_2 E_p \left[\frac{g(x)}{p(x)} \right] = -\log_2 \sum_x g(x) = 0,$$

com igualdade sse $p = g$.

Não é métrica — e isso vira resultado. Assimétrica, sem desigualdade triangular. No trabalho: $D_{KL}(\text{SBCCI} \| \text{PID}) = 1.94$ vs $D_{KL}(\text{PID} \| \text{SBCCI}) = 1.01$ bits. A direção “descrever a bancada ruidosa com a referência apertada” custa mais: a PID (estreita) atribui probabilidade ínfima às excursões largas da SBCCI, e o log pune $g(x) \approx 0$ onde $p(x) > 0$. A **Jensen–Shannon** (simétrica, ≤ 1 bit) dá **0.279 bits** — a “distância entre ambientes de validação” transferível.

Autoteste 1.2 — responda por escrito, sem consultar

- Derive $I(S; T, V) = H(S) - H(S | T, V)$ a partir da definição por KL.
- Prove $D_{KL} \geq 0$ por Jensen, de memória.
- $H(S) = 3.43$, $H(S | T, V) = 2.30$: extraia MI e fração de informação e diga o que cada uma significa fisicamente.
- Por que a assimetria 1.94 vs 1.01 tem essa direção?

3 Bloco 1.3 — Entropia diferencial e a ponte Gaussiana (2,5 h)

Corresponde a §3.3. Contém a derivação mais importante do Dia 1: a fórmula $-\frac{1}{2} \log_2(1 - R^2)$ que sustenta toda a comparação do §6.1.

3.1 Entropia diferencial e suas armadilhas

Para X contínua com densidade f : $h(X) = -\int f \log_2 f dx$. Duas propriedades *se perdem* do caso discreto: (i) não é invariante a escala, $h(cX) = h(X) + \log_2 |c|$; (ii) pode ser **negativa**. Por isso o trabalho trata S como **discreto** (inteiro nativo: dispensa binning arbitrário do próprio S e a dependência de escala), enquanto T, V contínuos são discretizados em 16 bins equiprováveis *apenas para estimar* a MI conjunta — com a sensibilidade dessa escolha medida e reportada (Dia 2).

3.2 A Gaussiana como máxima entropia

Entre todas as densidades de variância fixa σ^2 , a Gaussiana maximiza h , com

$$h(X_{Gauss}) = \frac{1}{2} \log_2(2\pi e \sigma^2). \quad (5)$$

(Esboço: maximizar $-\int f \ln f$ com normalização e variância fixas; Lagrange dá $f \propto e^{-\lambda x^2}$.) Dois usos no trabalho: torna a conversão $R^2 \rightarrow$ MI equivalente significativa (a seguir) e é o passo crucial da capacidade Gaussiana (Dia 2).

3.3 ★ A derivação do quadro nº 1: $I_{Gauss} = -\frac{1}{2} \log_2(1 - R^2)$

Suponha (S, T, V) conjuntamente Gaussianos e seja $\hat{S}$ o ajuste linear de S em (T, V) com fração de variância explicada R^2 .

Passo 1. Para Gaussianas, condicionar é Gaussiano com variância constante: $S | (T, V) \sim \mathcal{N}(\hat{S}, \sigma_{S|TV}^2)$, e por definição de R^2 : $\sigma_{S|TV}^2 = (1 - R^2) \sigma_S^2$.

Passo 2. MI como diferença de entropias diferenciais, usando (5):

$$I(S; T, V) = h(S) - h(S | T, V) = \frac{1}{2} \log_2(2\pi e \sigma_S^2) - \frac{1}{2} \log_2(2\pi e (1 - R^2) \sigma_S^2).$$

Passo 3. Tudo cancela menos:

$$I_{Gauss} = -\frac{1}{2} \log_2(1 - R^2) \quad (6)$$

Verificação com os seus números: $R^2 = 0.738 \Rightarrow -\frac{1}{2} \log_2(0.262) = \mathbf{0.967 \text{ bits}}$. ✓ No código, é literalmente uma linha (e o R^2 vem do *mesmo* ajuste OLS da correção, não de uma constante digitada):

```
1 mi_lin_equiv = -0.5 * math.log2(1.0 - r2_linear)
2 excess_pct_binned = 100.0 * (mi_stv - mi_lin_equiv) / mi_lin_equiv # +17.05
3 excess_pct_ksg = 100.0 * (ksg_stv - mi_lin_equiv) / mi_lin_equiv # +26.32
```

A leitura que faz a comparação funcionar: 0.967 bits é a MI que os dados teriam *se* a dependência fosse exatamente a linear-Gaussiana que o R^2 enxerga. MI medida acima disso $\Rightarrow$ existe dependência que o resumo de segundo momento não captura. Medido: binned 1.132 (+17%), KSG 1.221 (+26%); envelope com ICs propagados **13–32%**.

3.4 A letra miúda da ponte (que o artigo usa a seu favor)

A comparação contrasta uma **MI discreta** (S inteiro) com um **construto contínuo**. Para sinal de entropia alta ($H(S) = 3.43 \gg 1.13$), a discretização quase não morde — o excesso bruto é, se algo, conservador. Mas para um **resíduo quantizado em poucas contagens** (o caso detrendizado do §6.1), a MI discreta pode legitimamente ficar *abaixo* do equivalente contínuo (teto entrópico baixo + viés descendente do estimador em MI pequena). Guarde: é por isso que o déficit detrendizado de $-19/-11\%$ **não** pode ser lido como “relação sub-linear” — apenas como “nenhum excesso não-linear resolúvel acima do piso do estimador nesta série”. (O slide de backup do deck já formula exatamente assim.)




Figura 3: A ponte Gaussiana: a curva $-\frac{1}{2}\log_2(1-R^2)$ com os três R^2 da linha de pesquisa (PID anterior, PID nova, bang-bang) e a MI medida da campanha nova acima do seu equivalente.

Exercício de código (obrigatório)

Exercício de código 1 (40 min). No repo, escreva ~15 linhas: carregue o CSV (pule #, descarte dropouts, corte 1h de soak), monte o histograma inteiro de `dut_slack` e compute $-\sum p \log_2 p$. Alvo: `H_S_plugin = 3.4296`. Depois confirme no console: $-0.5 \cdot \log_2(1-0.7382) = 0.9667$ e $1.1315/0.9667 - 1 = 17.05\%$, com o `results.json` aberto do lado.

Autoteste 1.3 — responda por escrito, sem consultar

- Derive a Eq. (6) no papel, os 3 passos, sem consultar.
- Por que S é discreto e T, V binned? Cite os dois problemas da entropia diferencial.
- Em que regime a comparação discreto-vs-Gaussiano é conservadora, e em que regime pode gerar déficit legítimo? Por que isso blind — e limita — a leitura do resultado detrendizado?

4 Gabarito do Dia 1

Gabarito 1.1 (conferir só após responder)

a) Transmissor = S_{aged} ; canal/ruído = $\Delta_{PVT} + \varepsilon_q$; receptor = estimador de RUL. **b)** $E[X^3] = 0$ por simetria $\Rightarrow \text{Cov} = 0$ com dependência determinística $\Rightarrow$ métricas de segundo momento têm ponto cego estrutural para dependência não-linear. **c)** Estados resolúveis; antecedência de detecção; informação preservada por bancada.

Gabarito 1.2 (conferir só após responder)

a) $D_{KL}(p(s, t, v) \| p(s)p(t, v)) = \sum p \log_2 \frac{p(s, t, v)}{p(s)p(t, v)} = \sum p \log_2 \frac{p(s|t, v)}{p(s)} = H(S) - H(S|T, V)$. **c)** $I = 1.13$ bits = o que o ambiente escreve em cada leitura; fração 0.33 = análogo informacional do R^2 . **d)** A referência PID estreita dá probabilidade ≈ 0 às excursões da SBCCI; o log pune; a direção inversa é mais barata porque a SBCCI larga “cobre” a PID.

Gabarito 1.3 (conferir só após responder)

b) Diferencial não é invariante a escala e pode ser negativa; o inteiro nativo de S dispensa binning arbitrário. **c)** Conservadora quando $H \gg I$ (série bruta); déficit legítimo quando o resíduo tem teto entrópico baixo (detrendizado) — blindada contra ler o déficit como sub-linearidade, mas também impede afirmar não-linearidade instantânea.

DIA 2 — Estimar informação de dados reais; canal; teoria de estimação

O Dia 2 é o coração metodológico. A manhã (Bloco 2.1) é a parte do trabalho que não está em livro-texto e onde a arguição vai mirar.

5 Bloco 2.1 — Estimar MI de série autocorrelacionada (3,5 h)

Corresponde a §4.2 e §6.1. Leia o `tier1_pipeline.py` inteiro durante este bloco.

5.1 O estimador plug-in, seu viés e Miller–Madow

Estimar I substituindo probabilidades por frequências (histograma conjunto) dá o estimador **plug-in — viesado para cima**: flutuações amostrais criam “estrutura” espúria no histograma conjunto que se contabiliza como dependência. Miller–Madow remove o primeiro termo do viés:

$$\hat{H}_{MM} = \hat{H}_{plug} + \frac{\hat{m} - 1}{2N} \log_2 e \quad (\hat{m} = \text{células ocupadas}),$$

e para a MI as correções das 4 entropias se combinam:

Listing 2: MI com binning + MM; códigos equiprováveis para T, V ; combinação de códigos.

```
1 def equiprobable_codes(x, nbins):
2     """Map a continuous array to integer bin codes using quantile edges."""
3     edges = np.quantile(x, np.linspace(0, 1, nbins + 1))
4     edges = np.unique(edges) # collapse ties (near-discrete V)
5     codes = np.clip(np.digitize(x, edges[1:-1]), 0, len(edges) - 2)
6     return codes
7
8 def mi_binned(a_codes, b_codes):
9     """I(A;B) bits, plug-in and Miller-Madow corrected."""
10    A = a_codes.max() + 1; B = b_codes.max() + 1
11    joint = np.bincount(a_codes * B + b_codes, minlength=A*B).reshape(A, B)
12    Ha, Ha_mm = entropy_counts(joint.sum(axis=1))
13    Hb, Hb_mm = entropy_counts(joint.sum(axis=0))
14    Hab, Hab_mm = entropy_counts(joint.ravel())
15    return (Ha + Hb - Hab), (Ha_mm + Hb_mm - Hab_mm)
```

Bins **equiprováveis** (por quantis) em vez de uniformes: cada bin carrega a mesma massa, nenhuma resolução é desperdiçada em regiões vazias.

5.2 O estimador KSG (verificação cruzada independente)

Kraskov–Stögbauer–Grassberger estima MI **sem binning**, por distâncias de k -vizinhos no espaço conjunto (métrica de Chebyshev), comparando densidade local conjunta com o produto das marginais via função digamma:

Listing 3: KSG: dither para quebrar empates do inteiro S ; subamostragem honesta.

```
1 def ksg_mi(X, Y, k=4, sample=20000, seed=0):
2     rng = np.random.default_rng(seed)
3     n = len(X)
4     if n > sample:
5         idx = np.linspace(0, n - 1, sample).astype(int) # even thinning
6         X, Y = X[idx], Y[idx]
7     n = len(X)
8     X = X + 1e-10 * rng.standard_normal(X.shape) # tiny dither (ties)
9     Y = Y + 1e-10 * rng.standard_normal(Y.shape)
```

```

10 Z = np.hstack([X, Y]); tz = cKDTree(Z)
11 dist, _ = tz.query(Z, k=k + 1, p=np.inf) # k-th neighbour (Chebyshev)
12 eps = dist[:, -1]
13 tx, ty = cKDTree(X), cKDTree(Y)
14 nx = [len(tx.query_ball_point(X[i], eps[i]-1e-12, p=np.inf))-1 for i in range(n)]
15 ny = [len(ty.query_ball_point(Y[i], eps[i]-1e-12, p=np.inf))-1 for i in range(n)]
16 mi_nats = digamma(k)+digamma(n) - np.mean(digamma(np.array(nx)+1)+digamma(np.array(ny)+1))
17 return max(mi_nats, 0.0) / math.log(2.0)

```

Por que dois estimadores? Famílias com vieses de natureza diferente. Resultado: binned **1.132, IC [1.091, 1.176]** vs KSG **1.221, IC [1.156, 1.275]** — ICs se sobrepõem *só estreitamente* (em [1.156, 1.176]), pontos em extremos opostos. O artigo NÃO chama de concordância: chama de **diferença sistemática caracterizada**, e por isso o excesso é **faixa** 17–26% (envelope 13–32%), não número único. Reportar a divergência como incerteza de estimador em vez de escolher o número mais bonito é um dos pontos de honestidade que sustentam o item “metodologia” da rubrica.

5.3 ★★ n_{eff} : por que 768 884 amostras “valem” 1 224 — com a resposta da tarefa crítica

O problema. Fórmulas de IC assumem amostras independentes. Uma série a 1 Hz cujo processo físico muda em minutos é massivamente redundante: vizinhas são quase cópias. Usar n bruto encolheria os ICs por $\sqrt{768884/1224} \approx 25\times$ — certeza falsa.

A solução. Tempo de autocorrelação integrado e tamanho efetivo:

$$\tau_{\text{int}} = \frac{1}{2} + \sum_{k \geq 1} \rho(k) \quad \left(\text{no código: } \tau = 1 + 2 \sum_{k=1}^w \rho(k) \right), \quad n_{\text{eff}} = \frac{n}{2\tau_{\text{int}}}.$$

Nos dados: $\tau_{\text{int}} = 314 \text{ s}$ (≈ 5 min de decorrelação) $\Rightarrow n_{\text{eff}} = 768884/628 = \mathbf{1\ 224}$.

Atenção

RESPOSTA DA TAREFA CRÍTICA (a pergunta de arguição que não está no PDF). Como o pipeline estima τ_{int} ? Três decisões, todas visíveis no código abaixo:

1. **Sobre quê:** não sobre S bruto, mas sobre o resíduo de S após detrend com *média móvel de 1 h* (janela 3600 amostras) — para que τ_{int} reflita a dependência de curto alcance, e não a deriva lenta de envelhecimento (que inflaria τ e esmagaria n_{eff} injustamente).
2. **Como:** FAC via FFT (autocovariância por transformada, normalizada), somada com a *regra de janelamento automatizado de Sokal*: soma-se $\rho(k)$ até a janela w em que $w \geq c\tau(w)$, com $c = 5$. Isso corta a soma quando o ruído da FAC passaria a dominar — o viés-variância clássico da estimação de τ .
3. **Sensibilidade:** $n_{\text{eff}} \propto 1/\tau_{\text{int}}$ e o sd do CRLB $\propto \sqrt{\tau_{\text{int}}}$; a conclusão qualitativa (taxa medida $15\times$ o piso) sobrevive a variações amplas de τ_{int} .

Listing 4: τ_{int} por janelamento de Sokal + o detrend de 1 h no driver.

```

1 def integrated_autocorr_time(x, c=5.0, maxlag=None):
2     """Integrated autocorrelation time via the automated-windowing (Sokal) rule."""
3     x = np.asarray(x, float); x = x - x.mean(); n = len(x)
4     if maxlag is None: maxlag = min(n - 1, 200000)
5     f = np.fft.rfft(x, n=2 * n) # autocovariance via FFT
6     acf = np.fft.irfft(f * np.conj(f))[:maxlag]
7     acf /= acf[0]
8     tau = 1.0
9     for w in range(1, maxlag):

```

```

10     tau = 1.0 + 2.0 * np.sum(acf[1:w + 1])
11     if w >= c * tau: # Sokal window: w >= 5*tau
12         break
13     return max(tau, 1.0)
14
15 # no driver -tau sobre o slack detrendizado com média movel de 1 h:
16 win = 3600
17 kern = np.ones(win) / win
18 trend = np.convolve(S, kern, mode="same")
19 resid = S - trend
20 tau = integrated_autocorr_time(resid[win:-win]) # 314.0 amostras (= s @ 1 Hz)
21 n_eff = n / (2.0 * tau) # 1224.4

```

Tudo no trabalho usa n_{eff} : ICs (bootstrap em blocos de $\sim \tau$), piso surrogate, verossimilhança Bayesiana (série decimada), CRLB, Kalman (médias em blocos de $2\tau_{\text{int}}$). O artigo chama de “pilar da honestidade”.

5.4 Bootstrap em blocos: ICs que respeitam a dependência

Reamostrar pontos i.i.d. destruiria a autocorrelação; reamostram-se **blocos móveis** de comprimento $\sim \tau$, que preservam a dependência interna:

```

1 def block_bootstrap_mi(s_codes, tv_codes, block, B=120, seed=1):
2     """95% CI for I(S;T,V) (MM) via moving-block bootstrap."""
3     rng = np.random.default_rng(seed)
4     n = len(s_codes); nblocks = int(math.ceil(n / block))
5     ests = []
6     for _ in range(B):
7         starts = rng.integers(0, n - block, size=nblocks)
8         idx = (starts[:, None] + np.arange(block)[None, :]).ravel()[:n]
9         ests.append(mi_binned(s_codes[idx], tv_codes[idx])[1])
10    return np.percentile(ests, [2.5, 97.5])

```

(O análogo `block_bootstrap_ksg` espelha isto para o KSG, com $B = 30$ só por custo computacional.)

5.5 O piso nulo surrogate: dependência real vs. viés

Quanto do 1.132 é viés residual? Medir o que o estimador reporta **sob independência garantida que preserve todo o resto**: deslocar *circularmente* (T, V) contra S por defasagens aleatórias grandes ($> 10\tau$) — destrói a dependência cruzada, **preserva marginais e autocorrelação** de cada canal (por isso circular, e não embaralhamento, que destruiria a autocorrelação e *subestimaria* o piso, tornando o teste fácil demais):

```

1 def surrogate_mi_floor(s_codes, tv_codes, tau, B=400, seed=3):
2     rng = np.random.default_rng(seed)
3     n = len(s_codes); lo = int(max(10 * tau, 100))
4     ests = []
5     for _ in range(B):
6         shift = int(rng.integers(lo, n - lo))
7         ests.append(mi_binned(s_codes, np.roll(tv_codes, shift))[1])
8     return np.mean(ests), np.percentile(ests, 95), np.percentile(ests, 99)

```

Resultado: nulo com média **0.069**, p95 **0.097 bits**; o medido é $12\times$ o piso $\Rightarrow$ real. **Refinamento que blinda o excesso**: descontando o viés médio (0.069) do excesso bruto (0.165 bits) sobram **0.096 bits $\approx 10\%$** ; descontando até o p95 sobram 0.068 — o excesso bruto *não* é artefato do piso.

5.6 ★★ As “duas ameaças distintas” — o parágrafo mais importante do artigo

Há **duas** razões independentes pelas quais o excesso poderia ser espúrio:

Ameaça A — viés de estimador. Testada pelo surrogate. O excesso **sobrevive** ($\sim 10\%$ após desconto). ✓

Ameaça B — confusão com a tendência compartilhada. Envelhecimento e deriva lenta de T, V dividem o eixo do tempo em 214.6 h; a MI bruta contabiliza a co-tendência como dependência. Teste: repetir a comparação *inteira* nas séries detrendizadas (as mesmas da correção PVT): $R^2_{detr} = 0.640 \Rightarrow$ equivalente **0.736**; MI binned **0.596** [0.582, 0.632], KSG **0.656** [0.622, 0.735] — déficit -19% a -11% . O excesso **não sobrevive**. ✗




Figura 4: O achado central do §6.1 em uma figura: à esquerda, série bruta (excesso real sobre o equivalente); à direita, detrendizada (déficit). O teto do IC do KSG detrendizado (0.735) *toca* o equivalente (0.736): KSG compatível com paridade exata; binned claramente abaixo.




Figura 5: Excesso percentual com ICs propagados (macros da rodada 4): o envelope bruto [13,32]% fica inteiro acima de zero; o detrendizado fica abaixo, tocando zero apenas no teto do KSG.

Consequência (a retração honesta): o excesso bruto está concentrado na tendência compartilhada, não na física PVT reversível instantânea. A leitura causal “a MI excede o R^2 porque a física é não-linear” é **retratada**. Fica de pé o argumento **estrutural**: a MI não tem ponto cego de linearidade, seja qual for a origem da dependência — e de fato capturou (na tendência) dependência que o R^2 não via.

Nota de implementação que evita uma pegadinha de arguição: o valor KSG detrendizado (0.656) é *o mesmo escalar* que o “acoplamento reversível pré-correção” do §6.2 (`mi_dt_ksg`

= `pre_mi_dt` no código, com comentário explícito): mesma série detrendizada, dois papéis retóricos, *uma* computação — não são dois números que “coincidem”.

Treino obrigatório: contar a lógica completa — bruta pareada com R^2 bruto $\rightarrow$ excesso real (sobrevive ao surrogate) $\rightarrow$ não sobrevive ao detrend $\rightarrow$ retração da causa, manutenção da estrutura — em **90 segundos cronometrados**, três vezes.

5.7 Sensibilidade de bins (a pergunta fácil de derrubar)

16 bins equiprováveis; repetindo com 12/24/32: $I \in [1.111, 1.171]$ — faixa ~ 0.06 bits, ordem do IC. Até o mínimo fica acima do piso (0.097) e do equivalente (0.967). Resposta pronta: “nenhuma conclusão depende dos 16 bins”.

Autoteste 2.1 — responda por escrito, sem consultar

- Por que o plug-in é viesado para cima, e o que a correção MM faz?
- Defina τ_{int} e n_{eff} ; descreva as *três* decisões do pipeline ao estimar τ_{int} (sobre quê, como, com que corte); o que aconteceria com os ICs usando n bruto?
- Por que o surrogate usa deslocamento circular e não embaralhamento?
- Enuncie as duas ameaças, o teste de cada uma e o veredito de cada uma.
- O KSG detrendizado é compatível com quê, exatamente? E o binned? E de onde “vem” o número 0.656 no código?

6 Bloco 2.2 — Canal: codificação de fonte, BSC, capacidade (2 h)

Corresponde a §3.4–§3.5, §6.4.

6.1 Codificação de fonte — usada só como cota

Kraft–McMillan: código-prefixo com comprimentos l_k existe sse $\sum_k 2^{-l_k} \leq 1$; daí o teorema da codificação de fonte: $H(A) \leq \bar{L} < H(A) + 1$. Nenhum código sem perdas bate H bits/símbolo. O trabalho usa isto *apenas* como limite (“qualquer código $\geq H(S) = 3.43$ bits/amostra”) e deliberadamente não roda Huffman/LZW — resposta de escopo pronta: um codec seria redundante com a entropia e a autocorrelação já calculadas; núcleo coberto como conceito, não como implementação decorativa.

6.2 BSC — derive a capacidade em 4 linhas

Canal binário simétrico com cruzamento p : $I(X;Y) = H(Y) - H(Y|X)$; o ruído independe da entrada $\Rightarrow H(Y|X) = H_2(p)$; maximizar $H(Y) \Rightarrow$ entrada uniforme $\Rightarrow H(Y) = 1$:

$$C_{BSC} = 1 - H_2(p), \quad H_2(p) = -p \log_2 p - (1-p) \log_2 (1-p). \quad (7)$$

Máximo 1 bit em $p = 0$; **zero** em $p = 0.5$ (alarme = moeda).

Como o pipeline obtém p por janela (detalhe que o PDF só dá por alto): a decisão “houve envelhecimento na janela W ?” compara a deriva acumulada $|\beta|W$ com o ruído da média da janela $\sigma_{\bar{W}} = \sigma / \sqrt{n_{eff}(W)}$, formando um $d' = |\beta|W / \sigma_{\bar{W}}$; o limiar no ponto médio dá $p = Q(d'/2)$:

Listing 5: BSC por janela: d' e $p = Q(d'/2)$.

```
1 def n_eff_of_T(T_hours):
2     return (T_hours * 3600.0) / (2.0 * tau_c)
3
4 W = 24.0
5 sigma_mean_W = sigma / math.sqrt(n_eff_of_T(W))
6 dprime = abs(beta) * W / sigma_mean_W
7 p_bsc = qfunc(dprime / 2.0) # Q-function: Gaussian tail
```

Números: $1\text{ h} \Rightarrow p = \mathbf{0.49}$, $C \approx 0$; $24\text{ h} \Rightarrow p = \mathbf{0.0011}$, $C = \mathbf{0.99\text{ bits/decisão}}$; campanha $\Rightarrow$ certeza. Como $n_{\text{eff}}(W) \propto W$, tem-se $d' \propto W^{3/2}$ — a mesma escala do CRLB (próximo bloco), e por isso a transição do alarme coincide com o tempo mínimo de observação: três figuras de mérito mutuamente consistentes, não três heurísticas soltas.




Figura 6: Esquerda: $H_2(p)$ e $C_{BSC}(p)$ com os pontos de operação. Direita: reconstrução *analítica exata* da curva do artigo, $p(W) = Q(d'(W)/2)$ com $d' \propto W^{3/2}$ (calibrada com β , σ , τ_c do `results.json` — reproduz $p(24\text{ h}) = 0.0011$).

6.3 Capacidade Gaussiana — derive em 5 linhas

$Y = X + N$, $X \perp N$: $I(X; Y) = h(Y) - h(N)$; $h(N)$ fixo $\Rightarrow$ maximizar $h(Y)$; com potência fixa o máximo é Gaussiano (Eq. 5) $\Rightarrow$

$$C = \frac{1}{2} \log_2 \left(1 + \frac{\sigma_{\text{sig}}^2}{\sigma_{\text{noise}}^2} \right). \quad (8)$$

Números: $\sigma_{\text{noise}} = \mathbf{0.84}$ (resíduo reversível pós-correção), $\sigma_{\text{sig}} = \mathbf{1.29}$ (dispersão do sinal de envelhecimento — no código, o desvio da *tendência* de S_{corr} , média móvel de 1 h) $\Rightarrow$ SNR $\mathbf{2.36} \Rightarrow C = \mathbf{0.87\text{ bits}} \Rightarrow 2^C = \sqrt{1 + \text{SNR}} = \mathbf{1.8\text{ estados distinguíveis}}$.

Ressalva a enunciar antes que perguntem: não há codificador inserindo redundância no processo físico — a fórmula é **limite superior de distinguibilidade** (heurística de resolução efetiva), não taxa alcançável de Shannon. 1.8 é deliberadamente modesto (excursão de envelhecimento $\sim \sqrt{2.36} \times$ o piso) — e é um número que a métrica residual- σ anterior *não tinha como expressar*.

Autoteste 2.2 — responda por escrito, sem consultar

- Derive C_{BSC} e C Gaussiana, de memória.
- Por que $p = 0.5$ anula o canal? O que isso significa para o alarme de 1 h?
- Como o pipeline constrói $p(W)$, e por que $d' \propto W^{3/2}$?
- Por que 1.8 estados é heurística e não alegação de Shannon literal?
- Resposta de 3 frases para “por que não rodou Huffman?”.

7 Bloco 2.3 — Estimação: OLS, CRLB, Bayes, MDL (3 h)

Corresponde a §3.6–§3.7, §6.2, §6.5. Você tem vantagem: o seminário de TIP7266 sobre método dos momentos cobre parte disto.

7.1 A escada de estimadores da correção PVT

Ajustar $\hat{\Delta}_{PVT}(T, V)$ e formar $S_{corr} = S - \hat{\Delta}_{PVT}$, com três famílias em ordem crescente de hipóteses (OLS linear; “MLE” não-linear com design motivado pela física; Bayesiana). Os dois designs do pipeline:

Listing 6: Designs linear ($k = 3$) e não-linear ($k = 6$, Arrhenius-like) + seleção por MDL/BIC.

```

1 def _design_linear(T, V):
2     Tc, Vc = T - T.mean(), V - V.mean()
3     return np.column_stack([np.ones_like(T), Tc, Vc]) # k = 3
4
5 def _design_nonlinear(T, V):
6     Tc = (T - T.mean()) / T.std(); Vc = (V - V.mean()) / V.std()
7     return np.column_stack([np.ones_like(T), Tc, Tc**2, Vc, Vc**2, Tc*Vc]) # k = 6
8
9 def bic_neff(Scorr, k, n_eff):
10     """n_eff * ln(sigma^2_resid) + k * ln(n_eff). Lower = better (MDL pick)."""
11     sigma2 = max(Scorr.var(), 1e-12)
12     return n_eff * math.log(sigma2) + k * math.log(n_eff)

```

Métrica de sucesso correta: não a correlação zerada (OLS zera correlação linear *por construção* — seria circular), mas a **MI reversível residual** sobre sinais detrendizados: **0.656** → **0.046 bits**, **93% removidos**, resíduo na ordem do piso nulo (“ambiente removido” em termos de informação). Verificação externa: σ residual **0.84** vs 0.73 do PID publicado.

Resultado-chave: remover PVT não só limpa — **expõe**: **corr(S, t):** **−0.35** → **−0.73**. Honestidade: parte do fortalecimento é mecânica (remover variância ortogonal a t infla a correlação com t); o defensável é a *exposição da tendência* como estrutura dominante + a corroboração do ICA (Dia 3).

7.2 ★ CRLB da inclinação — derivação do quadro nº 2

Modelo: $y_i = \alpha + \beta t_i + \varepsilon_i$, $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ i.i.d., n_{eff} pontos uniformes em $[0, T]$. Cramér–Rao: $\text{Var}(\hat{\beta}) \geq 1/I_F(\beta)$ com $I_F(\beta) = \sum_i (t_i - \bar{t})^2 / \sigma^2$; para amostragem uniforme $\sum (t_i - \bar{t})^2 \approx n_{\text{eff}} T^2 / 12$:

$$\text{sd}(\hat{\beta}) \geq \sigma \sqrt{\frac{12}{n_{\text{eff}} T^2}}. \quad (9)$$

```

1 def crlb_slope_sd(sigma, n_eff_T, T_hours):
2     """Var(beta_hat) >= 12 sigma^2 / (n_eff_T * T^2)."""
3     return math.sqrt(12.0 / n_eff_T) * sigma / T_hours

```

Verifique: $\sigma = 0.84$, $n_{\text{eff}} = 1224$, $T \approx 214$ h $\Rightarrow$ sd = **0.39 m-cnt/h**; taxa mínima a 3σ : **1.2 m-cnt/h**; taxa medida **−18.3** $\Rightarrow$ **15**× o piso.

Tempo mínimo de observação (a retrodição-joia). Encurtando a janela para T' : $n_{\text{eff}}(T') \propto T' \Rightarrow \text{sd}(T') \propto T'^{-3/2}$ ($\sqrt{T'}$ das amostras, T' da alavancagem temporal). No código, a forma fechada usa a constante $\sigma\sqrt{24\tau_c/3600}$:

```

1 const = sigma * math.sqrt(24.0 * tau_c / 3600.0) # sd(T') = const * T'^{-1.5}
2 min_obs_time = (3.0 * const / abs(beta)) ** (2.0 / 3.0) # = 34.18 h

```

Resolver $3\text{sd}(T') = 18.3$ dá $T'_{\text{min}} \approx$ **34 h** — e a retrodição: **as campanhas anteriores tinham** $\sim$ **23 h** < **34 h**; eis, em um número, por que elas não separavam envelhecimento do piso reversível (Fig. 7). Enquadramento anti-overclaim: *limite de detectabilidade*, não predição de vida útil.

7.3 A rota Bayesiana (concordância entre paradigmas)

Regressão linear Bayesiana de S_{corr} sobre t na série **decimada até** n_{eff} (para o i.i.d. valer), prior de Jeffreys $\Rightarrow$ posterior t de Student:




Figura 7: A lei $T'^{-3/2}$ da detectabilidade (reconstruída da forma fechada do pipeline): a taxa medida cruza o piso 3σ em ≈ 34 h; campanhas de 23 h ficam do lado indetectável.

Listing 7: Bayes: decimação, posterior t , e o que “P(aging)” é de fato.

```

1 step = max(int(n / n_eff_of_T(T_full)), 1)
2 ti, yi = t_h[::step], Sc[::step] # thinning ate ~n_eff pontos
3 Xb = np.column_stack([np.ones(len(ti)), ti])
4 bhat, *_ = np.linalg.lstsq(Xb, yi, rcond=None)
5 resid = yi - Xb @ bhat
6 s2 = float(resid @ resid) / (len(ti) - 2)
7 s_beta = math.sqrt(s2 / np.sum((ti - ti.mean())**2))
8 p_aging = float(tdist.cdf(-bhat[1] / s_beta, len(ti) - 2)) # = P(slope < 0 | data)

```

Resultados: -18.2 m-cnt/h, CrI $[-19.2, -17.2]$; tempo mínimo CrI $[33, 36]$ h $\supset 34$ h. **Frequentista $\approx$ Bayesiano** $\Rightarrow$ o resultado não depende do paradigma. E note no código: `p_aging` é literalmente $P(\text{inclinação} < 0)$ — a rodada 4 do artigo condicionou corretamente a leitura “como envelhecimento” à hipótese de identificação (dispositivo único, §7.6). $P(\beta < 0) \neq P(\text{causa} = \text{envelhecimento})$.

7.4 MDL: Kolmogorov computável e o veredito “linear”

Kolmogorov: $K(x) = \min_{p: U(p)=x} l(p)$ — incomputável; o MDL o operacionaliza com código em duas partes $L(\text{modelo}) + L(\text{dados} \mid \text{modelo})$; forma assintótica Gaussiana (estilo BIC): $DL = n_{\text{eff}} \ln \sigma_{\text{resid}}^2 + k \ln n_{\text{eff}}$ (função `bic_neff` acima — note o uso de n_{eff} , não n , também aqui).

Aplicação: o não-linear remove um pouco mais de MI residual (**0.024 vs 0.046 bits**) mas quase não reduz variância (σ : **0.8366 vs 0.8403**) $\Rightarrow DL_{\text{lin}} = -404.7 < DL_{\text{nl}} = -394.1 \Rightarrow$ **linear vence**.

Leitura correta (decore a formulação): não “a física é linear” — e sim “*neste único e estreito ponto de operação* (125°C, 1.40 V), os dados não contêm informação de curvatura suficiente para pagar os parâmetros extras do modelo Arrhenius/super-linear”. Occam formalizado. E a convergência que o §7.3 explora: MDL e a checagem de MI detrendizada perguntam coisas *diferentes* e chegam *independentemente* ao mesmo veredito.

Autoteste 2.3 — responda por escrito, sem consultar

- Derive o CRLB da inclinação e reproduza 0.39 m-cnt/h.
- De onde vem o expoente $T^{-3/2}$? Recalcule as 34 h (use `const` = $\sigma \sqrt{24\tau_c/3600}$).
- Por que a métrica de sucesso da correção é MI residual detrendizada e não correlação

zerada?

d) Enuncie o veredito MDL na formulação exata e diga que outra análise chega à mesma conclusão por rota independente.

e) O que `p_aging` é no código, e o que isso NÃO afirma?

8 Gabarito do Dia 2

Gabarito 2.1 (conferir só após responder)

a) Flutuações amostrais criam estrutura espúria no histograma conjunto $\Rightarrow$ MI superestimada; MM soma $(\hat{m} - 1)/(2N) \log_2 e$ à entropia. **b)** $\tau_{int} = \frac{1}{2} + \sum \rho(k)$; $n_{\text{eff}} = n/(2\tau_{int}) = 1224$; as três decisões: (i) sobre o slack detrendizado com média móvel de 1 h, (ii) FAC via FFT somada com janelamento de Sokal, (iii) corte em $w \geq 5\tau$; com n bruto os ICs encolheriam $\sim 25\times$. **c)** Circular preserva a autocorrelação de cada canal (embaralhar a destruiria e o piso sairia subestimado). **d)** A: viés — surrogate — sobrevive ($\sim 10\%$). B: tendência — refazer no detrendizado — não sobrevive ($-19/-11\%$). **e)** KSG: compatível com paridade exata (IC toca 0.736); binned: claramente abaixo; 0.656 é o mesmo escalar `pre_mi_dt` do §6.2 (uma computação, dois papéis).

Gabarito 2.2 (conferir só após responder)

b) $H_2(0.5) = 1 \Rightarrow C = 0$: saída independente da entrada; o alarme horário não carrega informação. **c)** $d' = |\beta|W/(\sigma/\sqrt{n_{\text{eff}}(W)})$, $p = Q(d'/2)$; como $n_{\text{eff}}(W) \propto W$, $d' \propto W^{3/2}$. **d)** Sem codificador no processo físico; limite de distinguibilidade dado o piso pós-correção. **e)** O teorema já dá a cota $H(S)$; um codec só a confirmaria; a autocorrelação já caracteriza a redundância temporal; escopo deliberado (§3.4/§7).

Gabarito 2.3 (conferir só após responder)

b) $\text{sd} \propto 1/\sqrt{n_{\text{eff}}T^2}$ com $n_{\text{eff}} \propto T \Rightarrow T^{-3/2}$; $(3 \cdot \text{const}/|\beta|)^{2/3} \approx 34.2$ h. **c)** OLS zera correlação por construção (circular); a MI residual detrendizada mede dependência *de qualquer forma* remanescente, sem confundir com a tendência. **d)** “Curvatura insuficiente neste ponto de operação para pagar os parâmetros”; a MI detrendizada (§6.1) concorda por rota independente (e o MLE do ruído de taxa, Dia 3, também). **e)** `p_aging = tdist.cdf(-b/s)` $= P(\beta < 0 \mid \text{dados})$; não afirma que a causa é envelhecimento — identificação condicionada (dispositivo único).

DIA 3 — ICA; bancadas; Wiener/Kalman; genealogia; fronteiras; arguição

9 Bloco 3.1 — ICA, negentropia e separação cega (1,5 h)

Corresponde a §3.8, §6.7.

9.1 A ideia em um parágrafo (o argumento do TCL invertido)

Observados $\vec{x} = (S, T, V)$ como misturas lineares de fontes independentes, o ICA busca a desmistura $\vec{z} = W\vec{x}$ que maximiza a independência. O truque: pelo Teorema Central do Limite, uma soma de variáveis independentes é mais Gaussiana que as parcelas — logo, uma combinação $w \cdot \vec{x}$ *maximamente não-Gaussiana* tende a ser uma fonte pura. O contraste formal é a **negentropia**

$$N_G(X) = h(X_{Gauss}) - h(X) \geq 0$$

(zero sse Gaussiana — segue direto da máxima entropia, Eq. 5), aproximada por estatísticas de ordem superior (aqui, curtose em excesso). FastICA maximiza esse contraste.

9.2 O que foi obtido — e a leitura precisa

Aplicado a (S, T, V) sem forma funcional para Δ_{PVT} : componente temporal bate com S_{corr} em **|corr| = 0.834**; segundo componente alinha com T (0.688); fontes fortemente não-Gaussianas (curtose **+5.82 e +29.91** — consistente com as caudas pesadas do KL); separação **parcial**: MI residual entre componentes **0.571 bits** (ideal 0) — deriva não-estacionária + caudas pesadas só aproximadamente satisfazem as hipóteses.

As duas precisões anti-overclaim (decore):

1. $0.834 = \sim 70\%$ de **variância compartilhada** com S_{corr} — NÃO “70% do sinal recuperado”.
2. O ICA corrobora a **separação/correção**, não a atribuição física a envelhecimento. E é não-trivial porque regressão e ICA operam no *mesmo espaço* (S, T, V) com *critérios radicalmente distintos* — mínimos quadrados vs. independência/negentropia. Mesmo componente por dois critérios $\Rightarrow$ o achado não é artefato do critério.

Autoteste 3.1 — responda por escrito, sem consultar

- a) Por que não-Gaussianidade $\Rightarrow$ separabilidade? (TCL invertido, 3 frases.)
- b) Por que a separação é parcial aqui? Cite o número.
- c) O que exatamente 0.834 prova, e o que não prova?

10 Bloco 3.2 — KL entre bancadas: fechando o quadro (0,5 h)

Dois logs estabilizados de ~ 24 h no **dispositivo B** (o mesmo circuito do paper SBCCI — nunca misturado com o dispositivo A): bancada SBCCI não-PID (σ_{slack} **3.23**, σ_T 2.64 °C) vs referência PID (**1.46**, 1.25 °C). Razões de ruído $2.2\times$ e $2.1\times \Rightarrow$ contaminação térmica. Comparação sobre a *flutuação centrada* (setpoints diferentes) $\Rightarrow$ mede caráter do ruído, não ponto de operação.

Resultados: **KL 1.94 / 1.01 bits** (assimetria explicada no Dia 1); **JS 0.279**; e o refinamento: KL empírico (1.94) > forma fechada Gaussiana (**1.67**) $\Rightarrow$ excursões **não-Gaussianas de cauda pesada** — exatamente a premissa que o ICA confirmou pela curtose. As pontas se amarram.

Papel estratégico: este é o *sucedâneo declarado* da comparação de capacidade por regime prometida na proposta e não entregue (sem log bang-bang pareado) — parágrafo próprio na conclusão + slide de backup. Renegociação documentada, não lacuna silenciosa.




Figura 8: Esquemático (Gaussianas com os σ reais; *não* são os histogramas dos dados): a assimetria do KL nasce da referência estreita “não cobrir” as excursões da bancada larga; o excesso do KL empírico sobre o Gaussiano é a evidência de caudas pesadas.

11 Bloco 3.3 — Wiener, Kalman/RTS e RUL como distribuição (2 h)

Corresponde a §3.9, §6.6. Código: `kalman_rul.py`.

11.1 Por que uma segunda rota

CRLB/Bayes dá *uma* taxa + barra de erro. A pergunta sequencial é mais rica: (i) melhor estimativa *atual* do nível latente, continuamente atualizada; (ii) *distribuição completa* do tempo até o próximo marco.

11.2 O modelo em uma linha

O processo de Wiener é o análogo contínuo das cadeias de Markov da disciplina (o processo de Markov mais simples com trajetórias contínuas; incrementos Gaussianos independentes e estacionários):

$$dX = \mu dt + \sigma_B dW, \quad S_{corr}(t_k) = X(t_k) + v_k, \quad v_k \sim \mathcal{N}(0, R). \quad (10)$$

Espaço de estados linear-Gaussiano $\Rightarrow$ o **filtro de Kalman** é a atualização Bayesiana *exata*:

$$\hat{x}_k^- = \hat{x}_{k-1} + \mu \Delta t_k, \quad P_k^- = P_{k-1} + \sigma_B^2 \Delta t_k; \quad \hat{x}_k = \hat{x}_k^- + K_k(y_k - \hat{x}_k^-), \quad K_k = \frac{P_k^-}{P_k^- + R}. \quad (11)$$

Leia K_k como um *dial de confiança*: predição incerta (P^- grande) $\Rightarrow$ acredita na medição; medição ruidosa (R grande) $\Rightarrow$ acredita na predição. O suavizador RTS (passada retroativa) dá a trajetória suavizada da campanha inteira com bandas de credibilidade.

11.3 O ajuste e os três achados

Pipeline: média em blocos de $2\tau_{int} \Rightarrow$ 1 224 observações quase-independentes; σ_B e R por **método dos momentos** (variância dos incrementos vs. defasagem); σ_{rate}^2 (deriva variável, tendência linear local) por **MLE 1-D** na verossimilhança de inovações do próprio filtro.

1. $\sigma_{rate}^2 \rightarrow 10^{-10}$ (piso numérico): os dados preferem deriva **constante** — *terceira* confirmação independente do “sem curvatura” (MDL §6.2 + MI detrendizada §6.1 + isto).

2. Taxa suavizada **-15.9 m-cnt/h** vs CRLB/Bayes ~ -18 : mesmo sinal e ordem; $\sim 15\%$ de diferença reflete estimadores distintos, não contradição.
3. R abaixo do σ_{noise}^2 por amostra: a média num bloco de decorrelação inteiro ainda remove estrutura sub- τ_{int} ; e P suavizado **0.214→0.218** plano = regime permanente atingido cedo, como o modelo prevê — sanidade.

11.4 RUL como distribuição: primeira passagem Gaussiana-inversa

Para Wiener com deriva $\mu < 0$, o tempo de primeira passagem por distância D é Gaussiana inversa em forma fechada:

$$T_D \sim \text{IG}\left(m = \frac{D}{|\mu|}, \lambda = \frac{D^2}{\sigma_B^2}\right), \quad E[T_D] = \frac{D}{|\mu|}, \quad \text{Var}(T_D) = \frac{m^3}{\lambda} = \frac{D \sigma_B^2}{|\mu|^3}. \quad (12)$$

Atenção

ERRATA ENCONTRADA AO PREPARAR ESTA APOSTILA. O texto do §3.9 do artigo imprime a variância como $D^3/(|\mu|^3 \sigma_B^2)$; o correto é $D \sigma_B^2/|\mu|^3$ (Eq. 12) — a forma impressa nem fecha dimensionalmente (daria h^4/cnt^2 em vez de h^2). É um deslize *apenas na fórmula em prosa*: nenhum número do artigo é afetado, pois médias e medianas vêm do `scipy.stats.invgauss` do pipeline, que usa a parametrização correta (reverificado: 52.8/8.0 h e 81.1/17.5 h ✓). Correção de um caractere em `03_theory.tex` antes de 22/08. Saber explicar a errata, se notada, vale mais do que escondê-la.

Números (com $|\mu| = 15.9 \text{ m-cnt/h}$, $\sigma_B = 0.403 \text{ cnt}/\sqrt{\text{h}}$): $D = \sigma_{noise} = 0.84$: média **52.9 h**, mediana **8.0 h**; $D = \sigma_{sig} = 1.29$: média **81.3 h**, mediana **17.5 h**.

A ligação quantitativa (o achado bonito do §6.6): a assimetria média $\gg$ mediana ocorre exatamente quando D é pequeno em relação à escala de difusão — que é *o mesmo regime de SNR baixo (2.36)* que limita o sensor a 1.8 estados. A limitação de ruído que restringe a resolução é a mesma que torna o RUL de curto horizonte incerto: capacidade e RUL amarrados por um mecanismo.

Ressalva estrutural: limiares D *autorreferenciados* (σ_{noise} , σ_{sig}) porque não existe limiar de falha calibrado $\Rightarrow$ metodologia, no espírito do CRLB; um limiar calibrado (trabalho futuro) tornaria a distribuição operacional.




Figura 9: Esquerda (ilustrativo): trajetórias de Wiener com a deriva medida e o limiar $-D$. Direita: as duas densidades IG reais do trabalho, com média (tracejado) e mediana (pontilhado) — a cauda direita pesada é o regime de SNR baixo.

Exercício de código (obrigatório)

Exercício de código 2 (30 min). `from scipy import stats: monte invgauss(mu=m/lam, scale=lam)` com $m = D/0.0159$, $\lambda = D^2/0.403^2$ para os dois D ; confira média e mediana; plote as densidades. Depois abra `kalman_rul.py` e localize: o MLE 1-D de σ_{rate}^2 (verossimilhança de inovações) e a montagem da IG.

Autoteste 3.3 — responda por escrito, sem consultar

- Escreva predição/atualização do Kalman e explique o ganho como “dial”.
- Quais são as três confirmações independentes de “sem curvatura”?
- De onde vem a assimetria da IG e a que outro resultado ela se liga?
- Enuncie a errata da variância e por que nenhum número é afetado.

12 Bloco 3.4 — A genealogia das soluções (1 h)

Feche a apostila e reconstrua a cadeia causal; depois confira. **Critério: recontar 1→10 em voz alta em ≤5 min, sem travar.**

#	Problema	Solução	Resultado	Problema seguinte
1	R^2 cego a não-linearidade, sem unidade	$I(S; T, V)$ em bits	1.132 vs 0.967 (+17–26%)	como estimar MI de série autocorrelacionada?
2	768k amostras redundantes ⇒ ICs falsos	τ_{int} , $n_{\text{eff}}=1224$, block-bootstrap, 2 estimadores	ICs honestos; divergência caracterizada	o medido é real ou viés?
3	estimadores de MI viesados p/ cima	piso surrogate circular	12× o piso; sobra ~10%	física instantânea ou tendência?
4	envelhecimento e T, V dividem o eixo t	repetir no detrendizado	déficit –19/ –11% ⇒ retração da causa	o que sobra? (o estrutural)
5	contaminação identificada	correção PVT; MDL escolhe linear	0.656→0.046 (93%); corr –0.35 → –0.73	quantos estados o sensor resolve?
6	σ residual não diz resolução	capacidade Gaussiana + BSC	1.8 estados; 0.99 bits @24 h	quando a tendência é detectável?
7	predição de 1 dispositivo = overclaim	CRLB + Bayes como <i>limite</i>	1.2 m-cnt/h; 34 h (retrodição das 23 h)	taxa única esconde incerteza temporal
8	ponto + barra de erro é pobre p/ RUL	Wiener + Kalman/RTS + IG	distribuição completa; $\sigma_{rate} \rightarrow 0$ confirma MDL	limiar não calibrado ⇒ autorreferenciado
9	correção depende do modelo de regressão	ICA livre de modelo	0.834 corrobora; parcial (0.571)	—
10	sem log bang-bang pareado	KL/JS no dispositivo B como sucedâneo	1.94/1.01; JS 0.279; caudas pesadas	comparação por regime em bits → futuro

13 Bloco 3.5 — As 6 fronteiras e a frase defensável de cada (1 h)

Memorize a **formulação exata** — a diferença entre parecer pego e parecer dono:

- Não-linearidade instantânea não demonstrada.** “O excesso bruto é real — sobrevive ao piso de viés — mas não sobrevive ao detrend; a leitura defensável é que nenhum excesso não-linear é resolúvel acima do piso do estimador nesta série, o que tampouco significa sub-linearidade (teto entrópico do resíduo quantizado). A contribuição estrutural — MI sem ponto cego de linearidade — permanece.”
- Capacidade por regime não entregue.** “Sem registro bang-bang pareado; entregamos capacidade e RUL no regime PID e o KL/JS entre bancadas como sucedâneo declarado; é o primeiro item de trabalho futuro, não uma lacuna silenciosa.”

3. **ICA não é desmistura limpa.** “MI residual 0.571 bits; corroborativa — deriva não-estacionária e caudas pesadas só aproximadamente satisfazem as hipóteses; reportada como parcial.”
4. **RUL não é predição.** “Limite de detectabilidade (CRLB/Bayes) e metodologia de distribuição (IG) com limiares autorreferenciados, porque não existe limiar de falha calibrado para este sensor.”
5. **Identificação não fechada.** “ $P(\beta < 0) = 100\%$ sob a hipótese de que a deriva residual é envelhecimento; dispositivo único, regime único — por isso limite e metodologia, não alegação de causa.”
6. **Divergência binned/KSG não resolvida — caracterizada.** “Duas famílias com vieses distintos; ICs próprios se sobrepõem só estreitamente; reportamos a faixa 17–26% (envelope 13–32%) como incerteza de estimador, em vez de escolher um número.”

14 Bloco 3.6 — Simulado de arguição com respostas-modelo (2 h)

Cronometre ≤ 90 s por resposta, em voz alta.

P1. Como τ_{int} foi estimado? Quanto sensível é n_{eff} ?

“Sobre o slack detrendizado com média móvel de 1 h — para medir a dependência de curto alcance, não a deriva de envelhecimento —, com a FAC calculada via FFT e somada pela regra de janelamento automatizado de Sokal, cortando em $w \geq 5\tau$. Dá 314 s, logo $n_{\text{eff}} = n/(2\tau) = 1224$. Sensibilidade: $n_{\text{eff}} \propto 1/\tau$ e o sd do CRLB $\propto \sqrt{\tau}$; a conclusão qualitativa (taxa medida $15\times$ o piso) sobrevive a variações amplas.”

P2. Por que 16 bins? E com outros?

“Equiprováveis para não desperdiçar resolução; 12/24/32 dão [1.111, 1.171], faixa da ordem do IC; até o mínimo fica acima do piso e do equivalente — nenhuma conclusão depende dos 16.”

P3. MI discreta comparada a um construto Gaussiano contínuo é justo?

“Na série bruta, $H(S) = 3.43 \gg 1.13 \Rightarrow$ o teto quase não morde, comparação conservadora; no resíduo detrendizado o teto morde — e é exatamente por isso que vemos o déficit como ‘sem excesso resolúvel’, nunca como sub-linearidade.”

P4. O excesso de 17–26% não é viés de estimador?

“Surrogate circular: nulo 0.069/0.097; medido $12\times$; descontando o viés médio sobra $\sim 10\%$, descontando o p95 sobram 0.068 bits — o excesso bruto sobrevive à ameaça de viés; ele cai na outra ameaça, a tendência.”

P5. Então a física não é não-linear?

“Não é o que afirmamos: neste ponto de operação estreito não há curvatura resolúvel — e três rotas independentes concordam (MI detrendizada, MDL, MLE do ruído de taxa). Numa campanha multi-setpoint com curvatura Arrhenius/BTI amostrada, esperamos os três vereditos se invertem.”

P6. Por que não Huffman/LZW?

“O teorema da codificação de fonte já dá a cota $H(S)$; um codec só a confirmaria; a autocorrelação já caracteriza a redundância temporal; decisão de escopo declarada no §3.4 e §7.”

P7. 1.8 estados é capacidade de Shannon literal?

“Heurística de resolução: não há codificador no processo físico; usamos a fórmula como limite superior de distinguibilidade dado o piso pós-correção.”

P8. O que a assimetria do KL significa?

“1.94 = custo de descrever a bancada ruidosa com a referência apertada (a PID atribui probabilidade ínfima às excursões da SBCCI e o log pune); 1.01 no inverso; ilustração empírica de que KL não é métrica — por isso também reportamos $JS = 0.279$, simétrica e limitada.”

P9. corr $-0.35 \rightarrow -0.73$ não é efeito mecânico?

“Em parte, sim — e por isso não apoiamos a conclusão só nisso: a tendência exposta é corroborada pelo ICA (0.834, critério independente) e a taxa é consistente por três estimadores (OLS, Bayes, Kalman).”

P10. Cadê o bang-bang?

Fronteira 2, verbatim.

P11. Wiener/Kalman está na ementa?

“Aprofundamento declarado (§3.9 e mapeamento D.1b) construído sobre o que a ementa cobre — MLE e processos estocásticos/Markov —, citado à literatura padrão (Kalman; Whitmore; Si), apresentado como extensão, não como cobertura de núcleo.”

P12. O que 0.834 do ICA prova?

“Corroboração de critério: mesmo espaço (S, T, V) , critérios opostos (MQ vs independência), mesmo componente — $\sim 70\%$ de variância compartilhada, não fração de sinal, e válida a separação, não a causa física.”

P13. Por que o Bayesiano usa a série decimada?

“Para a verossimilhança i.i.d. valer; decimar até n_{eff} é a forma honesta de declarar a informação realmente disponível — e o resultado bate com o CRLB.”

P14. E se a deriva residual não for envelhecimento?

Fronteira 5, verbatim + “é por isso que o multi-dispositivo é o segundo item de trabalho futuro.”

P15. Qual é a contribuição, se a hipótese central caiu?

“Três coisas que o trabalho anterior não podia enunciar: uma métrica de contaminação sem ponto cego de linearidade e com unidade transferível; um protocolo anti-confundimento (n_{eff} , surrogate, detrend, dois estimadores) que inclusive detectou e retratou a nossa própria leitura causal; e a especificação de resolução do sensor — 1.8 estados, alarme 0.99 bits/24 h, detectabilidade em 34 h — que explica quantitativamente por que campanhas de 23 h não viam envelhecimento. O achado negativo reforça o protocolo: foi ele que o encontrou.”

Fechamento (30 min): grave uma passada dos 15 min do deck e ouça; cada travamento aponta o bloco a reler.

15 Critério final de conclusão dos 3 dias

Você terminou quando consegue, sem consulta:

1. Derivar no quadro: $-\frac{1}{2} \log_2(1 - R^2)$; $C_{BSC} = 1 - H_2(p)$; $C = \frac{1}{2} \log_2(1 + \text{SNR})$; $\text{sd}(\hat{\beta}) = \sigma \sqrt{12/(n_{\text{eff}} T^2)}$.
2. Recontar a genealogia $1 \rightarrow 10$ em ≤ 5 min e a lógica do achado negativo em 90 s.
3. Enunciar as 6 fronteiras com as frases defensáveis.
4. Responder P1 (τ_{int}) com o método exato do código — e explicar a errata da variância da IG (Bloco 3.3), corrigindo-a no `.tex` antes de 22/08.
5. Reconhecer de vista cada **número-âncora** e dizer de qual seção vem.

A results.json completo, agrupado

Grupo	Chave	Valor
Dados	n_raw / n_postsoak / n_dropouts	772 484 / 768 884 / 5
	duration_h	214.581
	dut_temp_mean / dut_volt_mean	125.070 / 1.3999
	slack_mean / slack_std	278.457 / 3.032
	slack_lo / slack_hi / n_levels	267 / 300 / 27
	corr_ST / corr_SV	-0.8592 / +0.2133
	slope_raw_cnt_h	-0.01712
Autocorr.	tau_int / n_eff	313.99 / 1224.4
Entropia/MI	H_S_plugin / H_S_mm	3.42963 / 3.42965
	I_ST / I_SV / I_STV	1.0867 / 0.1125 / 1.1315
	H_S_cond_TV / info_fraction	2.2981 / 0.3299
	I_STV_ksg	1.2211
	I_STV_ci (binned)	[1.0905, 1.1757]
	I_STV_ci_ksg	[1.1564, 1.2751]
	bins / bin_sensitivity	16 / [1.111, 1.156, 1.171]
Surrogate	mi_null_mean / p95 / p99	0.0690 / 0.0968 / 0.1187
	mi_floor_ratio	11.69
Excesso	mi_lin_equiv	0.9667
	excess_pct_binned / _ksg	17.05 / 26.32
	mi_excess_ci*_binned	[12.81, 21.62]
	mi_excess_ci*_ksg	[19.62, 31.90]
	mi_excess_floor_adj (bits / %)	0.0958 / 9.91
Detrend	r2_detrended / mi_lin_equiv_detrended	0.6395 / 0.7360
	mi_dt_binned [ci]	0.5958 [0.5824, 0.6318]
	mi_dt_ksg [ci]	0.6557 [0.6217, 0.7347]
	excess_pct_detrended / _detr_ksg	-19.04 / -10.90
Correção	pre_mi_reversible	0.6557
	resid_mi_lin / resid_mi_nl	0.0457 / 0.0242
	resid_sigma_lin / resid_sigma_nl	0.8403 / 0.8366
	bic_lin / bic_nl / corr_model	-404.71 / -394.08 / linear
	mi_reduction_pct	93.03
Capacidade	corr_St_raw / corr_St_corr	-0.3482 / -0.7254
	sigma_signal / sigma_noise / snr	1.2912 / 0.8403 / 2.3611
	capacity_bits / capacity_states	0.8745 / 1.8333
RUL	aging_slope_mcnt_h	-18.252
	crlb_sd_mcnt_h / min_detect_rate	0.3895 / 1.1685
	min_obs_time_h	34.18
BSC	bsc_p_1h / bsc_p (24h) / bsc_capacity	0.4896 / 0.001117 / 0.9874
Bayes	bayes_slope_mcnt_h [CrI]	-18.168 [-19.157, -17.180]
	bayes_p_aging	100.0 (= $P(\beta < 0)$)
	bayes_mot_lo / _hi	33.10 / 35.59

B Mapa função do pipeline → seção do artigo

Função (tier1_pipeline.py)	O que faz	Alimenta
load / clean	CSV, dropouts, corte de soak	§5
integrated_autocorr_time	τ_{int} (Sokal, FFT)	§6.1, §6.5 (via n_{eff})
entropy_counts	H plug-in + MM	§6.1
equiprobable_codes / combine_codes	bins por quantis; código conjunto	§6.1
mi_binned	I binned + MM	§6.1, §6.2
ksg_mi	I por k NN (dither, thinning)	§6.1, §6.2
block_bootstrap_mi / _ksg	ICs 95% em blocos	§6.1
surrogate_mi_floor	piso nulo circular	§6.1
_design_linear / _nonlinear	correções $k=3$ / $k=6$	§6.2
bic_neff	MDL/BIC com n_{eff}	§6.2, §7.3
bloco detrend	média móvel 1 h	§6.1, §6.2
bloco capacidade	SNR, C , estados	§6.4
qfunc / h2 + bloco BSC	d' , $p(W)$, C_{BSC}	§6.4
crlb_slope_sd + min_obs_time	Eq. (9), $T^{-3/2}$	§6.5
bloco Bayes	posterior t , $P(\beta < 0)$, MOT CrI	§6.5
(kalman_rul.py)	Wiener/Kalman/RTS/IG	§6.6
(kl_benches.py)	KL/JS bancadas	§6.3
(ica_separation.py)	FastICA	§6.7