



TECNOLOGIA DA INFORMAÇÃO

Prof. Dr. Julio César Santos dos Anjos
Dados e Informação

Revisão de Conceitos - Introdução — 3 de março de 2026


1. Dados e Informação
 - Como os dados são coletados?
2. Revisão Conceitos
3. Valor Esperado e Momento de uma Variável Aleatória
4. Variância e Desvio Padrão de uma Variável Aleatória
 - Covariância de uma Variável Aleatória e Variável Aleatória Independente
5. Distribuição de Probabilidade Conjunta de Funções
6. Convergência de Variáveis Aleatórias
 - Desigualdades Importantes
7. Importância do Tratamento de Dados
 - Tipos de Dados
 - Etapas da Análise dos Dados



1. Dados e Informação
2. Revisão Conceitos
3. Valor Esperado e Momento de uma Variável Aleatória
4. Variância e Desvio Padrão de uma Variável Aleatória
5. Distribuição de Probabilidade Conjunta de Funções
6. Convergência de Variáveis Aleatórias
7. Importância do Tratamento de Dados



Dados vs Informação



- ✓ Desde os primórdios da existência humana já se registrava de alguma forma o conhecimento;
- ✓ O homem primitivo nos deixou o registro dos primeiros dados daquela época.

Dados vs Informação



Figura 1: Figura Rupestre na Amazônia, Parque da Pedra Pintada


- ✓ O dado só terá relevância quando se agregar a este um *valor*, para se atribuir um significado;
- ✓ Significado depende
- ✓ Quanto maior a relevância maior é o grau de *informação* associado;

O que fazemos com a Informação?

captura **privacidade** **consistência**
armazenamento **segurança**
recuperação **análise** **preservação**
processamento **terminação**
distribuição **transformação**
apresentação **relacionamento**
visualização



Era da Informação



- ✓ No passado tínhamos falta de informação;
 - A questão era de como transmitir a informação;
- ✓ Com a escrita;
 - Temos uma forma de representação da informação;
- ✓ Hoje temos excesso de informação;
 - A questão é Como deve-se processar a informação?

Como os dados eram coletados no passado?



O que os dados escondem?

Algumas vezes a atualização de tecnologia resolve o problema.





Figura 2: Hubble vs. James Webb Telescope

Fonte: Nasa Dez/2023 (Nebulosa do Anel Sul)

- ✓ Os dados vistos/coletados são apenas a ponta superior de um grande Iceberg.
- ✓ Toda informação deverá ser processada antes, para então ter-se as verdadeiras dimensões dos resultados.




Crescimento dos dados



$$1 \text{ ZB} = 1 \times 10^9 \text{ TB}$$

Dispositivos conectados na Internet

- ✓ Existem 6.65 Bilhões de usuários de smartfone;
- ✓ + 83% da população mundial;
- ✓ 60% do tráfego da Internet de origina de celulares;
- ✓ Celulares tem estrutura interna semelhante aos computadores atuais;



Source: <https://www.statista.com/statistics/277125/share-of-website-traffic-coming-from-mobile-devices/>

Dado

Registro que por si só não carrega informação.

Valor

O dado coletado, só terá *relevância* quando se agregar a este uma propriedade chamada *valor*.

Informação

É o dado na qual é atribuído um significado, adicionado um *valor*.

Conhecimento

É o resultado do cruzamento de diferentes informações onde através de inferências toma-se decisões gerando uma nova informação.



1. Dados e Informação
2. Revisão Conceitos
3. Valor Esperado e Momento de uma Variável Aleatória
4. Variância e Desvio Padrão de uma Variável Aleatória
5. Distribuição de Probabilidade Conjunta de Funções
6. Convergência de Variáveis Aleatórias
7. Importância do Tratamento de Dados



Probabilidade

Seja um conjunto observável S contido dentro do espaço de Borel F , com σ -álgebra, e considerando-se que se dois eventos são mutuamente exclusivos $A \wedge B | A \cdot B = \emptyset$ que representam um subconjunto de possíveis medições em F , então

$$P(A) \geq 0$$

$$P(S) = 1 \tag{1}$$

$$\text{Se } A \cdot B = \emptyset \quad \Rightarrow P(A + B) = P(A) + P(B)$$

$$\therefore P(\cdot) : F \rightarrow \mathbb{R}$$



Probabilidade

Ainda, podemos ver que a probabilidade de um evento A ocorrer, dado que outro evento B já tenha ocorrido pode ser expressa como:

$$P(A|B) \equiv \frac{P(AB)}{P(B)}, P(B) > 0 \quad (2)$$

Neste caso

$$\begin{aligned} P(A|B) &\geq 0 \\ P(S|B) &= 1 \\ \text{Para } A \cdot C = \emptyset &\Rightarrow P[(A + C)|B] = P(A|B) + P(C|B) \end{aligned} \quad (3)$$



Eventos iid

Dois eventos A e B são ditos independentes e identicamente distribuídos (iid) se a probabilidade de cada evento se mantém a mesma se outro evento ocorrer ou não. Este conceito, nos diz respeito que todos os eventos ocorrem independentes um do outro. E a probabilidade dele ocorrer não se altera. Ou seja,

$$P(A \cdot B) = P(A) \cdot P(B)$$

Generalizando para três eventos A , B e C

(4)

$$\left. \begin{array}{l} P(AB) = P(A) \cdot P(B) \\ P(AC) = P(A) \cdot P(C) \\ P(BC) = P(B) \cdot P(C) \end{array} \right\} P(ABC) = P(A)P(B)P(C) \quad (5)$$



Função Distribuição de Probabilidade

A distribuição de probabilidade é um espaço amostral que pode ser finito ou contavelmente infinito. Se uma variável aleatória pode assumir um número contável de valores possíveis ela é dita discreta. De outra forma, existem variáveis aleatórias cujo conjunto de valores possíveis são incontáveis e neste caso elas são chamadas de contínuas.

$$F(x) = P(X \leq x) = \sum_{x_i \leq x} f(x_i); \text{ onde } -\infty < x < \infty \quad (6)$$



Propriedades da Função de Distribuição de Probabilidade

Uma função de distribuição de uma variável aleatória X obedece às seguintes propriedades:

$$1. \lim_{x \rightarrow -\infty} F(x) = 0 \text{ e } \lim_{x \rightarrow \infty} F(x) = 1 \quad (7)$$

$$2. F \text{ é contínua à direita} \quad (8)$$

$$3. F \text{ não é decrescente, isto é, } F(x) \leq F(y), \text{ sempre que } x \leq y, \forall x, y \in \mathbb{R} \quad (9)$$



Função Densidade e Cumulativa de Probabilidade

- ✓ Se X for contínuo, então $P(X = x) = 0$.
- ✓ Se $F(X)$ for uma função absolutamente contínua,
- ✓ A função análoga contínua da função densidade de probabilidade discreta é a *função densidade de probabilidade* dada pela equação 10.

$$f(x) = \frac{dF(x)}{dx} \quad (10)$$



Função Densidade e Cumulativa de Probabilidade

- ✓ Pela propriedade da continuidade absoluta é recíproco afirmar
- ✓ A equação 11 representa *função cumulativa de probabilidade* ou *CDF* - *cumulative distribution function*
- ✓ Contínua de X , onde o conjunto de valores possíveis é incontável;

$$F(X) = \int_{-\infty}^x f(u) du \quad (11)$$

Nas condições da equação 11 a probabilidade $P(X \in (-\infty, \infty)) = 1$.



Função Densidade e Cumulativa de Probabilidade

- ✓ Pela propriedade da continuidade absoluta é recíproco afirmar
- ✓ A equação 11 representa *função cumulativa de probabilidade* ou *CDF* - *cumulative distribution function*
- ✓ Contínua de X , onde o conjunto de valores possíveis é incontável;

$$P(a \leq X \leq b) = \int_a^b f(x)dx \quad (12)$$

- ✓ A equação 12 mostra que se $a = b$
- ✓ O valor da probabilidade $P(X = a) = 0$.
- ✓ Assim, a probabilidade de uma variável aleatória contínua assume um valor específico igual a zero.



1. Dados e Informação
2. Revisão Conceitos
3. Valor Esperado e Momento de uma Variável Aleatória
4. Variança e Desvio Padrão de uma Variável Aleatória
5. Distribuição de Probabilidade Conjunta de Funções
6. Convergência de Variáveis Aleatórias
7. Importância do Tratamento de Dados



Valor Esperado

- ✓ Uma variável aleatória X que contém os valores de $x_1, x_2, x_3, \dots, x_n$
- ✓ Com probabilidade definida por $f(x_1), f(x_2), f(x_3), \dots, f(x_n)$,
- ✓ Tem média (μ) ou *valor esperado* ou *esperança* de X ,
- ✓ A esperança ou valor esperado é denotado como $E[X]$, calculada como na equação 13

$$E[X] = \sum_{i=1}^n x_i f(x_i) \quad (13)$$

- ✓ Uma variável aleatória que tem valores em $\mathbb{R}$
- ✓ Distribuição μ , com valor esperado de n -ésima potência de X , nomeado $E[X^n]$.
- ✓ Esta n -ésima potência é chamada de n -ésimo momento de X .



Valor Esperado

- ✓ Se X é uma variável aleatória contínua com função densidade de probabilidade $f(x)$
- ✓ Então $f(x)dx \approx P(x \leq X \leq x + dx)$ para um dx pequeno.
- ✓ Considerando a propriedade da continuidade absoluta aplicada à equação 11 anterior
- ✓ É análogo afirmar que a *esperança* de uma variável aleatória contínua é dada pela equação 14,
- ✓ Onde $f(x)$ é uma função não negativa definida em todo real $X \in (-\infty, \infty)$.

$$E[X] = \int_{-\infty}^{\infty} xf(x)dx; \quad (14)$$



1. Dados e Informação
2. Revisão Conceitos
3. Valor Esperado e Momento de uma Variável Aleatória
4. **Variança e Desvio Padrão de uma Variável Aleatória**
5. Distribuição de Probabilidade Conjunta de Funções
6. Convergência de Variáveis Aleatórias
7. Importância do Tratamento de Dados



Variança

- ✓ Seja uma variável X com distribuição de probabilidade $f(x_i)$ e $r > 0$, um inteiro.
- ✓ Se existe a *esperança* da variável aleatória X^r
- ✓ Então seu valor pode ser calculado como na equação 15

$$E[X^r] = \sum x_i^r f(x_i) \quad (15)$$

- ✓ Com a esperança do *r-ésimo* momento de X relacionado à origem
- ✓ e com seu segundo momento de $r + 1$
- ✓ pode-se calcular a média μ como: $\mu = E[X]$.
- ✓ Então, a variável aleatória X pode ser redefinida pelo seu desvio da média como $X - \mu$.



Variança

- ✓ Portanto, considerando a propriedade expressa na equação 9,
- ✓ Desde que exista a condição em que $(x - \mu)^2 \leq 2(x^2 - \mu^2)^2$,
- ✓ Haverá um segundo momento de $X - \mu$ sempre que que $E[X^2]$
- ✓ Se X é uma variável aleatória com segundo momento $E[X^2]$
- ✓ Como sua média é um valor dado por $\mu = E[X]$,
- ✓ A *variança* de X pode ser expressa pela equação 16

$$Var(X) = E[(X - \mu)^2] = E[X^2] - \mu^2 \quad (16)$$

Assim, pode-se simplificar a equação 16 substituindo o resultado da μ por seu valor esperado, temos a equação 17.

$$Var(X) = E[X^2] - (E[X])^2 \quad (17)$$



Variança

- ✓ O conceito da variança estabelece o quanto os valores estão dispersos em torno da média.
- ✓ A raiz quadrada da $Var(X)$ é chamada de *desvio padrão* de X , representado na equação 18.

$$\sigma = \sqrt{Var(X)} \quad (18)$$

A variança tem as seguintes propriedades básicas:

1. $Var(cX) = c^2 Var(X)$ para qualquer $c \in \mathbb{R}$.
2. $Var(X + k) = Var(X)$ para qualquer $k \in \mathbb{R}$.
3. $Var(X) \geq 0$ para qualquer variável aleatória X .
4. $Var(X) = 0$ se e somente se $P(X = c) = 1$, para alguma constante $c \in \mathbb{R}$.
5. $Var(X) = E[X^2] - \mu^2$



Covariança

- ✓ Se duas variáveis aleatórias X e Y estão em um mesmo espaço amostral.
- ✓ Então $X + Y$ e XY são também variáveis aleatórias deste espaço amostral
- ✓ Suas distribuições podem ser obtidas mediante os arranjos das distribuições conjuntas de X e Y .
- ✓ Para determinar o quanto estas variáveis dependem do resultado de uma em relação a outra, deve-se calcular a *covariança* de X e Y da pela equação 19.

$$Cov(X, Y) = E[(X - \mu_x)(Y - \mu_y)] \quad (19)$$



Covariança

- ✓ O valor da média definido anteriormente como sendo $E[X]$.
- ✓ Conclui-se que $\mu_x = E[X]$ e $\mu_y = E[Y]$, e,
- ✓ Portanto, a equação 19 pode ser reescrita como em 20

$$Cov(X, Y) = E[X \cdot Y] - (E[X] \cdot E[Y]) \quad (20)$$

- ✓ Se as variáveis aleatórias X e Y forem independentes então $Cov(X, Y) = 0$.
- ✓ Assim, pode-se assumir que $E[X]$ e $E[Y]$ não são dependentes uma da outra se for verdadeira a equação 21.

$$P(XY) = P(X) \cdot P(Y) \quad (21)$$



Correlação de uma Variável Aleatória

- ✓ Se houver dependência entre as variáveis aleatórias X e Y é possível calcular-se o nível de associação entre elas.
- ✓ Este nível de associação é conhecido como *correlação*.
- ✓ O cálculo é obtido através da relação entre a *covariança* das variáveis
- ✓ Com a medida de seus desvios padrões σ_x e σ_y , como na equação 22.

$$Cor(X, Y) = \frac{Cov(X, Y)}{\sigma_x \cdot \sigma_y} \quad (22)$$



1. Dados e Informação
2. Revisão Conceitos
3. Valor Esperado e Momento de uma Variável Aleatória
4. Variância e Desvio Padrão de uma Variável Aleatória
5. Distribuição de Probabilidade Conjunta de Funções
6. Convergência de Variáveis Aleatórias
7. Importância do Tratamento de Dados



Distribuição de Probabilidade

- ✓ Sejam X_1 e X_2 variáveis aleatórias contínuas independentes com função densidade de probabilidade conjunta f_{X_1, X_2} num mesmo espaço de probabilidade.
 - ✓ As variáveis aleatórias Y_1 e Y_2 , que surgem das funções X_1 e X_2 ,
 - ✓ Dadas por $Y_1 = g_1(X_1, X_2)$ e por $Y_2 = g_2(X_1, X_2)$,
 - ✓ Têm função densidade de probabilidade conjunta, desde que g_1 e g_2 satisfaçam as seguintes condições:
1. As equações $y_1 = g_1(x_1, x_2)$ e $y_2 = g_2(x_1, x_2)$ são solucionáveis para x_1 e x_2 em termos de y_1 e y_2 dadas por $x_1 = h_1(y_1, y_2)$ e $x_2 = h_2(y_1, y_2)$.



Distribuição de Probabilidade

2. As funções g_1 e g_2 têm derivadas parciais contínuas em todos os pontos (x_1, x_2) e são tais que o determinante formado a partir destas seja

$$J(x_1, x_2) = \begin{vmatrix} \frac{\partial g_1}{\partial x_1} & \frac{\partial g_1}{\partial x_2} \\ \frac{\partial g_2}{\partial x_1} & \frac{\partial g_2}{\partial x_2} \end{vmatrix} \equiv \frac{\partial g_1}{\partial x_1} \cdot \frac{\partial g_2}{\partial x_2} - \frac{\partial g_1}{\partial x_2} \cdot \frac{\partial g_2}{\partial x_1} \neq 0$$

em todos os pontos (x_1, x_2) .



Distribuição de Probabilidade

- ✓ Sendo J_x o *Jacobiano* formado pelas derivadas parciais dadas em função de cada uma das variáveis independentes x_n
- ✓ Pertencente a um conjunto de funções $f_1(x_1, x_2, x_3, \dots, x_n)$, $f_2(x_1, x_2, x_3, \dots, x_n)$, $\dots$, $f_n(x_1, x_2, x_3, \dots, x_n)$, representado pela matriz da equação 23.

$$J_x = \begin{vmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \cdots & \cdots & \cdots & \cdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \cdots & \frac{\partial f_n}{\partial x_n} \end{vmatrix} \neq 0 \quad (23)$$



Função Densidade de Probabilidade

Com variáveis aleatórias Y_1 e Y_2 é dada pela equação 24:

$$P\{Y_1 \leq y_1, \dots, Y_n \leq y_n\} = f_{Y_1, \dots, Y_n}(y_1, \dots, y_n) = f_{X_1, \dots, X_n}(x_1, \dots, x_n) |J(x_1, \dots, x_n)|^{-1} \quad (24)$$

onde $x_i = h_i(y_1, \dots, y_n)$, $i = 1, 2, \dots, n$.

✓ Considerando a *função densidade de probabilidade cumulativa conjunta* do par de variáveis aleatórias X e Y definida como em 25:

$$F(x, y) = P\{X \leq x, Y \leq y\}; \text{ onde } -\infty < x, y < \infty \quad (25)$$

Se a função de distribuição conjunta puder ser fatorada em uma parte dependente somente de x em outra dependente somente de y , então X e Y são independentes e

$$P\{X \in A, Y \in B\} = P\{X \in A\}P\{Y \in B\} \text{ para todos os conjuntos } A \text{ e } B \quad (26)$$

Vide Apostila para detalhes das simplificações.



1. Dados e Informação
2. Revisão Conceitos
3. Valor Esperado e Momento de uma Variável Aleatória
4. Variância e Desvio Padrão de uma Variável Aleatória
5. Distribuição de Probabilidade Conjunta de Funções
6. Convergência de Variáveis Aleatórias
7. Importância do Tratamento de Dados



Convergência de Variáveis Aleatórias

- ✓ Seja X uma variável aleatória com esperança finita e g uma função convexa
- ✓ onde na equação 27, se verifica a *Desigualdade de Jensen*:

$$E[g(X)] \leq g(E[X]) \quad (27)$$



Convergência de Variáveis Aleatórias

- ✓ Existe uma reta que passa no ponto $(x_0, g(x_0))$, conforme é representado na Figura 3.
- ✓ Para o ponto $(x_0, g(x_0)) = (E[X], g(E[X]))$
- ✓ Em que há uma função $h(x) = ax + b$ que define esta reta.
- ✓ Se $h = g$ no ponto $(E[X], g(E[X]))$ e nos demais pontos $h(x) \leq g(x)$,
- ✓ Considerando a *Desigualdade de Jensen* da equação 27.
- ✓ Assim, $g(E[X]) = aE[X] + b = E[aX + b]$ onde $E[h(X)] \leq E[g(X)]$.



Convergência de Variáveis Aleatórias

- ✓ Portanto, o valor esperado pode ser utilizado para avaliar a amplitude de valores de uma variável.




Figura 3: Função Convexa



Desigualdade de Markov

- ✓ Seja uma variável aleatória X com apenas valores não negativos e $a > 0$.
- ✓ Então a probabilidade de $P(X \geq a)$ pode ser dada pela equação 28

$$P(X \geq a) \leq \frac{E[X]}{a} \quad (28)$$

- ✓ Assim, a esperança $E[X]$ existe, porque X não é negativa.
- ✓ Considerando um evento $A = \{X \geq a\}$
- ✓ e uma variável discreta $Y = aI_A$, tal que para todo w dentro do espaço amostral em 29:

$$Y(w) = \begin{cases} a & \text{se } X(w) \geq a \\ 0 & \text{se } 0 \leq X(w) < a \end{cases} \quad (29)$$



Desigualdade de Markov

Demonstração: Como pela equação 29 tem-se $X(w) \geq Y(w)$ então pode-se afirmar que:

$$E[X] \geq E[Y] = aP(A) = aP(X \geq a)$$

e, portanto, demonstra-se a equação 28.



Desigualdade de Chebyshev

- ✓ Seja X uma variável aleatória com média finita μ e variância σ^2
- ✓ então, para qualquer $k > 0$, a probabilidade pode ser dada pela equação 30

$$P\{|X - \mu| \geq k\} \leq \frac{\sigma^2}{k^2} \quad (30)$$

Demonstração: Como $(X - \mu)^2$ é uma variável aleatória positiva, aplicando-se a desigualdade de Markov de 28 com $a = k^2$ tem-se a equação 31.

$$P\{(X - \mu)^2 \geq k\} \leq \frac{E[(X - \mu)^2]}{k^2} \quad (31)$$

Portanto, como $(X - \mu)^2 \geq \sigma^2$ se o $|X - \mu| \geq k$, a esperança $E[(X - \mu)^2] \approx \sigma^2$, o que demonstra a equação 30.



IMPORTÂNCIA DA DESIGUALDADE MARKOV E CHEBYSHEV

Importância da Desigualdade Markov e Chebyshev


- ✓ Está em permitir definir os limites para as probabilidades quando se conhece somente a média
- ✓ Ou somente a media e a variância, das distribuições de probabilidade.
- ✓ Como não são feitas restrições sobre a variável aleatória X , se μ e σ são finitos
- ✓ A inequação de Chebyshev é aplicável e se μ é finita a inequação de Markov é aplicável.
- ✓ A natureza universal destas inequações também as faz tipicamente conservativas



1. Dados e Informação
2. Revisão Conceitos
3. Valor Esperado e Momento de uma Variável Aleatória
4. Variança e Desvio Padrão de uma Variável Aleatória
5. Distribuição de Probabilidade Conjunta de Funções
6. Convergência de Variáveis Aleatórias
7. Importância do Tratamento de Dados



Porque a Tratar os Dados é Importante?



Astrônomos confirmaram a existência de um planeta diferente de todos os conhecidos até agora e que terá mais água que a Terra. O GJ1214b, a 40 anos-luz do nosso planeta, foi descoberto pelo telescópio espacial Hubble por (Charbonneau et al. 2009)

A descoberta da água ocorreu após o estudo dos dados em 28/novembro/2011.

Ciclo da Análise dos Dados em Astronomia




Figura 4: Exemplo de Ciclo das Pesquisas Astronômicas





Figura 5: Dados Tratados (Berta et al. 2010)

Dimensões de Big Data:



Fonte: [?], <<http://www-01.ibm.com/software/data/bigdata/>>



Big Data é a nossa natureza.





Fonte: <https://www.discovery.com/science/mexapixels-in-human-eye>

- ✓ Nosso olhos capturam 576 megapixels para cada cena.
- ✓ iPhone 15 Pro captura somente 63 megapixels (9 vezes menos).



Componentes da Arquitetura

- ✓ Implementação de Cloud em IaaS ou PaaS;
- ✓ Big data centers (CPU clusters);
- ✓ Ex.: Amazon, Google, Azure, etc;



Complexidade dos Dados

- ✓ Vários tipos de dados: tabelas, séries temporais, imagens, gráficos, etc.
 - Aspectos espaciais e temporais
 - Dados interligados de diferentes tipos:
 - Do celular pode-se coletar a localização do usuário, informações de amizade, opiniões através do Twitter, imagens através de câmeras, consultas aos motores de busca, etc
- ✓ Bilhões de transações na vida real;
 - Walmart: 20 Milhões de transações por dia;
 - AT&T: 300 Milhões de chamadas por dia;
 - Companhias de Cartão de Crédito: Bilhões de transações por dia;



Complexidade dos Dados

- ✓ Repositórios Web: 50 Bilhões de páginas;
 - Wikipedia: 4 Milhões de artigos;
 - Agências de Notícias: Centenas de streaming todo dia;
 - Twitter (X): 300 Milhões de tweets todo dia;
- ✓ Genoma Humano;
 - Sequenciamento de 1000 indivíduos;
 - $3 \cdot 10^9$ nucleotídeos por pessoa = $3 \cdot 10^{12}$ nucleotídeos



Workload in 60 segundos - @ 2020



+243,000 posts



+350,000 Tweets



+1,500,000 musics



+65,000 uploads



+1,000,000



+20,000,000



+3,800,000



+103,000,000

Tipos de Dados

✓ Estruturados

- A forma de organização dos dados é bem definida e rígida;
- Normalmente sua apresentação se dá em tabelas compostas de linhas e colunas;
- Os dados estruturados só podem ser utilizados para o uso pretendido. Alterações na sua estrutura são custosas;
- Uma das vantagens dos dados estruturados é a habilidade das pessoas e programas de computador de analisar as informações;

Ex.: bancos de dados SQL, planilhas eletrônicas, resultados de formulários da Web.

Nome	CPF	Endereço	Telefone
Marcela Freitas	11111	Rua A, nº 1	101010
João Augusto	22222	Rua B, nº 2	202020
Pablo Silva	33333	Rua C, nº 3	303030
André Mendes	44444	Rua D, nº 4	404040
Juliana Freitas	55555	Rua E, nº 5	505050



Tipos de Dados

✓ Semi-Estruturados

- Dados semi-estruturados não podem ser considerados totalmente estruturados porque não contam com um modelo de dados tabular ou relacional específico;
- Contêm metadados que podem ser analisados, como tags e outros marcadores;

Ex.: JSON, XML, Arquivos Web, arquivos compactados,

XML

```
<user>
  <id>11</id>
  <animal>Bob</animal>
  <idade>2</idade>
</user>
```

JSON

```
{
  "user": {
    "id": "11",
    "animal": "Bob",
    "idade": "2"
  }
}
```



Tipos de Dados

✓ Não Estruturados

- São dados que não seguem um padrão definido;
- Não podem ser organizados em tabelas;
- Informações de difícil processamento e recuperação;
- 80% dos dados produzidos no mundo são não estruturados;
- Na sua maioria precisam passar por um etapa de pré-processamento antes de sua análise;

Ex.: e-mails, textos, documentos, páginas da web, feeds de mídia social, arquivos de imagem, vídeos e de áudio.



O que são os Dados?

- ✓ Coleção de dados e atributos;
- ✓ O atributo é uma propriedade ou característica de um atributo;
 - Ex.: Cor dos olhos, temperatura;
 - Também conhecido como variável, campo, característica ou feature;
- ✓ Uma coleção de atributos descreve o objeto;
 - Objeto também é conhecido como registro, ponto, caso, amostra, entidade ou instância;

Atributos (features)

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

Objetos



Tipos de Atributos

Categórico

- Ex.: Cor dos olhos, código postal, ranking (bom, médio, ruim), medidas (alto, médio, baixo), etc.
- Nominal → sem ordem ou comparação;
- Ordinal → ordenável, mas não comparável;

Numérico

- Ex.: Datas, temperatura, tempo, comprimento, valores, contagem, etc.
- Discreto → contagem
- Contínuo → temperatura
- Caso especial: Binário (sim/não, existe/ não existe), etc.


→ Se os objetos de dados tiverem o mesmo conjunto fixo de atributos numéricos, então os objetos de dados poderão ser considerados como pontos em um espaço multidimensional;

- Cada dimensão representa um atributo distinto;
- Representados em uma matriz de $m \times n$;




Dados em Documentos

- ✓ Cada documento se torna um vetor de 'termo'
- ✓ Cada termo é um componente (atributo) do vetor
- ✓ O valor de cada componente é o número de vezes que o termo correspondente ocorre no documento.
- ✓ Representação de saco de palavras – sem ordem



Dados em Documentos



Valor de cada atributo.

#	termo	$f_{i,1}$	$f_{i,2}$	$f_{i,3}$	$f_{i,4}$
1	to	4	2	–	–
2	do	2	–	3	3
3	is	2	–	–	–
4	be	2	2	2	2
5	or	–	1	–	–
6	not	–	1	–	–
7	I	–	2	2	–
8	am	–	2	1	–
9	what	–	1	–	–
10	think	–	–	1	–
11	therefore	–	–	1	–
12	da	–	–	–	3
13	let	–	–	–	2
14	it	–	–	–	2
Tamanho do documento (# palavras)		10	11	10	12



Dados de Transações

- ✓ Cada gravação (transação) é um conjunto de itens;

<i>TID</i>	<i>Items</i>
1	Bread, Coke, Milk
2	Beer, Bread
3	Beer, Coke, Diaper, Milk
4	Beer, Bread, Diaper, Milk
5	Coke, Diaper, Milk

- ✓ Um conjunto de itens também pode ser representado como um vetor binário, onde cada atributo é um item.
- ✓ Um documento também pode ser representado como um conjunto de palavras (sem contagem)



Dados Ordenados

- ✓ Dados de um sequenciamento genômico;

```
GGTTCCGCCTTCAGCCCCGCGCC
CGCAGGGCCCCGCCCCGCGCCGTC
GAGAAGGGCCCCGCCTGGCGGGCG
GGGGGAGGCGGGGCGCCCGAGC
CCAACCGAGTCCGACCAGGTGCC
CCCTCTGCTCGGCCTAGACCTGA
GCTCATTAGGCGGCAGCGGACAG
GCCAAGTAGAACACGCGAAGCGC
TGGGCTGCCTGCTGCGACCAGGG
```

- ✓ O dado é uma longa string ordenada.



Dados Ordenados

- ✓ Séries temporais.

Evolução da Cotação do Dólar vs Real




- ✓ Uma sequência de valores numéricos ordenados através do tempo;




Grafo de Dados

- ✓ Grafos Web e Links de páginas HTML.




```
<a href="papers/papers.html#bbbb">  
Data Mining </a>  
<li>  
<a href="papers/papers.html#aaaa">  
Graph Partitioning </a>  
<li>  
<a href="papers/papers.html#aaaa">  
Parallel Solution of Sparse Linear System of Equations </a>  
<li>  
<a href="papers/papers.html#ffff">  
N-Body Computation and Dense Linear System Solvers
```

Fases da Análise dos Dados



Etapas da Transformação dos Dados em Informação



Base de Dados

- ✓ Coleção de dados, que pode estar organizada ou não;
- ✓ Possui valores quantitativos e qualitativos;
- ✓ O conjunto de dados deve conter todos os casos possíveis de um domínio.
- ✓ O domínio é uma coleção de alto nível, a raiz de um conjunto, por ex.: o reino animal.




1. Seleção

- ✓ Consiste em extrair os dados de sua origem ou source;
- ✓ É um processo que pode ocorrer concomitantemente com a fase de pré-processamento;
- ✓ Pode exigir diferentes parsers dos dados, ou seja, extração de campos específicos dos dados;
- ✓ Muitas vezes pode ser um processo recursivo coletando dados em diferentes níveis;
- ✓ Dependendo da fonte dos dados, podem ser necessários diferentes ferramentas de extração de dados;
- ✓ Em sistemas Big Data este processo pode ser contínuo, por ex.: em processamento streaming.



2. Pré-Processamento

- ✓ O dado pode vir acompanhado de problemas;



- ✓ Essa etapa prepara os dados e remove inconsistências;
- ✓ Inclui as seguintes tarefas:
 - Limpeza (remoção de ruídos e problemas nos dados);
 - Integração (combinação de dados obtidos a partir de múltiplas fontes);
 - A seleção ou redução (escolha dos dados relevantes à análise);



2. Pré-Processamento

Figura 6: Exemplo de ruído em uma base de dados

Nome	Idade	Nível educacional	Estado civil	Gênero	Cartão de crédito	Renda mensal (\$)
Roberto Felix	42	Especialização	Divorciado	M	Sim	5.000
Joana Pereira	10	Doutorado	Viúva	F	Sim	6.500
?	?	?	?	?	?	?
Isabela Assis	33	Graduação	Casada	F	?	3.900
Marco Araújo	29	Graduação	89 Kg	M	Não	3.100

- ✓ **Incompletude:** Pode faltar valores de um dado atributo; pode faltar um atributo de interesse; ou pode faltar um objeto de interesse;
- ✓ **Inconsistência:** É aquele cujo valor está fora do domínio do atributo ou apresenta uma grande discrepância em relação aos outros dados;
- ✓ **Ruído:** Dependendo do nível de ruído, nem sempre é possível saber se ele está ou não presente em um dado. Por ex.: em vídeo, um ruído é aquele chuvisco na imagem e, em som, um chiado no sinal de áudio.



2. Pré-Processamento

Figura 6: Exemplo de ruído em uma base de dados

Nome	Idade	Nível educacional	Estado civil	Gênero	Cartão de crédito	Renda mensal (\$)
Roberto Felix	42	Especialização	Divorciado	M	Sim	5.000
Joana Pereira	10	Doutorado	Viúva	F	Sim	6.500
→ ?	?	?	?	?	?	?
Isabela Assis	33	Graduação	Casada	F	?	3.900
Marco Araújo	29	Graduação	89 Kg	M	Não	3.100

- ✓ **Incompletude:** Pode faltar valores de um dado atributo; pode faltar um atributo de interesse; ou pode faltar um objeto de interesse;
- ✓ **Inconsistência:** É aquele cujo valor está fora do domínio do atributo ou apresenta uma grande discrepância em relação aos outros dados;
- ✓ **Ruído:** Dependendo do nível de ruído, nem sempre é possível saber se ele está ou não presente em um dado. Por ex.: em vídeo, um ruído é aquele chuvisco na imagem e, em som, um chiado no sinal de áudio.



Tipo de Ruídos

- ✓ Na extração dos dados brutos:
 - Está próximo do conceito de ruído em estatística, são variações inexplicáveis em uma amostra;
- ✓ Em processamento de sinais:
 - São variações indesejadas e normalmente inexplicáveis em um sinal;



3. Transformação

- ✓ Implica em transformar um dado meramente descritivo em um valor quantitativo que possa ser avaliado. Por ex.: transformar um período 8-12hs, 14-17hs em manhã e tarde ou 0 e 1, respectivamente;
- ✓ Ou criar features de uma imagem através de convoluções de forma a evidenciar um detalhamento de uma imagem que até então era oculto;
- ✓ Também torna os dados padronizáveis e deixa-os em um formato passível de aplicação das diferentes técnicas para a descoberta de conhecimento;
- ✓ Outra tarefa importante, consiste em normalizar os dados. Este processo evita que hajam escaladas de dados discrepantes que podem conduzir a um viés (bias) pela escala;



4. Extração de Dados

- ✓ Essa etapa do processo corresponde à aplicação de algoritmos capazes de extrair conhecimentos a partir dos dados pré-processados.
- ✓ As técnicas aplicadas de análise podem ser:
 - Descritiva (medidas de distribuição, tendência central e variância, e métodos de visualização);
 - Agrupamento (segmentação de bases de dados);
 - Predição (classificação e estimação);
 - Associação (determinação de atributos que ocorrem);
 - Detecção de anomalias;



5. Interpretação (Análise de Resultados)

- ✓ Avaliação dos resultados da extração de dados objetivando identificar conhecimentos verdadeiramente úteis e não triviais;
- ✓ A interpretação depende também do estágio de conhecimento de um determinado domínio;
- ✓ Sobre os mesmos dados abordagens diferentes de análise podem revelar novos conhecimentos anteriormente ocultos;
- ✓ Após esta etapa, caso os resultados não sejam satisfatórios, por ex., ter baixa acurácia, deve-se voltar ao passo 2 ou ainda ao passo 1 e executar todo o processo novamente.
 - Este procedimento se verifica principalmente em algoritmos de aprendizado supervisionado e semi-supervisionado;



1. Dados e Informação
 - Como os dados são coletados?
2. Revisão Conceitos
3. Valor Esperado e Momento de uma Variável Aleatória
4. Variância e Desvio Padrão de uma Variável Aleatória
 - Covariância de uma Variável Aleatória e Variável Aleatória Independente
5. Distribuição de Probabilidade Conjunta de Funções
6. Convergência de Variáveis Aleatórias
 - Desigualdades Importantes
7. Importância do Tratamento de Dados
 - Tipos de Dados
 - Etapas da Análise dos Dados





TECNOLOGIA DA INFORMAÇÃO

Prof. Dr. Julio César Santos dos Anjos
Dados e Informação

Revisão de Conceitos - Introdução — 3 de março de 2026