



ANÁLISES DE COMPONENTES PRINCIPAIS - PCA

Prof. Dr. Julio César Santos dos Anjos
Transformações Lineares

Principais Conceitos — 29 de março de 2026

1. Transformações Matriciais



1. Transformações Matriciais



Análise das Componentes Principais

Transformadas Matriciais

Para cada $\mathbf{x} \in \mathbb{R}^p$, uma transformada matricial é definida por

$$\mathbf{z} = \mathbf{W}\mathbf{x} \quad (\text{ou} \quad \mathbf{W}\mathbf{x} = \mathbf{z}), \quad (1)$$

em que $\mathbf{W}$ é uma matriz $q \times p$.

- ✓ Para simplificar, muitas vezes denotamos essa transformação matricial por


$$\boxed{\mathbf{x} \mapsto \mathbf{W}\mathbf{x}} \quad (2)$$



Análise das Componentes Principais

Diagrama de Blocos

Ajuda muito no entendimento de uma transformação linear se representarmos a relação $\mathbf{z} = \mathbf{W}\mathbf{x}$ na forma de um diagrama de blocos do tipo entrada-saída.



Formalização Matemática do Problema

- ✓ Considere um conjunto de dados formado por N vetores de atributos $\mathbf{x}_k$, $k = 1, \dots, N$, que estão organizados ao longo das colunas da matriz $\mathbf{X} \in \mathbb{R}^{p \times N}$:

$$\mathbf{X} = \begin{bmatrix} \vdots & \vdots & \cdots & \vdots \\ \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_N \\ \vdots & \vdots & \cdots & \vdots \end{bmatrix}, \quad (3)$$

com cada vetor de atributo $\mathbf{x}_k \in \mathbb{R}^{p \times 1}$ dado por

$$\mathbf{x}_k = \begin{bmatrix} x_{1,k} \\ x_{2,k} \\ \vdots \\ x_{p,k} \end{bmatrix}, \quad \text{tal que } p \rightarrow \infty. \quad (4)$$



Formalização Matemática do Problema

- ✓ Deseja-se transformar cada vetor $\mathbf{x}_k$ no conjunto de dados em um outro vetor $\mathbf{z}_k$ de dimensão q , ou seja

$$\mathbf{z}_k = \begin{bmatrix} z_{1,k} \\ z_{2,k} \\ \vdots \\ z_{q,k} \end{bmatrix}, \quad \text{tal que } q \leq p. \quad (5)$$

- ✓ Isto deve ser feito por meio de uma transformação linear:

$$\mathbf{z}_k = \mathbf{Q}\mathbf{x}_k, \quad \forall k = 1, \dots, N. \quad (6)$$

- ✓ Além disso, esta transformação deve preservar a informação **relevante** constante no conjunto $\mathbf{X}$.



Perspectiva Histórica e Vários Nomes para Mesma Técnica

- ✓ Desenvolvido por Harold Hotelling em 1933, que cunhou também o termo PCA, sendo também conhecida como *Transformada de Hotelling*.
 - H. Hotelling (1933). "Analysis of a complex of statistical variables into principal components", *Journal of Educational Psychology*, 24(7):498-520.
- ✓ Também conhecida como *Transformada de Karhunen–Loeve* em processamento de sinais.
 - K. Karhunen (1947). "Über lineare Methoden in der Wahrscheinlichkeitsrechnung", *Ann. Acad. Sci. Fennicae. Ser. A. I. Math.-Phys.*, No. 37, 179.
 - M. Loeve (1955). "Probability Theory". Princeton, New Jersey, USA: D Van Nostrand.
- ✓ É um caso particular da *Decomposição em Valores Singulares* (SVD, sigla do inglês), quando a matriz a ser decomposta é a matriz de covariância dos dados (quadrada, simétrica e definida positiva).
 - G. W. Stewart (1993). "On the early history of the singular value decomposition". *SIAM Review*. 35 (4): 551566.



Algoritmo PCA: Passo-a-Passo

- ✓ **Passo 1** - Determinar o vetor-médio dos dados em $\mathbf{X}$:

$$\bar{\mathbf{x}} = \frac{1}{N} \sum_{k=1}^N \mathbf{x}_k. \quad (7)$$

- ✓ **Passo 2** - Centralizar os dados: $\mathbf{x}_k = \mathbf{x}_k - \bar{\mathbf{x}}$.

- ✓ **Passo 3** - Estimar a matriz de covariância dos dados em $\mathbf{X}$:

$$\mathbf{C}_{\mathbf{x}} = E[\mathbf{x}\mathbf{x}^T], \quad (8)$$

$$\approx \frac{1}{N} \sum_{k=1}^N \mathbf{x}_k \mathbf{x}_k^T, \quad (9)$$

em que $E[\cdot]$ é o operador valor esperado.



Algoritmo PCA: Passo-a-Passo

- ✓ **Passo 4** - Determinar os p autovalores da matriz $\mathbf{C}_x$ e os p autovetores correspondentes. Em outras palavras, resolver o seguinte sistema de equações:

$$\mathbf{C}_x \mathbf{v} = \lambda \mathbf{v}, \quad (10)$$

em que λ e $\mathbf{v}$ denotam, respectivamente, o autovalor e o autovetor associado.

- ✓ Os autovalores são as raízes do polinômio em λ , de ordem p , obtido a partir da seguinte expressão:

$$\det(\mathbf{C}_x - \lambda \mathbf{I}_p) = 0. \quad (11)$$



Algoritmo PCA: Atenção

- ✓ A Eq. (10) trata de um problema clássico em sistemas lineares: o problema do autovalor.
- ✓ Este é um caso particular do problema mais geral de transformações lineares do tipo $\mathbf{Ax} = \mathbf{b}$.
- ✓ Lembre-se que a operação matricial $\mathbf{Ax}$ produz um vetor $\mathbf{b}$.
- ✓ Para gerar o vetor $\mathbf{b}$, o vetor $\mathbf{x}$ tem sua norma e/ou orientação modificados pela multiplicação pela matriz $\mathbf{A}$.
- ✓ O problema do autovalor é um caso particular de transformação linear em que $\mathbf{b} = \lambda \mathbf{x}$.
- ✓ Ou seja, a matriz $\mathbf{A}$ altera apenas a norma de $\mathbf{x}$, pois gera um vetor múltiplo de $\mathbf{x}$.



Algoritmo PCA: Atenção

- ✓ Por ser uma matriz simétrica e definida positiva, os p autovalores são sempre positivos.
- ✓ Para resolver a Eq. (10), a escrevemos como um sistema homogêneo:

$$\mathbf{C}_x \mathbf{v} = \lambda \mathbf{v} \quad \Rightarrow \quad (\mathbf{C}_x - \lambda \mathbf{I}_p) \mathbf{v} = \mathbf{0}_p, \quad (12)$$

em que $\mathbf{0}_p$ é um vetor de zeros de dimensão $p \times 1$.

- ✓ Este sistema tem uma única solução $\mathbf{v} = \mathbf{0}_p$, chamada de trivial, se o determinante de $\mathbf{C}_x - \lambda \mathbf{I}_p$ for diferente de zero.
- ✓ A solução trivial não nos interessa. Logo, buscamos as soluções não-triviais, ou seja, aquelas para as quais o determinante de $\mathbf{C}_x - \lambda \mathbf{I}_p$ é nulo. Vide Eq. (11).



Algoritmo PCA: Atenção

- ✓ A Eq. (11) resulta em uma equação polinomial em λ de ordem p . Os autovalores são as raízes deste polinômio.
- ✓ Suponha que a matriz $\mathbf{C}_x$ é dada por

$$\mathbf{C}_x = \begin{bmatrix} 1 & 0,8 \\ 0,8 & 4 \end{bmatrix}$$

- ✓ Neste caso, a matriz $\mathbf{C}_x - \lambda \mathbf{I}_2$ é dada por

$$\begin{bmatrix} 1 & 0,8 \\ 0,8 & 4 \end{bmatrix} - \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} = \begin{bmatrix} 1 - \lambda & 0,8 \\ 0,8 & 4 - \lambda \end{bmatrix}$$



Algoritmo PCA: Atenção

- ✓ Igualando seu determinante a zero, obtemos a seguinte equação polinomial:

$$p(\lambda) = (1 - \lambda)(4 - \lambda) - (0,8)(0,8) = \lambda^2 - 5\lambda + 3,36 = 0. \quad (13)$$

- ✓ Cujas raízes são $\lambda_1 = 0,8$ e $\lambda_2 = 4,2$.
- ✓ Em Octave/Matlab, as raízes de $p(\lambda)$ podem ser encontradas por meio do seguinte comando:
» `roots([1 -5 3.36])`



Algoritmo PCA: Passo-a-Passo

- ✓ Como a matriz $\mathbf{C}_x$ é positiva definida, todos os seus p autovalores são positivos e distintos.
- ✓ Os autovalores devem ser ordenados em ordem decrescente de suas magnitudes:

$$\lambda_1 > \lambda_2 > \lambda_3 > \cdots > \lambda_p \quad (14)$$

- ✓ Os autovetores são determinados resolvendo-se o sistema na Eq. (10) p vezes, uma para cada autovalor:

$$\mathbf{C}_x \mathbf{v}_i = \lambda_i \mathbf{v}_i, \quad i = 1, \dots, p. \quad (15)$$

em que λ_i e $\mathbf{v}_i$ são, respectivamente, o i -ésimo autovalor e o autovetor associado.



Algoritmo PCA: Passo-a-Passo

- ✓ Note que se $\mathbf{v}_i$ é uma solução da Eq. (15), então o seu vetor oposto $-\mathbf{v}_i$ também é, como é facilmente verificável abaixo.

$$\mathbf{C}_\mathbf{x}(-\mathbf{v}_i) = \lambda_i(-\mathbf{v}_i), \quad (16)$$

$$-\mathbf{C}_\mathbf{x}\mathbf{v}_i = -\lambda_i\mathbf{v}_i, \quad (17)$$

$$\mathbf{C}_\mathbf{x}\mathbf{v}_i = \lambda_i\mathbf{v}_i. \quad (18)$$

- ✓ Esta propriedade faz com que, a depender do algoritmo numérico usado para resolver a Eq. (15), o conjunto de autovetores encontrados difira entre si apenas pelos sinais.
- ✓ Por exemplo, compare o conjunto de autovetores retornados as funções `eig` e `pcacov` do Octave/Matlab.



Algoritmo PCA: Passo-a-Passo

- ✓ Os autovetores $\mathbf{v}_i$, $i = 1, \dots, p$, formam um conjunto de vetores **ortonormais**:

$$\mathbf{v}_i^T \mathbf{v}_j = \|\mathbf{v}_i\| \cdot \|\mathbf{v}_j\| \cdot \cos(\theta) = \begin{cases} 1, & \text{se } i = j \ (\theta = 0) \\ 0, & \text{se } i \neq j \ (\theta = \pi/2) \end{cases} \quad (19)$$

- ✓ Dispor os autovetores ao longo das colunas da matriz $\mathbf{V}$:

$$\mathbf{V} = \begin{bmatrix} \vdots & \vdots & \cdots & \vdots \\ \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_p \\ \vdots & \vdots & & \vdots \end{bmatrix}_{p \times p} \quad (20)$$

- ✓ A matriz $\mathbf{V}$ é quadrada e de dimensões $p \times p$.



Algoritmo PCA: Passo-a-Passo

- ✓ A ortonormalidade de $\mathbf{V}$ pode ser verificada matricialmente por meio da seguinte operação: $\mathbf{V}\mathbf{V}^T = \mathbf{I}_p$, em que $\mathbf{I}_p$ é a matriz identidade de dimensões $p \times p$.
- ✓ Ao analisarmos a expressão anterior, nota-se que a transposta da matriz $\mathbf{V}$ é a sua inversa:

$$\mathbf{V}^{-1} = \mathbf{V}^T. \quad (21)$$

- ✓ Essa propriedade é resultado da ortogonalidade dos vetores que formam suas colunas e será útil na reconstrução dos dados originais a partir dos dados transformados, ou seja, através do mapeamento inverso de $\mathbf{z}_k$ para $\mathbf{x}_k$.



Algoritmo PCA: Passo-a-Passo

- ✓ **Passo 5** - Definir a matriz de transformação $\mathbf{Q}$ como

$$\mathbf{Q} = \mathbf{V}^T. \quad (22)$$

- ✓ **Passo 6** - Aplicar a matriz $\mathbf{Q}$ sobre os vetores de atributos originais. Isto pode ser feito vetor a vetor:

$$\mathbf{z}_k = \mathbf{Q}\mathbf{x}_k, \quad (23)$$

para $k = 1, \dots, N$. Ou, de forma matricial, em uma única operação dada por

$$\mathbf{Z} = \mathbf{Q}\mathbf{X}. \quad (24)$$

- ✓ O mapeamento inverso é então dado por $\mathbf{x}_k = \mathbf{Q}^T \mathbf{z}_k$ ou $\mathbf{X} = \mathbf{Q}^T \mathbf{Z}$.



Análise PCA

- ✓ Note que a aplicação da matriz $\mathbf{Q}$ sobre o vetor de atributos original $\mathbf{x}_k$ produz um novo vetor de atributos $\mathbf{z}_k$.
- ✓ Sem perda de generalidade, o índice k é retirado para deixar a notação mais clara.
- ✓ Pode-se escrever a transformação linear $\mathbf{z} = \mathbf{V}^T \mathbf{x}$ em sua forma escalar como um sistema de equações lineares:

$$\begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_i \\ \vdots \\ z_p \end{bmatrix} = \begin{bmatrix} v_{11} & v_{21} & \cdots & v_{i1} & \cdots & v_{p1} \\ v_{12} & v_{22} & \cdots & v_{i2} & \cdots & v_{p2} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ v_{1i} & v_{2i} & \cdots & v_{ii} & \cdots & v_{pi} \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ v_{1p} & v_{2p} & \cdots & v_{ip} & \cdots & v_{pp} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_i \\ \vdots \\ x_p \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1^T \mathbf{x} \\ \mathbf{v}_2^T \mathbf{x} \\ \vdots \\ \mathbf{v}_i^T \mathbf{x} \\ \vdots \\ \mathbf{v}_p^T \mathbf{x} \end{bmatrix} \quad (25)$$



Análise PCA

- ✓ Tomemos a i -ésima componente de $\mathbf{z}$ na Eq. (25):

$$z_i = \mathbf{v}_i^T \mathbf{x} = \begin{bmatrix} v_{1i} & v_{2i} & \cdots & v_{ii} & \cdots & v_{pi} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_i \\ \vdots \\ x_p \end{bmatrix}, \quad (26)$$

$$= v_{1i}x_1 + v_{2i}x_2 + \cdots + v_{ii}x_i + \cdots + v_{pi}x_p \quad (27)$$

- ✓ Assim, a i -ésima componente de $\mathbf{z}$ é uma combinação linear dos atributos de $\mathbf{x}$, com as componentes do i -ésimo autovetor $\mathbf{v}_i$ sendo os coeficientes de ponderação.
- ✓ Resumindo, z_i é o produto escalar de $\mathbf{v}_i$ e $\mathbf{x}$.



Diagonalização da Matriz C_x

- ✓ Ao aplicar a matriz Q sobre os vetores de atributos originais, da forma como está definida na Eq. (23), percebemos que as dimensões dos vetores x_k e z_k são iguais (i.e. $p = q$). Portanto, não temos aqui uma redução de dimensionalidade.
- ✓ O que, então, acontece com os vetores de dados?
- ✓ Que tipo de transformação eles sofreram?
- ✓ Para responder estas questões, vamos precisar calcular a matriz de covariância dos dados transformados, ou seja, precisamos determinar

$$C_z = E[zz^T]. \quad (28)$$



Diagonalização da Matriz $\mathbf{C}_x$

- ✓ A partir da Eq. (28) e da Eq. (24), obtemos:

$$\mathbf{C}_z = E[\mathbf{z}\mathbf{z}^T] \quad (29)$$

$$= E[(\mathbf{V}^T \mathbf{x}) (\mathbf{V}^T \mathbf{x})^T] \quad (30)$$

$$= E[(\mathbf{V}^T \mathbf{x}) (\mathbf{x}^T \mathbf{V})] \quad (31)$$

$$= E[\mathbf{V}^T (\mathbf{x}\mathbf{x}^T) \mathbf{V}] \quad (32)$$

$$= \mathbf{V}^T E[\mathbf{x}\mathbf{x}^T] \mathbf{V} \quad (33)$$

$$= \mathbf{V}^T \mathbf{C}_x \mathbf{V} \quad (34)$$

- ✓ Este resultado mostra que dada a matriz de covariância dos dados originais $\mathbf{C}_x$ e a matriz de autovetores $\mathbf{V}$, facilmente obtemos a matriz de covariância dos dados transformados $\mathbf{C}_z$.



Diagonalização da Matriz C_x

- ✓ Contudo, não diz muita coisa sobre a forma da matriz de covariância dos dados transformados. Para isso, vamos expandir os produtos matriz-vetor da Eq. (34), começando pelo produto $C_x V$:

$$C_x V = C_x \begin{bmatrix} \vdots & \vdots & \vdots & \vdots \\ \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_p \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix} \quad (35)$$

$$= \begin{bmatrix} \vdots & \vdots & \vdots & \vdots \\ C_x \mathbf{v}_1 & C_x \mathbf{v}_2 & \cdots & C_x \mathbf{v}_p \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}_{p \times p} \quad (36)$$

$$= \begin{bmatrix} \vdots & \vdots & \vdots & \vdots \\ \lambda_1 \mathbf{v}_1 & \lambda_2 \mathbf{v}_2 & \cdots & \lambda_p \mathbf{v}_p \\ \vdots & \vdots & \vdots & \vdots \end{bmatrix}_{p \times p} \quad (37)$$

usando o fato que $C_x \mathbf{v}_i = \lambda_i \mathbf{v}_i$.



Diagonalização da Matriz $\mathbf{C}_x$

- ✓ Agora, lembrando que $\mathbf{V}^T$ também é uma matriz $p \times p$, podemos realizar a segunda parte do produto:

$$\mathbf{V}^T \mathbf{C}_x \mathbf{V} = \underbrace{\begin{bmatrix} \cdots & \mathbf{v}_1^T & \cdots \\ \cdots & \mathbf{v}_2^T & \cdots \\ & \vdots & \\ \cdots & \mathbf{v}_p^T & \cdots \end{bmatrix}}_{p \times p} \underbrace{\begin{bmatrix} \vdots & \vdots & & \vdots \\ \lambda_1 \mathbf{v}_1 & \lambda_2 \mathbf{v}_2 & \cdots & \lambda_p \mathbf{v}_p \\ \vdots & \vdots & & \vdots \end{bmatrix}}_{p \times p} \quad (38)$$



Diagonalização da Matriz $\mathbf{C}_x$

✓ Chegamos à seguinte expressão da matriz de covariância $\mathbf{C}_z$:

$$\mathbf{C}_z = \mathbf{V}^T \mathbf{C}_x \mathbf{V} \quad (39)$$

$$= \begin{bmatrix} \lambda_1 \mathbf{v}_1^T \mathbf{v}_1 & \lambda_2 \mathbf{v}_1^T \mathbf{v}_2 & \cdots & \lambda_p \mathbf{v}_1^T \mathbf{v}_p \\ \lambda_1 \mathbf{v}_2^T \mathbf{v}_1 & \lambda_2 \mathbf{v}_2^T \mathbf{v}_2 & \cdots & \lambda_p \mathbf{v}_2^T \mathbf{v}_p \\ \vdots & \vdots & \ddots & \vdots \\ \lambda_1 \mathbf{v}_p^T \mathbf{v}_1 & \lambda_2 \mathbf{v}_p^T \mathbf{v}_2 & \cdots & \lambda_p \mathbf{v}_p^T \mathbf{v}_p \end{bmatrix} \quad (40)$$

$$= \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 \cdots & 0 & \lambda_p \end{bmatrix} \quad (41)$$



Diagonalização da Matriz C_x

- ✓ O produto $V^T C_x V$ pode também ser desenvolvido em função dos elementos de C_x .

$$C_z = V^T C_x V \quad (42)$$

$$= \begin{bmatrix} \sigma_1^2 \mathbf{v}_1^T \mathbf{v}_1 & \sigma_{12} \mathbf{v}_1^T \mathbf{v}_2 & \cdots & \sigma_{1n} \mathbf{v}_1^T \mathbf{v}_p \\ \sigma_{21} \mathbf{v}_2^T \mathbf{v}_1 & \sigma_2^2 \mathbf{v}_2^T \mathbf{v}_2 & \cdots & \sigma_{2n} \mathbf{v}_2^T \mathbf{v}_p \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{n1} \mathbf{v}_p^T \mathbf{v}_1 & \sigma_{n2} \mathbf{v}_p^T \mathbf{v}_2 & \cdots & \sigma_p^2 \mathbf{v}_p^T \mathbf{v}_p \end{bmatrix} \quad (43)$$

$$= \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 \cdots & 0 & \sigma_p^2 \end{bmatrix} \quad (44)$$



Diagonalização da Matriz $\mathbf{C}_x$

- ✓ Resumindo, temos que a matriz de covariância dos dados transformados $\mathbf{C}_z = \mathbf{V}^T \mathbf{C}_x \mathbf{V}$ tem a seguinte forma:

$$\mathbf{C}_z = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 \cdots & 0 & \lambda_p \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & 0 & \cdots & 0 \\ 0 & \sigma_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 \cdots & 0 & \sigma_p^2 \end{bmatrix} \quad (45)$$



Diagonalização da Matriz C_x

- ✓ Do exposto na Eq. (45), tiramos as seguintes conclusões:
 1. A matriz de covariância dos dados transformados é diagonal, ou seja, não há correlação entre as componentes do vetor z .
 2. Ou seja, PCA atua sobre os dados em X para gerar um novo conjunto de dados Z , cuja matriz de covariância é diagonal.
 3. As variâncias das variáveis transformadas são iguais aos autovalores de C_x .
 4. Os autovalores, por sua vez, são iguais às variâncias das variáveis originais.
- ✓ Uma consequência imediata desses resultados é que não é necessário calcular os autovalores da matriz C_z , já que eles são iguais às variâncias das variáveis originais!!



Interpretação Geométrica

- ✓ A transformação linear do PCA pode ser entendida como uma mudança de base. Uma base no espaço $\mathbb{R}^n$ é qualquer conjunto de n vetores linearmente independentes (LI) usado para representar os vetores daquele espaço.
- ✓ Por exemplo, a base canônica do $\mathbb{R}^2$ é formada pelos vetores

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad (46)$$

- ✓ Assim, qualquer vetor $\begin{bmatrix} a & b \end{bmatrix}^T$ no $\mathbb{R}^2$ pode ser escrito como

$$\begin{bmatrix} a \\ b \end{bmatrix} = a\mathbf{e}_1 + b\mathbf{e}_2 = a \begin{bmatrix} 1 \\ 0 \end{bmatrix} + b \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad (47)$$



Interpretação Geométrica

- ✓ Uma outra possível base do $\mathbb{R}^2$ é formada pelos vetores

$$\mathbf{v}_1 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad (48)$$

- ✓ Neste caso, o vetor $[a \ b]^T$, originalmente escrito com relação à base $\mathcal{B}_1 = \{\mathbf{e}_1, \mathbf{e}_2\}$, com relação à base $\mathcal{B}_2 = \{\mathbf{v}_1, \mathbf{v}_2\}$ passa ser representado como

$$\begin{bmatrix} a \\ b \end{bmatrix} = a\mathbf{v}_1 + (b - a)\mathbf{v}_2 = a \begin{bmatrix} 0 \\ 1 \end{bmatrix} + (b - a) \begin{bmatrix} 1 \\ 1 \end{bmatrix} \quad (49)$$

$$\begin{bmatrix} a \\ b \end{bmatrix}_{\mathcal{B}_1} \equiv \begin{bmatrix} a \\ (b - a) \end{bmatrix}_{\mathcal{B}_2} \quad (50)$$



Interpretação Geométrica

- ✓ Existem muitas outras possibilidades de se formar uma base no $\mathbb{R}^2$, bastando para isso que os vetores sejam LI.
- ✓ A base $\mathcal{B}_1$ é chamada de base ortonormal $\{\mathbf{e}_1, \mathbf{e}_2\}$, porque os vetores $\mathbf{e}_1$ e $\mathbf{e}_2$ são ortogonais (ou perpendiculares) entre si, pois seu produto interno é nulo.
- ✓ Além disso, ambos tem norma unitária (i.e. $\|\mathbf{e}_1\| = \|\mathbf{e}_2\| = 1$).
- ✓ Com relação à PCA, os vetores de dados originais $\mathbf{x}_k$ são escritos em relação à base canônica do $\mathbb{R}^p$.
- ✓ Enquanto os vetores transformados $\mathbf{z}_k$ são escritos em relação à base formada pelos autovetores da matriz de covariância $\mathbf{C}_x$.





Interpretação Geométrica

- ✓ Lembre-se que no espaço original as componentes do vetor $\mathbf{x}_k$ estão correlacionadas, enquanto no espaço transformado as componentes do vetor $\mathbf{z}_k$ não.
- ✓ Dito de outra forma, no sistema de coordenadas perpendiculares associado à nova base formada pelos autovetores de $\mathbf{C}_x$, as componentes de $\mathbf{z}_k$ são descorrelacionadas.
- ✓ Do ponto de vista geométrico, o processo de descorrelação levado a cabo via PCA corresponde a uma rotação do sistema de coordenadas no qual os dados são representados.



Interpretação Geométrica

- ✓ Graficamente, o processo de diagonalização da matriz de covariância de um conjunto de dados, ou equivalente, de decorrelação dos atributos de um conjunto de dados, está mostrado na figura abaixo.



PCA para Seleção de Atributos

- ✓ Pode-se usar a primeira componente z_1 para verificar a importância de cada atributo do vetor $\mathbf{x}$ e selecionar os mais relevantes.
- ✓ Para isso, basta entender que a operação que gera o atributo $z_1 = \mathbf{v}_1^T \mathbf{x}$ depende do autovetor que define a direção (ou eixo) de maior variância dos dados. Podendo ser interpretada como uma projeção de $\mathbf{x}$ na direção de $\mathbf{v}_1$.

- ✓ Percebe-se os coeficientes v_{j1} , $j = 1, \dots, p$, ponderam os atributos originais $\{x_1, x_2, \dots, x_p\}$; ou seja

$$z_1 = v_{11}x_1 + v_{21}x_2 + v_{31}x_3 + \dots + v_{p1}x_p \quad (51)$$

- ✓ Assim, quanto maior for o coeficiente v_{j1} , mais importante é a variável x_j , $j = 1, \dots, p$.



PCA para Redução de Dimensão

✓ Usando apenas as q primeiras colunas de $\mathbf{V}$, obtemos

$$\mathbf{V}_q = \begin{bmatrix} \vdots & \vdots & \cdots & \vdots \\ \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_q \\ \vdots & \vdots & \cdots & \vdots \end{bmatrix}_{p \times q} \Rightarrow \mathbf{Q}_q = \mathbf{V}_q^T \quad (52)$$

✓ A matriz $\mathbf{Q}_q$ tem dimensão $q \times p$. O vetor $\mathbf{z}_k = \mathbf{Q}_q \mathbf{x}_k = \mathbf{V}_q^T \mathbf{x}_k$ terá dimensão $q \times 1$. E a matriz de covariância $\mathbf{C}_z^{(q)}$ é dada por

$$\mathbf{C}_z^{(q)} = \mathbf{V}_q^T \mathbf{C}_x \mathbf{V}_q = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 \cdots & 0 & \lambda_q \end{bmatrix}_{q \times q} \quad (53)$$



Uma Medida da Informação Contida em $\mathbf{X}$

- ✓ Lembrando que nosso objetivo inicial era encontrar uma transformação linear que preservasse a informação relevante contida nos dados originais. Mas, como quantificar a informação relevante em um conjunto de dados?
- ✓ Podemos definir a Variância Total (VT) como uma medida da quantidade de informação contida nos dados originais:

$$VT = \sigma_1^2 + \sigma_2^2 + \cdots + \sigma_p^2 \quad (54)$$

$$= \lambda_1 + \lambda_2 + \cdots + \lambda_p \quad (55)$$

- ✓ Como $\lambda_i = \sigma_i^2$, podemos criar uma medida de quanto da informação (i.e. variância) do conjunto original está sendo representada no autovalor λ_i .



Uma Medida da Informação Contida em $\mathbf{X}$

- ✓ Chamaremos esta medida de variância explicada pelo i -ésimo autovalor (VE_i):

$$VE_i = 100 \times \frac{\lambda_i}{VT} = 100 \times \left(\frac{\lambda_i}{\lambda_1 + \lambda_2 + \dots + \lambda_p} \right) \quad (56)$$

- ✓ Consequentemente, a porcentagem da variância total dos dados explicada pelos primeiros q autovalores é dada por:

$$VE(q) = 100 \times \frac{\sum_{i=1}^q \lambda_i}{VT} \quad (57)$$

$$= 100 \times \left(\frac{\lambda_1 + \lambda_2 + \dots + \lambda_q}{\lambda_1 + \lambda_2 + \dots + \lambda_p} \right) \quad (58)$$

- ✓ O gráfico $VE(q) \times q$ é usualmente chamado de *scree plot*.




Uma Medida da Informação Contida em $\mathbf{X}$

- ✓ A grandeza VT pode ser entendida como uma medida linear da informação total contida nos dados.
- ✓ Lembre-se que as únicas estatística relevante que sobrou com a transformação imposta aos dados pela equação $\mathbf{z} = \mathbf{V}^T \mathbf{x}$ foram as variâncias, na forma de autovalores na diagonal da matriz $\mathbf{C}_z$.
- ✓ As médias dos atributos originais foram eliminadas no Passo 2 do algoritmo do PCA. E as correlações que existiam entre os atributos x_i e x_j não existem mais entre os atributos z_i e z_j .
- ✓ Consequentemente, a grandeza $VE(q)$ é uma medida (linear) da informação dos dados devida aos q primeiros autovalores.
- ✓ Se $q = p$, não há redução de dimensionalidade; logo, não haverá compressão (perda) de informação e uma eventual reconstrução da entrada será perfeita.
- ✓ Se $q < p$, há redução de dimensionalidade; logo, haverá perda de informação e uma reconstrução da entrada não será perfeita.



Classificação Baseada em Múltiplos Protótipos por Classe



1. Transformações Matriciais





ANÁLISES DE COMPONENTES PRINCIPAIS - PCA

Prof. Dr. Julio César Santos dos Anjos
Transformações Lineares

Principais Conceitos — 29 de março de 2026