

Apostila de 3 dias — Domínio total do TF

"Caracterização Informacional do Envelhecimento e do Ruído em Sensores de Slack Embarcados"

Como usar. Três dias de dedicação integral (~8–9 h/dia úteis de estudo). A apostila é **autocontida**: toda a teoria necessária está derivada aqui, ancorada nos números reais do seu artigo (`results.json`).

Leituras externas aparecem só como "se sobrar tempo". Regras: (i) cada bloco termina com um autoteste — responda **de memória, por escrito**, antes de olhar o gabarito no fim do dia; (ii) os exercícios de código são obrigatórios — é neles que a teoria gruda; (iii) se um autoteste falhar, releia o bloco antes de avançar.

Notação: S = slack (contagens inteiras), T = temperatura do die, V = tensão do core, t = tempo. Logs em base 2 (bits), salvo indicação. $\langle \dots \rangle$ Números-âncora entre [colchetes] são do seu `results.json` — cada um deve ser reconhecível de vista ao final dos 3 dias.

DIA 1 — O problema, as medidas de informação e a ponte Gaussiana

Bloco 1.1 — O problema físico como canal de comunicação (1,5 h)

1.1.1 O modelo de sinal

Tudo no trabalho deriva de uma única equação, herdada dos três trabalhos anteriores (sensor SBCCI 2025; fidelidade térmica SBCCI 2026; plataforma TCC):

$$S(t) = S_{aged}(t) - \Delta_{PVT}(T, V) + \varepsilon_q$$

O que o sensor **reporta** (S) é a soma de três coisas de natureza distinta:

$S_{aged}(t)$ — o componente **permanente**, de deriva lenta: o envelhecimento real (BTI/NBTI, portadores quentes). É o que interessa ao SLM. Monotônico, escala de dias.

$\Delta_{PVT}(T, V)$ — o componente **reversível**: flutuação instantânea causada pelo ambiente. Sobe a temperatura $\rightarrow$ caminho mais lento $\rightarrow$ menos slack (por isso $\langle \text{corr}(S, T) \rangle = -0.859$); sobe a tensão $\rightarrow$ mais rápido $\rightarrow$ mais slack ($\langle \text{corr}(S, V) \rangle = +0.213$). Some quando o ambiente volta.

ε_q — ruído de **quantização**: o sensor conta incrementos de fase de 19.85 ps; a saída é um inteiro. Piso irreduzível.

1.1.2 A tradução para canal ruidoso

A jogada conceitual do TF inteiro é ler essa equação como um **canal de comunicação**:

Papel no canal	Objeto físico
Transmissor (mensagem)	$S_{aged}(t)$ — o estado latente de degradação
Canal (ruído)	$\Delta_{PVT}(T, V) + \varepsilon_q$ — reversível + quantização
Receptor	o estimador de RUL, que tenta recuperar a trajetória lenta

Por que isso importa: assim que o problema é um canal, as figuras de mérito naturais deixam de ser variâncias e passam a ser **entropia** (quanta incerteza há na saída), **informação mútua** (quanto o ambiente "escreve" na leitura), **capacidade** (quantos estados o receptor distingue) e **teoria de estimação** (quando

a mensagem se torna detectável no ruído). Cada seção de resultados do artigo é uma dessas perguntas.

1.1.3 As duas falhas do R^2 (a lacuna que motivou tudo)

O trabalho anterior mede a contaminação com o R^2 da regressão linear de S em (T, V) : [0.738] na campanha nova (0.592 no PID anterior, 0.921 no bang-bang). Duas falhas:

Falha 1 — só vê dependência linear. R^2 é função da covariância/correlação de Pearson, e covariância zero caracteriza apenas ausência de **associação linear**. O contraexemplo canônico (decore — cai em arguição): $Y = X^2$ com X simétrico em torno de 0. Então $\text{Cov}(X, Y) = E[X^3] - E[X]E[X^2] = 0$, mas Y é **função determinística** de X — dependência total, correlação nula. Um R^2 de regressão pode ler como "quase independente" uma variável inteiramente determinada pelas entradas por um mapa não-linear. E o risco é real neste domínio: BTI é super-linear em V , Arrhenius é exponencial em $1/T$.

Falha 2 — não tem unidade transferível. "Fração de variância explicada" é dependente do modelo e não responde às perguntas do SLM: quantos estados de envelhecimento o sensor resolve? Quão cedo uma tendência é detectável? Quanta informação de envelhecimento uma bancada preserva? Bits respondem às três na mesma moeda.

A tese do trabalho: substituir R^2 por $I(S; T, V)$ — que é zero **se e somente se** houver independência, sem hipótese de linearidade — e deixar entropia/capacidade/estimação derivarem o resto.

✓ Autoteste 1.1 (responda por escrito, sem consultar)

a) Escreva o modelo de sinal e diga o que cada termo vira no vocabulário de canal. b) Prove que $\text{Cov}(X, X^2) = 0$ para X simétrico e explique em uma frase o que isso demonstra sobre R^2 . c) Quais são as três perguntas do SLM que "variância explicada" não responde?

Bloco 1.2 — Medidas de informação: entropia, condicional, MI, KL (3h)

Corresponde a §3.1-§3.2 do artigo. Fonte externa opcional: Cover & Thomas cap. 2 — mas o essencial está derivado aqui.

1.2.1 Autoinformação e por que o logaritmo

Para uma fonte discreta com símbolos s_k e probabilidades p_k , a autoinformação de um resultado é

$$I(s_k) = -\log_2 p_k \quad [\text{bits}]$$

Intuição: raro = surpreendente = informativo. **Por que log, e não outra função decrescente?** Porque queremos aditividade sob independência: $P(s_k, s_j) = p_k p_j$ deve dar $I(s_k s_j) = I(s_k) + I(s_j)$, e o log é a única função (contínua) que transforma produto em soma. Essa é a resposta de 30 segundos se perguntarem "por que essa definição".

1.2.2 Entropia

$$H(S) = -\sum_k p_k \log_2 p_k = E\{I(S)\}$$

É a **incerteza média** da fonte — o número esperado de bits para descrever uma leitura. Propriedades que você deve saber justificar:

$0 \leq H(S) \leq \log_2 K$ (K = nº de símbolos). Zero quando um símbolo é certo; máximo quando todos equiprováveis (prova do máximo: Jensen, ou multiplicadores de Lagrange).

No trabalho: o slack ocupa [27] níveis inteiros (faixa 267-300), e $[H(S) = 3.43 \text{ bits}]$. Compare com o teto: $\log_2 27 = 4.75 \text{ bits}$. Leitura: a distribuição real está longe de uniforme — 3.43 bits é o **orçamento total de incerteza** que o resto do trabalho vai fatiar em (ambiente removível) + (envelhecimento

recuperável) + (piso de quantização).

1.2.3 Entropia conjunta, condicional e a regra da cadeia

$$H(S, T, V) = H(T, V) + H(S | T, V)$$

$H(S | T, V) = - \sum p(s, t, v) \log_2 p(s | t, v)$ é a incerteza **residual** em S uma vez conhecido o ambiente. No trabalho: $\{H(S | T, V) = 2.30 \text{ bits}\}$. A diferença $H(S) - H(S | T, V) = 3.43 - 2.30 = 1.13$ bits é a "informação ambiental" — que é exatamente a informação mútua:

1.2.4 Informação mútua — a peça central

$$I(S; T, V) = H(S) - H(S | T, V) = \sum p(s, t, v) \log_2 \frac{p(s, t, v)}{p(s)p(t, v)}$$

Três leituras equivalentes (saiba as três):

Redução de incerteza: quantos bits de incerteza sobre S somem quando você conhece (T, V) .

Divergência da independência: a KL entre a lei conjunta e o produto das marginais (ver 1.2.5). Daí a propriedade-chave: $I = 0 \iff$ **independência** — sem nenhuma hipótese de forma funcional. É isto que o R^2 não tem.

Simetria (diagrama de Venn): $I(S; T, V) = H(T, V) - H(T, V | S)$ — a interseção dos círculos de entropia.

Números do trabalho: $\{I(S; T, V) = 1.132 \text{ bits}\}$ (binned), $\{I(S; T) = 1.087\}$, $\{I(S; V) = 0.113\}$ — temperatura domina, como a correlação já sugeria, mas agora com unidade transferível. A **fração de informação** $I/H(S) = 1.132/3.43 = \{0.330\}$ é o análogo informacional do R^2 : 33% dos bits da leitura são ambiente.

1.2.5 Divergência de Kullback–Leibler

$$D_{KL}(p \parallel g) = \sum_x p(x) \log_2 \frac{p(x)}{g(x)}$$

Leitura operacional: o **custo em bits por símbolo de assumir a lei errada** — codificar dados que vêm de p com um código otimizado para g .

Prova de $D_{KL} \geq 0$ (2 linhas, saiba reproduzir): $-\log_2(\cdot)$ é convexa; por Jensen, $D_{KL} = E_p \left[-\log_2 \frac{g}{p} \right] \geq -\log_2 E_p \left[\frac{g}{p} \right] = -\log_2 \sum_x g(x) = 0$, com igualdade sse $p = g$.

Não é métrica: assimétrica e sem desigualdade triangular. No trabalho isso não é defeito, é **resultado**: $\{D_{KL}(\text{SBCCI} \parallel \text{PID}) = 1.94\}$ vs $\{D_{KL}(\text{PID} \parallel \text{SBCCI}) = 1.01 \text{ bits}\}$. A direção "descrever a bancada ruidosa com a referência apertada" custa mais que o inverso — porque a PID (estreita) atribui probabilidade ínfima às excursões largas da SBCCI, e o log pune atribuir $g(x) \approx 0$ onde $p(x) > 0$. A **Jensen-Shannon** (simétrica, limitada a 1 bit) dá $\{0.279 \text{ bits}\}$ — a "distância entre ambientes de validação" transferível.

✓ Autoteste 1.2

a) Derive $I(S; T, V) = H(S) - H(S | T, V)$ a partir da definição por KL. b) Prove $D_{KL} \geq 0$ por Jensen, de memória. c) $H(S) = 3.43$, $H(S | T, V) = 2.30$: extraia a MI e a fração de informação, e diga em uma frase o que cada uma significa fisicamente. d) Por que a assimetria 1.94 vs 1.01 tem a direção que tem?

Bloco 1.3 — Entropia diferencial e a ponte Gaussiana (2,5 h)

Corresponde a §3.3 do artigo. Este bloco contém a derivação mais importante do Dia 1: a fórmula $-\frac{1}{2} \log_2(1 - R^2)$ que sustenta toda a comparação do §6.1.

1.3.1 Entropia diferencial e suas armadilhas

Para X contínua com densidade f : $h(X) = - \int f \log_2 f \, dx$. Duas propriedades **se perdem** em relação ao caso discreto (e ambas importam para o trabalho):

não é invariante a escala: $h(cX) = h(X) + \log_2 |c|$;

pode ser **negativa**.

Por isso o trabalho trata S como **discreto** (é um inteiro nativo — usar a definição discreta evita dependência de escala e binning arbitrário do próprio S), enquanto T, V contínuos são discretizados em 16 bins equiprováveis **apenas para estimar** a MI conjunta — com a sensibilidade dessa escolha medida e reportada (Dia 2).

1.3.2 A Gaussiana como máxima entropia

Fato central (usado duas vezes no trabalho): entre todas as densidades de variância fixa σ^2 , a Gaussiana maximiza a entropia diferencial, com

$$h(X_{Gauss}) = \frac{1}{2} \log_2(2\pi e \sigma^2)$$

(Esboço da prova: maximizar $-\int f \ln f$ sujeito a normalização e variância fixa; Lagrange dá $f \propto e^{-\lambda x^2}$.)

Os dois usos: (i) é o que torna a conversão $R^2 \rightarrow$ MI Gaussiana-equivalente uma comparação significativa (abaixo); (ii) é o passo crucial da capacidade do canal Gaussiano (Dia 2).

1.3.3 ★ A DERIVAÇÃO DO QUADRO: $I_{Gauss} = -\frac{1}{2} \log_2(1 - R^2)$

Esta é a fórmula-ponte de todo o §6.1 — você precisa saber derivá-la, não só citá-la. Suponha (S, T, V) **conjuntamente Gaussianos** e seja $\hat{S}$ o ajuste linear de S em (T, V) com fração de variância explicada R^2 .

Passo 1. Para Gaussianas, condicionar é Gaussiano com variância constante: $S \mid (T, V) \sim \mathcal{N}(\hat{S}, \sigma_{S|TV}^2)$, e por definição de R^2 : $\sigma_{S|TV}^2 = (1 - R^2) \sigma_S^2$.

Passo 2. MI como diferença de entropias diferenciais: $I(S;T,V) = h(S) - h(S \mid T,V) = \frac{1}{2} \log_2(2\pi e \sigma_S^2) - \frac{1}{2} \log_2(2\pi e (1-R^2) \sigma_S^2)$

Passo 3. Tudo cancela menos:

$$I_{Gauss} = -\frac{1}{2} \log_2(1 - R^2)$$

Verificação com os seus números: $R^2 = 0.738 \rightarrow -\frac{1}{2} \log_2(0.262) = 0.967$ bits. ✓

A leitura que faz a comparação funcionar: 0.967 bits é a MI que os dados teriam **se** a dependência fosse exatamente a linear-Gaussiana que o R^2 enxerga. Se a MI **medida** exceder isso, existe dependência que o resumo de segundo momento não captura. Medido: binned 1.132 (+17%), KSG 1.221 (+26%). [faixa 17–26%; envelope com ICs 13–32%].

1.3.4 A letra miúda da ponte (que o próprio artigo usa a seu favor)

A comparação contrasta uma **MI discreta** (S inteiro) com um **construto contínuo** (a fórmula Gaussiana).

Para um sinal com muitos níveis e entropia alta ($H(S) = 3.43 \gg 1.13$), a discretização quase não morde — o excesso bruto é, se algo, conservador. Mas para um **resíduo quantizado em poucas contagens** (o caso detrendizado do §6.1), a MI discreta pode legitimamente ficar **abaixo** do equivalente contínuo (teto entrópico baixo + viés descendente do estimador em MI pequena). Guarde isso: é a razão pela qual o déficit detrendizado de -19/-11% **não** pode ser lido como "a relação é sub-linear" — apenas como "nenhum excesso não-linear é resolvível acima do piso do estimador nesta série". (Slide de backup do deck já formula exatamente assim.)

Exercício de código 1 (40 min)

No repo, escreva ~15 linhas: carregue o CSV (pule `#`, descarte dropouts, corte 1 h de soak), monte o histograma inteiro de `dut_slack` e compute $-\sum p \log_2 p$. Alvo: `[H_S_plugin] = 3.4296`. Depois confirme $-\frac{1}{2} \log_2(1 - 0.7382) = 0.9667$ e $1.1315/0.9667 - 1 = 17.05\%$ com o `results.json` aberto do lado.

✓ Autoteste 1.3

a) Derive $-\frac{1}{2} \log_2(1 - R^2)$ no papel, os 3 passos, sem consultar. b) Por que S é tratado como discreto e T, V como binned? Cite os dois problemas da entropia diferencial. c) Em que regime a comparação discreto-vs-Gaussiano é conservadora, e em que regime ela pode gerar déficit legítimo? Por que isso blinda (e limita) a leitura do resultado detrendizado?

Gabarito do Dia 1 (conferir só após responder)

1.1a Transmissor = S_{aged} ; canal/ruído = $\Delta_{PVT} + \varepsilon_q$; receptor = estimador de RUL. **1.1b** $E[X^3] = 0$ por simetria $\Rightarrow \text{Cov} = 0$ com dependência determinística $\Rightarrow$ métricas de segundo momento têm ponto cego estrutural para dependência não-linear. **1.1c** Estados resolvíveis; antecedência de detecção; informação preservada por bancada.

1.2a $D_{\text{KL}}(p(s,t,v)|p(s)p(t,v)) = \sum p \log_2 \frac{p(s,t,v)}{p(s)p(t,v)} = \sum p \log_2 \frac{p(s|t,v)}{p(s)} = H(S) - H(S|T,V)$. **1.2c** $I = 1.13$ bits = o que o ambiente "escreve" em cada leitura; fração 0.33 = análogo informacional do R^2 . **1.2d** A referência PID estreita dá probabilidade ≈ 0 às excursões da SBCCI; o log pune isso; a direção inversa é mais barata porque a SBCCI larga "cobre" a PID.

1.3b Diferencial não é invariante a escala e pode ser negativa; o inteiro nativo de S dispensa binning arbitrário. **1.3c** Conservadora quando $H \gg I$ (série bruta); déficit legítimo quando o resíduo tem teto entrópico baixo (detrendizado) — blinda contra ler o déficit como sub-linearidade, mas também impede afirmar não-linearidade instantânea.

DIA 2 — Estimar informação de dados reais; canal; teoria de estimação

O Dia 2 é o coração metodológico. A manhã (Bloco 2.1) é a parte do trabalho que **não está em livro-texto** e onde a arguição vai mirar.

Bloco 2.1 — Estimar MI de uma série autocorrelacionada (3,5 h)

Corresponde a §4.2 e §6.1. Leia `analysis/tier1_pipeline.py` linha a linha durante este bloco — é obrigatório, não opcional.

2.1.1 O estimador plug-in e seu viés

Estimar I substituindo probabilidades por frequências relativas (histograma conjunto) produz o estimador **plug-in**. Problema: ele é **viesado para cima** — com amostras finitas, flutuações aleatórias criam "estrutura" espúria no histograma conjunto que se contabiliza como dependência. A correção de **Miller-Madow** remove o primeiro termo do viés:

$$\hat{H}_{MM} = \hat{H}_{\text{plugin}} + \frac{\hat{K} - 1}{2n \ln 2} \text{ bits}$$

($\hat{K}$ = nº de células ocupadas). Para MI (combinação de 4 entropias), as correções se combinam. Com n na casa dos milhares **efetivos** (não 768k — ver 2.1.3), a correção importa.

2.1.2 O estimador KSG (verificação cruzada independente)

Kraskov–Stögbauer–Grassberger estima MI **sem binning**, por distâncias de k -vizinhos-mais-próximos no espaço conjunto: $\hat{I} \approx \psi(k) + \psi(N) - \langle \psi(n_x+1) + \psi(n_y+1) \rangle$ (ψ = digamma; n_x, n_y = contagens de vizinhos nas marginais dentro do raio conjunto). Entender **a ideia** basta: densidade local conjunta vs. produto das marginais, medida por geometria de vizinhança em vez de histograma. Como S é inteiro (empates de distância quebram o kNN), o pipeline aplica **dither** e roda sobre subamostra decimada.

Por que dois estimadores? Famílias com vieses de natureza diferente. Se concordassem sempre, um seria redundante; aqui: binned [1.132, IC [1.091, 1.176]] vs KSG [1.221, IC [1.156, 1.275]] — ICs se sobrepõem **só estreitamente** (em [1.156, 1.176]), pontos em extremos opostos. O artigo NÃO chama isso de concordância: chama de **diferença sistemática caracterizada**, e por isso reporta o excesso como **faixa** 17–26% (envelope com ICs: 13–32%), não como número único. Essa postura — reportar a divergência como incerteza de estimador em vez de escolher o número mais bonito — é um dos pontos de honestidade que sustentam o item "metodologia" da rubrica.

2.1.3 ★ n_{eff} : por que 768.884 amostras "valem" 1.224

O problema. Toda fórmula de IC assume amostras independentes. Uma série a 1 Hz cujo processo físico muda em minutos é **massivamente redundante**: amostras vizinhas são quase cópias. Usar n bruto encolheria os ICs por um fator $\sqrt{768884/1224} \approx 25\times$ — certeza falsa.

A solução. Tempo de autocorrelação integrado:

$$\tau_{\text{int}} = \frac{1}{2} + \sum_{k=1}^K \rho(k) \quad (\text{em amostras; corte } K \text{ onde a FAC deixa de ser significativa})$$

e **tamanho efetivo de amostra** $n_{\text{eff}} = n/(2\tau_{\text{int}})$. Nos dados: [$\tau_{\text{int}} = 314$ s] (≈ 5 min de decorrelação)
 $\Rightarrow n_{\text{eff}} = 768884/628 = [1.224]$.

! TAREFA CRÍTICA (30 min): abra `tier1_pipeline.py` e escreva na ficha **como exatamente** o script computa τ_{int} (até que defasagem soma a FAC? qual critério de corte? sobre a série bruta ou detrendizada?). Esta é a única resposta-chave de arguição que **não está no PDF** — só no código. Rode também uma sensibilidade rápida: se τ_{int} fosse 250 ou 400, o que acontece com n_{eff} e com o CRLB do Bloco 2.3? (Ambos escalam; saiba a direção: $n_{\text{eff}} \propto 1/\tau_{\text{int}}$, sd do CRLB $\propto \sqrt{\tau_{\text{int}}}$.)

Tudo no trabalho usa n_{eff} : ICs (moving-block bootstrap com blocos de comprimento $\sim 2\tau_{\text{int}}$, que preservam a estrutura de dependência dentro do bloco), o piso surrogate, a verossimilhança Bayesiana (série **decimada** até n_{eff} pontos para o i.i.d. valer), o CRLB, o Kalman (médias em blocos de $2\tau_{\text{int}}$). É a espinha dorsal — o artigo chama de " pilar da honestidade".

2.1.4 O piso nulo surrogate: separar dependência real de viés

Mesmo com MM, quanto do 1.132 é viés residual? Resposta empírica: medir o que o estimador reporta **sob independência garantida que preserve tudo o mais**. Método: deslocar circularmente o fluxo (T, V) contra S por defasagens aleatórias grandes — isso **destrói a dependência cruzada** mas **preserva as marginais e a autocorrelação de cada canal** (é por isso que o deslocamento é circular, e não um embaralhamento, que destruiria a autocorrelação e subestimaria o piso). Resultado: nulo com média [0.069] e p95 [0.097 bits]. O medido é [12×] o piso $\Rightarrow$ dependência esmagadoramente real.

Refinamento que blinda o excesso: descontando o viés médio (0.069) do excesso bruto (0.165 bits), sobram [0.10 bits $\approx 10\%$] ainda positivos — e mesmo descontando o p95 (0.097) sobram 0.068 bits. O excesso bruto **não é** artefato do piso de viés.

2.1.5 ★★ As "duas ameaças distintas" — o parágrafo mais importante do artigo

Há **duas** razões pelas quais o excesso MI-sobre-equivalente poderia ser espúrio, e elas são independentes:

Ameaça A — viés de estimador. Testada pelo surrogate. O excesso **sobrevive** (sobra ~10% após desconto). ✓

Ameaça B — confusão com a tendência compartilhada. Envelhecimento e deriva lenta de T , V dividem o eixo do tempo numa campanha de 214.6 h; a MI bruta contabiliza essa co-tendência como "dependência". Teste: repetir a comparação inteira nas **séries detrendizadas** (as mesmas da correção PVT). Resultado: $R^2_{detr} = [0.640] \Rightarrow$ equivalente $[0.736 \text{ bits}]$; MI medida binned $[0.596, \text{IC } [0.582, 0.632]]$, KSG $[0.656, \text{IC } [0.622, 0.735]]$ — **déficit de -19% a -11%**. O excesso **não sobrevive**. ✗

Consequência (a retração honesta): o excesso bruto está concentrado na tendência compartilhada, não na física PVT reversível instantânea. A leitura causal "a MI excede o R^2 porque a física é não-linear" é **retratada**. O que fica de pé é o argumento **estrutural**: a MI não tem ponto cego de linearidade, seja qual for a origem da dependência — e ela de fato capturou (na tendência) dependência que o R^2 não via. Note o detalhe fino do IC: o teto do KSG detrendizado (0.735) **toca** o equivalente (0.736) — o KSG é compatível com paridade exata; o binned fica claramente abaixo (e a 1.3.4 explica por que "abaixo" não significa sub-linear).

Treino obrigatório: conte a lógica completa — bruta pareada com R^2 bruto $\rightarrow$ excesso real (sobrevive ao surrogate) $\rightarrow$ não sobrevive ao detrend $\rightarrow$ retração da causa, manutenção da estrutura — em **90 segundos cronometrados**, três vezes, até sair fluido. É a resposta mais provável da defesa inteira.

2.1.6 Sensibilidade de bins (a pergunta fácil de derrubar)

T , V em 16 bins equiprováveis; repetindo com 12/24/32: $I \in [[1.111, 1.171]]$ — faixa de ~0.06 bits, mesma ordem do IC. Até o extremo inferior fica acima do piso (0.097) e do equivalente (0.967). Resposta pronta: "nenhuma conclusão depende dos 16 bins".

✓ Autoteste 2.1

a) Por que o plug-in é viesado para cima, e o que a correção MM faz? b) Defina τ_{int} e n_{eff} ; o que aconteceria com os ICs usando n bruto? c) Por que o surrogate usa deslocamento **circular** e não embaralhamento? d) Enuncie as duas ameaças, o teste de cada uma e o veredito de cada uma. e) O KSG detrendizado é compatível com quê, exatamente? E o binned?

Bloco 2.2 — Canal: codificação de fonte, BSC, capacidade Gaussiana (2 h)

Corresponde a §3.4-§3.5, §6.4.

2.2.1 Codificação de fonte — usada só como cota

Kraft-McMillan: um código-prefixo com comprimentos l_k existe sse $\sum_k 2^{-l_k} \leq 1$. Daí o teorema da codificação de fonte: $H(A) \leq \bar{L} < H(A) + 1$. **Nenhum código sem perdas bate H bits/símbolo em média.** O trabalho usa isso **apenas** como limite ("qualquer código $\geq H(S) = 3.43 \text{ bits/amostra}$ ") e **deliberadamente não roda** Huffman/LZW — resposta de escopo pronta: um codec seria redundante com a entropia e a autocorrelação já calculadas; núcleo coberto como conceito, não como implementação decorativa.

2.2.2 BSC — derive a capacidade em 4 linhas

Canal binário simétrico com probabilidade de cruzamento p : $I(X; Y) = H(Y) - H(Y|X)$. O ruído independe da entrada: $H(Y|X) = H_2(p)$ (entropia binária). Maximizar $H(Y) \Rightarrow$ entrada uniforme $\Rightarrow H(Y) = 1$. Logo

$$C_{BSC} = 1 - H_2(p), \quad H_2(p) = -p \log_2 p - (1 - p) \log_2 (1 - p)$$

Máx. 1 bit em $p = 0$; **zero** em $p = 0.5$ (alarme = moeda). No trabalho, o alarme de envelhecimento por

anela: 1 h $\Rightarrow p \approx [0.49]$, $C \approx 0$ (a deriva de 1 h está enterrada no ruído); 24 h $\Rightarrow p = [0.001]$, $C_{BSC} = [0.99 \text{ bits/decisão}]$; campanha completa $\Rightarrow$ certeza. A transição coincide com o tempo mínimo de observação do CRLB (Bloco 2.3) — três figuras de mérito mutuamente consistentes, evidência de que o modelo de canal é coerente e não três heurísticas soltas.

2.2.3 Capacidade Gaussiana — derive em 5 linhas

Canal aditivo $Y = X + N$, $X \perp N$: $I(X; Y) = h(Y) - h(N)$. $h(N)$ é fixo; maximizar $I =$ maximizar $h(Y)$; com potência de saída fixa, o máximo é a Gaussiana (1.3.2) $\Rightarrow h(Y) = \frac{1}{2} \log_2(2\pi e(\sigma_{sig}^2 + \sigma_{noise}^2))$:

$$C = \frac{1}{2} \log_2 \left(1 + \frac{\sigma_{sig}^2}{\sigma_{noise}^2} \right) \text{ bits/amostra}$$

Números: $\sigma_{noise} = [0.84]$ (resíduo reversível pós-correção), $\sigma_{sig} = [1.29]$ (dispersão do sinal de envelhecimento) $\Rightarrow \text{SNR} [2.36] \Rightarrow C = [0.87 \text{ bits}] \Rightarrow 2^C = \sqrt{1 + \text{SNR}} = [1.8 \text{ estados de envelhecimento distinguíveis}]$ na campanha.

A ressalva que você deve enunciar antes que perguntem: não há codificador inserindo redundância no processo físico — a fórmula é usada como **limite superior de distinguibilidade** (heurística de resolução efetiva), não como taxa alcançável de Shannon. 1.8 é deliberadamente modesto: a excursão de envelhecimento é só $\sqrt{2.36} \times$ o piso de ruído — e é um número que a métrica residual- σ anterior **não tinha como expressar**.

✓ Autoteste 2.2

a) Derive C_{BSC} e C Gaussiana, de memória. b) Por que $p = 0.5$ anula o canal? O que isso significa para o alarme de 1 h? c) Por que 1.8 estados é heurística e não alegação de Shannon literal? d) Resposta de 3 frases para "por que não rodou Huffman?".

Bloco 2.3 — Teoria de estimação: OLS, CRLB, Bayes, MDL (3 h)

Corresponde a §3.6–§3.7, §6.2, §6.5. Você tem vantagem: o seminário de TIP7266 sobre método dos momentos cobre parte disto.

2.3.1 A escada de estimadores da correção PVT

Ajustar $\hat{\Delta}_{PVT}(T, V)$ e formar $S_{corr} = S - \hat{\Delta}_{PVT}$, com três famílias em ordem crescente de hipóteses: **OLS** (linear, livre de distribuição), **MLE** (forma não-linear Arrhenius/super-linear), **Bayesiana** (posterior completa). Métrica de sucesso metodologicamente correta: não a correlação zerada (OLS zera correlação linear **por construção** — seria circular), mas a **MI reversível residual** medida sobre sinais detrendizados: $[0.656 \rightarrow 0.046 \text{ bits, 93\% removidos}]$, com o resíduo no piso do estimador ($0.046 \approx$ ordem do piso nulo $0.069/0.097$ — "ambiente removido" em termos de informação). Verificação cruzada externa: σ residual $[0.84]$ vs 0.73 do PID publicado.

O resultado-chave da correção: remover PVT não só limpa — **expõe:** $[\text{corr}(S, t): -0.35 \rightarrow -0.73]$. Honestidade sobre este número: parte do fortalecimento é mecânica (remover variância ortogonal a t infla a correlação com t); o ponto defensável é a **exposição da tendência** como estrutura dominante do resíduo + a corroboração independente do ICA (Dia 3).

2.3.2 ★ CRLB da inclinação — a derivação do quadro nº 2

Modelo: $y_i = \alpha + \beta t_i + \varepsilon_i$, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ i.i.d., n_{eff} pontos efetivos uniformes em $[0, T]$. O limite de Cramér-Rao: $\text{Var}(\hat{\beta}) \geq 1/I_F(\beta)$, e para este modelo a informação de Fisher é $I_F(\beta) = \sum_i (t_i - \bar{t})^2 / \sigma^2$. Para amostragem uniforme, $\sum (t_i - \bar{t})^2 \approx n_{eff} T^2 / 12$. Logo:

$$\text{sd}(\hat{\beta}) \geq \sigma \sqrt{\frac{12}{n_{eff} T^2}}$$

Verifique: $\sigma = 0.84, n_{eff} = 1224, T \approx 214 \text{ h} \Rightarrow \text{sd} = [0.39 \text{ m-cnt/h}]$. Taxa mínima detectável a 3σ : **[1.2 m-cnt/h]** . Taxa medida: $[-18.3] \Rightarrow [15\times]$ acima do piso — firmemente detectável.

Tempo mínimo de observação (a retrodição-joia): encurtando a janela para $T', n_{eff}(T') \propto T' \Rightarrow \text{sd}(T') \propto T'^{-3/2}$ (um fator $\sqrt{T'}$ das amostras, um fator T' da alavancagem temporal). Resolver $3 \text{sd}(T') = 18.3$ dá $T'_{min} \approx [34 \text{ h}]$. E a retrodição: **as campanhas anteriores tinham ~23 h < 34 h** — eis, em um número, por que elas não conseguiam separar envelhecimento do piso reversível. Este é o gancho de introdução do futuro paper.

O enquadramento que evita overclaim: isto é um **limite de detectabilidade** (quando o envelhecimento se torna observável dado o ruído), não uma predição de vida útil.

2.3.3 A rota Bayesiana (concordância entre paradigmas)

Regressão linear Bayesiana de S_{corr} sobre t , ajustada na série **decimada até n_{eff}** (para a verossimilhança i.i.d. valer), prior de Jeffreys $\Rightarrow$ posterior **t de Student** para a inclinação: $[-18.2 \text{ m-cnt/h}, \text{CrI } 95\% [-19.2, -17.2]]$; propagando pela relação de detectabilidade: tempo mínimo CrI $[[33, 36] \text{ h}] \supset 34 \text{ h}$.

Frequentista $\approx$ Bayesiano $\Rightarrow$ o resultado não depende do paradigma.

$[P(\text{inclinação} < 0) = 100.00\%]$ — e a ressalva de identificação que a rodada 4 inseriu: a leitura dessa deriva **como envelhecimento** é condicionada à hipótese do estudo de dispositivo único (qualquer deriva lenta fora de T, V medidos contaria; §7.6). $P(\text{inclinação} < 0) \neq P(\text{causa} = \text{envelhecimento})$.

2.3.4 MDL: Kolmogorov computável e o veredito "linear"

Kolmogorov: $K(x) = \min_{p: U(p)=x} I(p)$ — informação de um objeto = menor programa que o gera (bem definida a menos de constante, pelo teorema da invariância). Incomputável $\Rightarrow$ o **MDL** a operacionaliza com um código em duas partes $L(\text{modelo}) + L(\text{dados} \mid \text{modelo})$: paga-se pelos parâmetros, depois pelo resíduo. Forma assintótica Gaussiana (estilo BIC):

$$DL = n_{eff} \ln \sigma_{resid}^2 + k \ln n_{eff}$$

Aplicação: a correção não-linear remove um pouco mais de MI residual ($[0.024 \text{ vs } 0.046 \text{ bits}]$) mas quase não reduz variância ($[\sigma: 0.8366 \text{ vs } 0.8403]$) $\Rightarrow [DL_{lin} = -404.7 < DL_{nl} = -394.1] \Rightarrow$ **linear vence**.

A leitura correta (decore a formulação): não é "a física é linear" — é "**neste único e estreito ponto de operação** (125 °C, 1.40 V), os dados não contêm informação de curvatura suficiente para pagar os parâmetros extras do modelo Arrhenius/super-linear". Occam formalizado. E note a convergência que o §7.3 explora: MDL e a checagem de MI detrendizada perguntam coisas **diferentes** (a forma paramétrica se paga? / há excesso não-linear no acoplamento instantâneo?) e chegam **independentemente** ao mesmo veredito — o tipo de validação cruzada que percorre o trabalho todo.

✓ Autoteste 2.3

a) Derive o CRLB da inclinação e reproduza 0.39 m-cnt/h. b) De onde vem o expoente $T^{-3/2}$? Recalcule as 34 h. c) Por que a métrica de sucesso da correção é MI residual detrendizada e não correlação zerada? d) Enuncie o veredito MDL na formulação exata correta e diga qual outra análise chega à mesma conclusão por rota independente. e) $P(\text{inclinação} < 0) = 100\%$: o que isso NÃO afirma?

Gabarito do Dia 2 (conferir após responder)

2.1a Flutuações amostrais criam estrutura espúria no histograma conjunto $\Rightarrow$ MI superestimada; MM soma

$(\hat{K} - 1)/(2n \ln 2)$ à entropia (remove o 1º termo do viés). **2.1b** $\tau_{int} = \frac{1}{2} + \sum \rho(k)$; $n_{eff} = n/(2\tau_{int}) = 1224$; com n bruto os ICs encolheriam $\sim 25\times$ — certeza falsa. **2.1c** Circular preserva a autocorrelação de cada canal (embaralhar a destruiria e o piso sairia subestimado — o teste ficaria fácil demais). **2.1d** A: viés de estimador — surrogate — sobrevive (resta $\sim 10\%$). B: tendência compartilhada — refazer no detrendizado — não sobrevive ($-19/-11\%$). **2.1e** KSG: compatível com paridade exata (IC toca 0.736); binned: claramente abaixo (e 1.3.4 explica por que isso não é sub-linearidade). **2.2b** $H_2(0.5) = 1 \Rightarrow C = 0$: saída independente da entrada; o alarme horário não carrega informação. **2.2c** Não há codificador no processo físico; é limite de distinguibilidade dado o piso de ruído. **2.2d** O teorema já dá a cota $H(S)$; codec só a confirmaria; a autocorrelação já caracteriza a redundância temporal; escopo deliberado, declarado no §3.4/§7. **2.3b** $sd \propto 1/\sqrt{n_{eff}T^2}$ com $n_{eff} \propto T \Rightarrow T^{-3/2}$; $214.6 \cdot (1.17/18.3)^{2/3} \approx 34$ h. **2.3c** OLS zera correlação por construção (circular); a MI residual detrendizada mede dependência **de qualquer forma** remanescente, sem confundir com a tendência. **2.3d** "Curvatura insuficiente neste ponto de operação para pagar os parâmetros"; a checagem de MI detrendizada (§6.1) concorda por rota independente (e, no Dia 3, o MLE do ruído de taxa também). **2.3e** Não afirma que a causa é envelhecimento — só que a inclinação é negativa; identificação condicionada (dispositivo único).

DIA 3 — ICA; bancadas; Wiener/Kalman; genealogia; fronteiras; arguição

Bloco 3.1 — ICA, negentropia e separação cega (1,5 h)

Corresponde a §3.8, §6.7.

3.1.1 A ideia em um parágrafo (o argumento do TCL invertido)

Observados $\vec{x} = (S, T, V)$ como misturas lineares de fontes independentes, o ICA busca a desmistura $\vec{z} = W\vec{x}$ que **maximiza a independência**. O truque para achar as fontes: pelo Teorema Central do Limite, uma **soma** de variáveis independentes é mais Gaussiana que as parcelas — logo, uma combinação $w \cdot \vec{x}$ que seja **maximamente não-Gaussiana** tende a ser uma fonte pura, não uma mistura. O contraste formal é a **negentropia** $N_G(X) = h(X_{Gauss}) - h(X) \geq 0$ (zero sse Gaussiana — segue direto da máxima entropia do Bloco 1.3.2), aproximada na prática por estatísticas de ordem superior (aqui, curtose em excesso). FastICA maximiza esse contraste.

3.1.2 O que foi obtido — e a leitura precisa

Aplicado a (S, T, V) **sem nenhuma forma funcional para Δ_{PVT}** :

o componente que acompanha o tempo bate com o resíduo da regressão S_{corr} em $[|corr| = 0.834]$; um segundo componente alinha com T ($|corr| = 0.688$); fontes fortemente não-Gaussianas (curtose $[+5.82$ e $+29.91]$ — consistente com as caudas pesadas que o KL das bancadas expôs); separação **parcial**: MI residual entre componentes $[0.571 \text{ bits}]$ (ideal: 0) — a deriva não-estacionária e as caudas pesadas só aproximadamente satisfazem as hipóteses do ICA.

As duas precisões que evitam overclaim (decore):

0.834 significa **$\sim 70\%$ de variância compartilhada** com S_{corr} — NÃO "70% do sinal recuperado" (confundiria correlação com fração de sinal).

O que o ICA corrobora é a **separação/correção**, não a atribuição física a envelhecimento. E a corroboração é não-trivial porque regressão e ICA operam no **mesmo espaço** (S,T,V) com **critérios radicalmente**

distintos — mínimos quadrados vs. independência/negentropia. Mesmo componente por dois critérios $\Rightarrow$ o achado não é artefato do critério.

✓ Autoteste 3.1

a) Por que não-Gaussianidade $\Rightarrow$ separabilidade? (TCL invertido, 3 frases.) b) Por que a separação é parcial aqui? Cite o número. c) O que exatamente 0.834 prova, e o que não prova?

Bloco 3.2 — KL entre bancadas: fechar o quadro (0,5 h)

Dois logs estabilizados de ~ 24 h no **dispositivo B** (o mesmo circuito do paper SBCCI — nunca misturado com o dispositivo A de 214 h): bancada SBCCI não-PID ($\sigma_{\text{slack}} [3.23]$, $\sigma_T 2.64^\circ\text{C}$) vs referência PID ($[1.46]$, 1.25°C). Razões de ruído $2.2\times$ (slack) e $2.1\times$ (temperatura) $\Rightarrow$ contaminação de origem térmica. Comparação sobre a **flutuação centrada** (pontos de operação diferentes) $\Rightarrow$ a divergência mede caráter do ruído, não setpoint.

Resultados: $[KL 1.94 / 1.01 \text{ bits}]$ (assimetria = ilustração viva de "KL não é métrica", direção explicada no Dia 1); $[JS = 0.279 \text{ bits}]$; e o refinamento: KL empírico (1.94) $\triangleright$ forma fechada Gaussiana ($[1.67]$) $\Rightarrow$ a bancada não-conforme injeta excursões **não-Gaussianas de cauda pesada** — que é exatamente a premissa que o ICA confirmou pela curtose. Note como as pontas se amarram.

Papel estratégico: este é o **sucedâneo declarado** da comparação de capacidade por regime que a proposta original prometia e não foi entregue (sem log bang-bang pareado) — parágrafo próprio na conclusão + slide de backup. Não é lacuna silenciosa; é renegociação documentada.

Bloco 3.3 — Wiener, Kalman/RTS e RUL como distribuição (2 h)

Corresponde a §3.9, §6.6. Código: `kalman_rul.py`.

3.3.1 Por que uma segunda rota de estimação

O CRLB/Bayes dá **uma** taxa para a campanha toda + barra de erro. A pergunta sequencial é mais rica: (i) qual a melhor estimativa **atual** do nível latente, atualizada continuamente? (ii) qual a **distribuição completa** do tempo até o próximo marco de degradação?

3.3.2 O modelo em uma linha

O processo de Wiener é o análogo contínuo (estado e tempo) das cadeias de Markov da disciplina — o processo de Markov mais simples com trajetórias contínuas (incrementos Gaussianos independentes e estacionários):

$$dX = \mu dt + \sigma_B dW, \quad S_{\text{corr}}(t_k) = X(t_k) + v_k, \quad v_k \sim \mathcal{N}(0, R)$$

Espaço de estados linear-Gaussiano $\Rightarrow$ o **filtro de Kalman** é a atualização Bayesiana **exata** (Gaussiana entra, Gaussiana sai):

$$\hat{x}_k^- = \hat{x}_{k-1} + \mu \Delta t_k, \quad P_k^- = P_{k-1} + \sigma_B^2 \Delta t_k, \quad \hat{x}_k = \hat{x}_k^- + K_k(y_k - \hat{x}_k^-), \quad K_k = \frac{P_k^-}{P_k^- + R}$$

Leia o ganho K_k como um dial de confiança: predição incerta (P^- grande) $\Rightarrow$ acredita na medição; medição ruidosa (R grande) $\Rightarrow$ acredita na predição. O suavizador **RTS** (passada retroativa) converte o filtrado causal em trajetória suavizada da campanha inteira com bandas de credibilidade — a contraparte "denoising de caminho completo" da correção por amostra.

3.3.3 O ajuste e os três achados

Pipeline: média em blocos de $2\tau_{\text{int}} \Rightarrow [1.224]$ observações quase-independentes; σ_B e R por **método dos momentos** (variância dos incrementos vs. defasagem); σ_{rate}^2 (deriva variável, modelo de tendência linear local) por **MLE 1-D** na verossimilhança de inovações do próprio filtro — o mesmo princípio MLE do

Bloco 2.3, agora num modelo dinâmico.

$\{\sigma_{rate}^2 \rightarrow 10^{-10}\}$ **(piso numérico)**: os dados preferem deriva **constante** — **terceira** confirmação independente do veredito "sem curvatura" (MDL §6.2 + MI detrendizada §6.1 + agora isto). Três princípios, três perguntas, um veredito.

Taxa suavizada $\{-15.9 \text{ m-cnt/h}\}$ vs CRLB/Bayes ~ -18 : mesmo sinal e ordem; a diferença de $\sim 15\%$ reflete estimadores distintos (OLS na série toda vs. estado filtrado em blocos), não contradição.

R abaixo do σ_{noise}^2 por amostra — a média num bloco de decorrelação inteiro ainda remove estrutura sub- τ_{int} que o τ_{int} escalar sozinho não captura. E $\{P \text{ suavizado } 0.214 \rightarrow 0.218\}$ essencialmente plano = o filtro atinge regime permanente cedo, como um linear-Gaussiano com R, σ_B^2 constantes prevê — sanidade do modelo.

3.3.4 RUL como distribuição: primeira passagem Gaussiana-inversa

Para Wiener com deriva $\mu < 0$, o tempo de primeira passagem por uma distância D é **Gaussiana inversa** em forma fechada:

$$T_D \sim \text{IG}(\alpha = D/|\mu|, \lambda = D^2/\sigma_B^2), \quad E[T_D] = \frac{D}{|\mu|}, \quad \text{Var}(T_D) = \frac{D^3}{\sigma_B^2 |\mu|^3} = \frac{D}{\sigma_B^2 |\mu|^3}$$

! ERRATA ENCONTRADA AO PREPARAR ESTA APOSTILA — o texto do §3.9 > imprime a variância como $D^3/(|\mu|^3 \sigma_B^2)$; o correto é $> D \sigma_B^2 / |\mu|^3$ (a forma impressa nem fecha dimensionalmente: dá $> h^4 / \text{contagens}^2$ em vez de h^2). É um deslize **apenas na fórmula em prosa** — nenhum número do artigo é afetado (médias/medianas vêm do `scipy.stats.invgauss` no pipeline, que usa a parametrização correta; reverificado: 52.8/8.0 h e 81.1/17.5 h ✓). Correção de um caractere em `03_theory.tex` antes de 22/08. Saber explicar a errata na defesa, se notada, vale mais do que escondê-la.

Números (com $|\mu| = 15.9 \text{ m-cnt/h}$, $\sigma_B = \{0.403 \text{ cnt/vh}\}$):

$D = \sigma_{noise} = 0.84$: média $\{52.9 \text{ h}\}$, mediana $\{8.0 \text{ h}\}$;

$D = \sigma_{signal} = 1.29$: média $\{81.3 \text{ h}\}$, mediana $\{17.5 \text{ h}\}$.

A ligação quantitativa (o achado bonito do §6.6): a enorme assimetria média $\gg$ mediana ocorre exatamente quando D é pequeno em relação à escala de difusão — que é **o mesmo regime de SNR baixo (2.36)** que limita o sensor a 1.8 estados. A limitação de ruído que restringe a resolução é a mesma que torna o RUL de curto horizonte altamente incerto — capacidade e RUL amarrados por um mecanismo, coisa que uma estimativa pontual jamais expressaria.

A ressalva estrutural: os limiares D são **autorreferenciados** ($\sigma_{noise}, \sigma_{signal}$ — grandezas já calculadas) porque não existe limiar de falha calibrado para este sensor $\Rightarrow$ é **metodologia**, no mesmo espírito do CRLB; um limiar calibrado (trabalho futuro) tornaria a eq. operacional.

Exercício de código 2 (30 min)

`from scipy import stats`: monte `invgauss(mu=m/lam, scale=lam)` com $m = D/0.0159$, $\lambda = D^2/0.403^2$ para os dois D ; confira média e mediana; plote as duas densidades e observe a cauda direita. Depois rode `kalman_rul.py` e localize no código: o MLE 1-D de σ_{rate}^2 e a montagem da IG.

Autoteste 3.3

a) Escreva predição/atualização do Kalman e explique o ganho como "dial". b) Quais são as três confirmações independentes de "sem curvatura"? c) De onde vem a assimetria da IG e a que outro resultado ela se liga? d) Enuncie a errata da variância e por que nenhum número é afetado.

Bloco 3.4 — A genealogia das soluções (1 h)

Feche o livro e reconstrua a cadeia causal — depois confira aqui. **Critério: recontar 1 $\rightarrow$ 10 em voz alta em ≤ 5 min, sem travar.**

#	Problema	Solução	Resultado	Problema seguinte
1	R^2 cego a não-linearidade, sem unidade	$I(S; T, V)$ em bits	1.132 vs 0.967 (+17–26%)	como estimar MI de série autocorrelacionada?
2	768k amostras redundantes $\Rightarrow$ ICs falsos	$\tau_{int}, n_{eff}=1224$, block-bootstrap, 2 estimadores	ICs honestos; divergência caracterizada	o medido é real ou viés?
3	estimadores de MI viesados p/ cima	piso surrogate circular	12× o piso; sobra ~10% após desconto	física instantânea ou tendência compartilhada?
4	envelhecimento e T,V dividem o eixo t	repetir no detrendizado	déficit –19/–11% $\Rightarrow$ retração da causa	o que sobra? (o argumento estrutural)
5	contaminação identificada	correção PVT; MDL escolhe linear	0.656 $\rightarrow$ 0.046 (93%); corr –0.35 $\rightarrow$ –0.73	quantos estados o sensor resolve?
6	σ residual não diz resolução	capacidade Gaussiana + BSC	1.8 estados; 0.99 bits @ 24 h	quando a tendência é detectável?
7	predição de 1 dispositivo = overclaim	CRLB + Bayes como limite	1.2 m-cnt/h; 34 h (retrodição das 23 h)	taxa única esconde a incerteza temporal
8	ponto + barra de erro é pobre p/ RUL	Wiener + Kalman/RTS + IG	distribuição completa; $\sigma_{rate} \rightarrow 0$ confirma MDL	limiar não calibrado $\Rightarrow$ autorreferenciado
9	correção depende do modelo de regressão	ICA livre de modelo	0.834 corrobora; separação parcial (0.571)	—
10	sem log bang-bang pareado	KL/JS no dispositivo B como sucedâneo	1.94/1.01; JS 0.279; caudas pesadas	comparação por regime em bits $\rightarrow$ trabalho futuro

Bloco 3.5 — As 6 fronteiras e a frase defensável de cada (1 h)

Memorize a **formulação exata** — a diferença entre parecer pego e parecer dono:

Não-linearidade instantânea não demonstrada. "O excesso bruto é real — sobrevive ao piso de viés — mas não sobrevive ao detrend; a leitura defensável é que nenhum excesso não-linear é resolvível acima do piso do estimador nesta série, o que tampouco significa sub-linearidade (teto entrópico do resíduo quantizado). A contribuição estrutural — MI sem ponto cego de linearidade — permanece."

Capacidade por regime não entregue. "Sem registro bang-bang pareado; entregamos capacidade e RUL no regime PID e o KL/JS entre bancadas como sucedâneo declarado; é o primeiro item de trabalho futuro, não uma lacuna silenciosa."

ICA não é desmistura limpa. "MI residual 0.571 bits; corroborativa — deriva não-estacionária e caudas pesadas só aproximadamente satisfazem as hipóteses; reportada como parcial."

RUL não é predição. "Limite de detectabilidade (CRLB/Bayes) e metodologia de distribuição (IG) com

limiares autorreferenciados, porque não existe limiar de falha calibrado para este sensor."

Identificação não fechada. " $P(\text{inclinação} < 0) = 100\%$ sob a hipótese de que a deriva residual é envelhecimento; dispositivo único, regime único — por isso limite e metodologia, não alegação de causa."

Divergência binned/KSG não resolvida — caracterizada. "Duas famílias com vieses distintos; ICs próprios se sobrepõem só estreitamente; reportamos a faixa 17–26% (envelope 13–32%) como incerteza de estimador, em vez de escolher um número."

Bloco 3.6 — Simulado de arguição com respostas-modelo (2 h)

Cronometre **≤90 s por resposta**, em voz alta. Modelos condensados:

P1. Como τ_{int} foi estimado? Quão sensível é n_{eff} ? → [A SUA resposta da tarefa crítica 2.1.3 — método exato do `tier1_pipeline.py`.] + " $n_{\text{eff}} \propto 1/\tau_{\text{int}}$; o sd do CRLB $\propto \sqrt{\tau_{\text{int}}}$; a conclusão qualitativa (15× acima do piso) sobrevive a variações amplas de τ_{int} ."

P2. Por que 16 bins? E com outros? → "Equiprováveis para não desperdiçar resolução; 12/24/32 dão [1.111, 1.171], faixa da ordem do IC; até o mínimo fica acima do piso e do equivalente — nenhuma conclusão depende dos 16."

P3. MI discreta comparada a um construto Gaussiano contínuo é justo? → "Na série bruta, $H(S) = 3.43 \gg 1.13 \Rightarrow$ o teto quase não morde, comparação conservadora; no resíduo detrendizado o teto morde — e é exatamente por isso que lemos o déficit como 'sem excesso resolvível', nunca como sub-linearidade."

P4. O excesso de 17–26% não é viés de estimador? → "Surrogate circular: nulo 0.069/0.097; medido 12×; descontando o viés médio sobra ~10%, descontando o p95 sobram 0.068 bits — o excesso bruto sobrevive à ameaça de viés; ele cai na outra ameaça, a tendência."

P5. Então a física não é não-linear? → "Não é o que afirmamos: neste ponto de operação estreito não há curvatura resolvível — e três rotas independentes concordam (MI detrendizada, MDL, MLE do ruído de taxa). Numa campanha multi-setpoint com curvatura Arrhenius/BTI amostrada, esperamos os três vereditos se invertem."

P6. Por que não Huffman/LZW? → Resposta do Autoteste 2.2d.

P7. 1.8 estados é capacidade de Shannon literal? → "Heurística de resolução: não há codificador no processo físico; usamos a fórmula como limite superior de distinguibilidade dado o piso pós-correção."

P8. O que a assimetria do KL significa? → "1.94 = custo de descrever a bancada ruidosa com a referência apertada (a PID atribui probabilidade ínfima às excursões da SBCCI e o log pune); 1.01 no inverso; é a ilustração empírica de que KL não é métrica — por isso também reportamos JS = 0.279, simétrica e limitada."

P9. corr -0.35 → -0.73 não é efeito mecânico da remoção de variância? → "Em parte, sim — e por isso não apoiamos a conclusão só nisso: a tendência exposta é corroborada pelo ICA (0.834, critério independente) e a taxa é consistente por três estimadores (OLS, Bayes, Kalman)."

P10. Cadê o bang-bang? → Fronteira 2, verbatim.

P11. Wiener/Kalman está na ementa? → "Aprofundamento declarado (§3.9 e mapeamento D.1b) construído sobre o que a ementa cobre — MLE e processos estocásticos/Markov —, citado à literatura padrão (Kalman; Whitmore; Si), e apresentado como extensão, não como cobertura de núcleo."

P12. O que 0.834 do ICA prova? → "Corroboração de critério: mesmo espaço (S,T,V), critérios opostos (MQ vs independência), mesmo componente — ~70% de variância compartilhada, não 70% do sinal, e válida a separação, não a causa física."

P13. Por que o Bayesiano usa a série decimada? → "Para a verossimilhança i.i.d. valer; decimar até n_{eff} é a forma honesta de declarar a informação realmente disponível — e o resultado bate com o CRLB."

P14. E se a deriva residual não for envelhecimento? → Fronteira 5, verbatim + "é por isso que o multi-dispositivo é o segundo item de trabalho futuro."

P15. Qual é a contribuição, afinal, se a hipótese central caiu? → "Três coisas que o trabalho anterior não podia enunciar: uma métrica de contaminação sem ponto cego de linearidade e com unidade transferível; um protocolo anti-confundimento (n_{eff} , surrogate, detrend, dois estimadores) que inclusive detectou e retratou a nossa própria leitura causal; e a especificação de resolução do sensor — 1.8 estados, alarme 0.99 bits/24 h, detectabilidade em 34 h — que explica quantitativamente por que as campanhas de 23 h não viam envelhecimento. O achado negativo reforça o protocolo: foi ele que o encontrou."

Fechamento (30 min): grave uma passada dos 15 min do deck e ouça. Cada travamento aponta o bloco a reler.

Critério final de conclusão dos 3 dias

Você terminou quando consegue, sem consulta:

Derivar no quadro: $-\frac{1}{2} \log_2(1 - R^2)$; $C_{BSC} = 1 - H_2(p)$; $C = \frac{1}{2} \log_2(1 + \text{SNR})$; $\text{sd}(\hat{\beta}) = \sigma \sqrt{12/(n_{\text{eff}} T^2)}$.

Recontar a genealogia 1→10 em ≤5 min e a lógica do achado negativo em 90 s.

Enunciar as 6 fronteiras com as frases defensáveis.

Responder P1 (τ_{int}) com o método exato do código — e explicar a errata da variância da IG (Bloco 3.3.4), que deve ser corrigida no `.tex` antes de 22/08.

Reconhecer de vista cada número entre [colchetes] e dizer de qual seção vem.