



**UNIVERSIDADE FEDERAL DO CEARÁ
CAMPUS ITAPAJÉ
CIÊNCIA DOS DADOS**

**Apostila de Aula - Notas
ÁREA: RECONHECIMENTO DE PADRÕES**

INTRODUÇÃO À TEORIA DA INFORMAÇÃO E FUNÇÕES ESTADÍSTICAS IMPORTANTES

Prof. Dr. Julio César Santos dos Anjos

Fortaleza, 13 de junho de 2025

Contexto

A forma como se produz ciência vem mudado ao longo de décadas em diferentes campos do conhecimento tais como biologia, física, astronomia, meteorologia, medicina, entre outros. No século XIV, a ciência era baseada na observação de fenômenos físicos e a precisão dos dados era medida de acordo com o campo visual. Hoje, os cientistas observam, por exemplo, o universo com sofisticados telescópios que geram milhões de imagens as quais necessitam de muito tempo de computação para a análise de dados. Alguns experimentos como o Large Synoptic Survey Telescope (LSST) produzem 20 Terabytes de dados brutos por noite¹, no CERN o Large Hadron Collider (LHC) é capaz de produzir 1 Petabyte de dados por dia². Em um passado recente, encontrar a informação em grandes conjuntos de dados era somente possível com bancos de dados relacionais, no qual o usuário ou pesquisador necessita ter uma ideia precisa do que procurar.

Em Big Data as consultas podem incluir desde dados estruturados a não estruturados, tais como vídeos, áudio, páginas web, textos, planilhas e assim por diante, originados de diferentes fontes de dados. Por outro lado, multimídia, redes sociais e dispositivos para a Internet das Coisas (IoT) coletam mais e mais informações nas quais as aplicações Big Data terão um crescente papel na atribuição de valor à informação para empresas e clientes. Contudo, é comum encontrar dados dispersos em múltiplos locais em que o custo de transferência para um único local seria proibitivo, seja por limitações de largura de banda da rede, seja pelo tamanho dos dados a serem armazenados [Jayalath et al. 2014], [Ahn and Jeong 2019].

A comunidade científica tem proposto *Cloud Computing* como uma infraestrutura básica para aplicações Big Data. Os provedores de serviços de *Cloud* mantém a oferta de aluguel de uso de recursos computacionais compartilhados fornecendo serviços com uma qualidade de serviços (QoS) baseado no número de noves (99,9999....%), os quais prometem propriedades como flexibilidade, espaço de armazenamento ilimitado, garantia de isolamento e elasticidade. Contudo, o tempo e o custo requerido para a transferência de dados e a dificuldade de manter um controle de grão fino sobre os recursos é um problema ainda em aberto [Chen and Zhang 2014], [Assuncao et al. 2015].

De outra forma, recursos de Computação Voluntária (*Volunteer Computing* - VC) são recursos exclusivos no momento de sua utilização, porém têm a característica de serem voláteis. Neste contexto, vários usuários doam recursos de seus computadores (que se encontram ociosos) para projetos de diferentes domínios como bio-medicina, previsão de catástrofes e desastres naturais [Anjos et al. 2020]. Além disto, o modelo de VC permite implementar a computação nas bordas (também conhecida como *Edge Computing*) para a utilização de redes 5G em telefonia móvel num futuro próximo. O desenvolvimento destas complexas plataformas é possível, entre outras coisas, devido ao uso de sistemas de Big Data, os quais serão apresentados neste volume.

¹[LSST 2024]

²[CERN 2022]

Sumário

1	Conceitos Básicos	5
1.1	Dado e Informação	5
1.2	Probabilidade e Variáveis Aleatórias	7
1.2.1	Conceitos de Probabilidade	8
1.3	Função Distribuição de Probabilidade	8
1.3.1	Propriedades da Função de Distribuição de Probabilidade	9
1.3.2	Função Densidade e Cumulativa de Probabilidade	9
1.3.3	Valor Esperado e Momento de uma Variável Aleatória	9
1.3.4	Variança e Desvio Padrão de uma Variável Aleatória	10
1.3.5	Covariância de uma Variável Aleatória e Variável Aleatória Independente	11
1.3.6	Correlação de uma Variável Aleatória	11
1.4	Distribuição de Probabilidade Conjunta de Funções	11
1.5	Convergência de Variáveis Aleatórias	13
1.5.1	Desigualdade de Markov	13
1.5.2	Desigualdade de Chebyshev	14
2	Tipos de Função de Distribuição	15
2.1	Distribuição de Pareto	15
2.2	Distribuição Exponencial	16
2.2.1	Propriedade da Falta de Memória	17
2.3	Distribuição Normal	17
2.4	Distribuição Log-normal	18
2.5	Distribuição Gama	19
2.6	Distribuição Beta	21
2.7	Distribuição Weibull	23
2.8	Distribuição Uniforme	24
2.9	Relação entre Distribuições Contínuas	25
3	Predição e Inferência	27
3.1	Método de Bayes	27
3.2	Processos Estocásticos	28
3.2.1	Processos de Markov	29
3.2.2	Equação de Chapman-Kolmogorov	30
3.2.3	Processos Estacionários	31
3.3	Inferência e Decisão	31
3.3.1	Minimização da Taxa de Erros de Classificação	32
3.3.2	Minimização da Perda Esperada	33



3.3.3	Métodos para Decisão e Inferência	34
4	Técnicas e Modelos de Predição	36
4.1	Métodos de Predição Simples	36
4.1.1	Método dos Mínimos Quadrados	37
4.1.2	Método dos K-vizinhos Mais Próximos	38
4.2	Máxima Verossimilhança	39
4.3	Maximum Likelihood e Mínimos Quadrados	40
4.4	Método de Lasso	42
4.5	Método dos Mínimos Ângulos de Regressão	43
4.5.1	Mínimo Ângulo de Regressão - Modificado pelo Método de Lasso	44
4.6	Método de Suavização de <i>Kernel</i>	45
4.6.1	Regressão Local em $\mathbb{R}^p$	46
4.7	Método de Regressão Linear Bayesiana	47
4.7.1	Distribuição dos Parâmetros	48
4.7.2	Distribuição Preditiva	48
4.8	Método de Amostragens	49
4.9	Método de Mistura Finita	51
4.9.1	Distribuição de Mistura Finita	52
	Referências Bibliográficas	53
	Índice Remissivo	54

Capítulo 1

Conceitos Básicos

As aplicações Big Data se diferenciam das demais aplicações científicas por serem além de intensivas em processamento, como por exemplo, aplicações de cálculos numéricos e predição de Montecarlo, serem intensivas em dados. Neste capítulo iremos apresentar conceitos fundamentais sobre dados, informação e inteligência computacional que ajudarão a compreensão dos demais capítulos. Ainda, estudaremos as principais arquiteturas computacionais por trás das infraestruturas que usamos nestas implementações de sistemas para o tratamento de grande volumes de dados.

1.1 Dado e Informação

Desde os primórdios da existência humana já se registrava de alguma forma o conhecimento sobre os acontecimentos de seu cotidiano. O homem primitivo nos deixou em vários locais o registro daquilo que podemos dizer serem os primeiros dados daquela época. Estes dados podem ter diferentes interpretações conforme a cultura local e o conhecimento de um determinado contexto. No Brasil, na Amazônia temos por exemplo, os registros em pinturas rupestres como os representados na Figura 1.1, na cidade de Monte Alegre, no Parque da Pedra Pintada¹ os quais datam de pelo menos 9.200 anos A.C. conforme estudos de paleontólogos americanos.



Figura 1.1: Figura Rupestre na Amazônia, Parque da Pedra Pintada

¹<https://www.youtube.com/watch?v=oQFkXGpWLP4>



Este contexto é importante para nosso aprendizado por dois motivos: primeiro, ilustra o conceito de dado, ou seja, um registro que por si só não carrega informação. Segundo, o estudo feito por cientistas no objeto desta figura (ou seja, a formação rochosa, elementos da pintura, etc...) agrega uma relevância histórica para aquele registro na pedra com uma longevidade maior do que 11.200 anos. Assim, podemos estabelecer que o dado coletado, só terá relevância quando se agregar a este uma propriedade chamada *valor*, com a qual se poderá atribuir um significado a este dado. A partir deste momento, dependendo do interesse de cada observador e do valor atribuído (que depende da interpretação deste próprio observador) o dado passará a conter uma *informação*. Conforme a *relevância* que a informação contém, que varia conforme a qualidade do valor atribuído ao dado, a informação conterá maior ou menor importância.

Ao observarmos a Tabela 1.1 abaixo que contém um conjunto de dados referentes a viagens. O número 1.000,00 na coluna quatro é um dado. Ao analisarmos que o significado de 1.000,00 representa o valor unitário de uma passagem de ida e volta Nacional em reais, estamos atribuindo uma informação ao dado. Já o fato de que uma passagem aérea internacional custa 6 vezes mais do que uma passagem nacional é o que chamamos de *conhecimento*. Igualmente dizer que os eventos internacionais tem a mesma duração que os eventos nacionais, ou seja 3 dias úteis, também é um conhecimento após realizado uma inferência (dedução) sobre as informações. Portanto, o *conhecimento* é o resultado do cruzamento de informações diferentes onde se deve fazer inferências, gerando uma nova informação.

Tabela 1.1: Recursos Financeiros para Viagens de Pesquisa

Custeio	Descrição	Qtde	Valor Unitário	Total
Passagens	Passagens Nacionais (ida e volta)	4	1.000,00	4.000,00
Passagens	Passagens Internacionais (Ida e volta)	3	6.000,00	18.000,00
Diárias	Nacionais	15	320,00	4.800,00
Diárias	Internacionais (US\$ 370,00*)	15	1.665,00	24.975,00
Eventos	Inscrições em eventos nacionais	6	300,00	1.800,00
Eventos	Inscrições em eventos internacionais	6	1.200,00	7.200,00
TOTAL GERAL				R\$ 89.575,00

1 US\$ = R\$ 3,18

No início dos anos 70, ao final da chamada *guerra fria* desenvolve-se os primeiros mecanismos de comunicação de dados em rede que inicialmente recebera o nome de ARPANET, se tornando o embrião da Internet atual. Em 1989, Timothy John Berners-Lee, um cientista britânico que trabalhava no CERN, desenvolveu um protocolo para compartilhar documentos chamado *Hypertext Transfer Protocol* (HTTP) e a linguagem *Hypertext Markup Language* (HTML). Em 1991, disponibilizou na Internet uma plataforma constituída de um servidor HTML e um software cliente para acessá-lo chamado *World Wide Web* (WWW). Dava-se assim os primeiros passos em direção ao compartilhamento de dados e informações em escala mundial, consolidando a Internet. Em 1996, no Brasil, ainda utilizavam-se sistemas de *bulletin board system* (BBS), porém este sistema permitia somente a visualização de caracteres ao invés de imagens/texto do HTML. A infraestrutura de comunicação da época possibilitava uso de links discados de 57600 bps full-duplex para a maioria dos usuários, o que permitia somente a troca de textos de forma meramente aceitável, como pode ser visto na Figura 1.2, a qual representa o acesso a BBS da Mandic. A Mandic foi um dos primeiros “provedores” de conteúdo no Brasil.

Até 1995 a Internet no Brasil era quase que exclusivamente de uso acadêmico. A partir desta data a Internet tornava-se pública, com a formação do Comitê Gestor da Internet no Brasil, assim as



```
CONNECT 33600/ARO
CONNECT 115200 / 04/09/96 (23:09:07)
(MNP/V42 Modem Detected)

<<< MANDIC BES >>> S.4.
PCBoard (R) v15.22 (05/2) 1000 - Noperational Languages Available:

1) English (default)
2) Portuguese (cadastramento)
3) Deutsch
4) RIP Script
5) Barra de Comando
6) INTERNET (somente usu rios cadastrados)

Enter Language # to use (enter)=no change?

'±-' ANSI detected and it will use the default '±-'

Do you want color (enter)-default?

BBS BBS BBS BBS BBS BBS BBS BBS BBS BBS
RRRRR RRRRR RRRR RR\ RRRRR RRRR RRRR RRRR RRRR RRRR\
BBBBBB BBBB BBBB BBBB BBBB BBBB BBBB BBBB BBBB BBBB\
BBBB BBBB BBBB BBBB BBBB BBBB BBBB BBBB BBBB BBBB\
BBB BB\ BBBB BBBB BBBB BBBB BBBB BBBB BBBB BBBB BBBB\
BBBB BBBB BBBB BBBB P\BBB BBBB BBBB BBBB BBBB BBBB\
BBB BBBB BBBB BBBB BBBB BBBB BBBB BBBB BBBB (R)

BBBRRRR RRRRRRR RRRRRRR
BBB BB\ BB\ BB\ BB\
BBBRRR BBBBRRR BBBBRRR
BB\ RR\ BB\ BB\ BB\
BBBRRR BBBBRRR BBBBRRR Node: 201

I N T E R N E T

(011) 816-3911 V.P.C. V.34+ 33.600 (pblico)
0800-216-3911 (Nivel EXTENDEO acima de 300km de Sao Paulo/SP)
E-mail: info@mandic.com.br
http://www.mandic.com.br
Telnet: bbs.mandic.com.br
FAX: (011) 816-3245 VOZ: 870-0888 Internet: 870-0100

What is your first name?
Password (dots will echo?) ()

Your last login: 04/09/96 at 23:08:00hrs
```

Figura 1.2: Mandic a primeira BBS no Brasil, nos anos 90

empresas começaram a divulgar suas próprias informações por servidores HTTP como uma forma de minimizar custos com marketing. O compartilhamento de arquivos exclusivos para leitura, através de um formato aberto chamado *Portable Document Format* (PDF), desenvolvido em 1993 pela Adobe, intensificou ainda mais a distribuição de conteúdo técnico e científico de forma eletrônica.

Após o início do processo de privatizações das empresas de telecomunicações em julho de 1998, o Brasil experimenta um novo ciclo de crescimento vigoroso do compartilhamento de informações via Internet. O surgimento de redes sociais como Orkut (2004), Facebook (2004) e Twitter (2006) acessíveis gratuitamente à população, em conjunto com a disseminação de celulares e dispositivos móveis baratos, que permitiam acesso facilitado à Internet, disseminou ainda mais o compartilhamento de informações entre as pessoas, entretanto numa escala muito maior. Contudo, com a explosão de informação compartilhada, mais e mais recursos computacionais eram necessários para dar conta do processamento destes dados.

1.2 Probabilidade e Variáveis Aleatórias

Quando um experimento é realizado são colhidos dados que contém informações sobre o sistema que os originou. O resultado contudo pode conter fatores indesejados como desvios originados no ambiente computacional, além das informações do próprio sistema. Estes dados ainda podem conter erros de medição e parâmetros não controláveis como sobrecarga do sistema [Jain 1991].

Modelos matemáticos podem ser criados para identificar os princípios que regulam a formação destes dados. O modelo também pode conter erros originados de cálculos de aproximação que geram outros erros em cascata. A probabilidade é uma ferramenta fundamental para o projeto e a análise de algoritmos probabilísticos e aleatórios [Ross 2010]. A adoção de processos estocásticos permite capturar os desvios da média ocasionados devido ao ruído das informações.

Em muitos experimentos não é possível estabelecer-se um modelo determinístico ou previsível relacionando-se todas as variações possíveis do comportamento de suas variáveis. Isto se deve às



características aleatórias que alguns eventos apresentam. Estes eventos não são tão triviais de serem definidos em modelos determinísticos e podem ser até inviáveis de serem modelados [e Albuquerque et al. 2008].

O método probabilístico é uma técnica de análise das propriedades dos elementos de um conjunto que introduz uma probabilidade de sucesso neste conjunto e estuda um elemento escolhido com essas probabilidades [Ross 2010]. Assim, estes experimentos necessitam ser representados por modelos estocásticos ou probabilísticos. Um experimento, com um resultado não determinístico, ou seja, que não possa ser previsto com certeza, tem uma *variável aleatória* X . Uma variável aleatória pode assumir quaisquer valores $x_n \in \mathbb{R}$ [Cinlar 2010].

1.2.1 Conceitos de Probabilidade

Seja um conjunto observável S contido dentro do espaço de Borel F , com σ -álgebra, e considerando-se que se dois eventos são mutuamente exclusivos $A \wedge B | A \cdot B = \emptyset$ que representam um subconjunto de possíveis medições em F , então

$$\begin{aligned} P(A) &\geq 0 \\ P(S) &= 1 \\ \text{Se } A \cdot B &= \emptyset \quad \Rightarrow P(A + B) = P(A) + P(B) \\ \therefore P(\cdot) : F &\rightarrow \mathbb{R} \end{aligned} \quad (1.1)$$

Ainda, podemos ver que a probabilidade de um evento A ocorrer, dado que outro evento B já tenha ocorrido pode ser expressa como:

$$P(A|B) \equiv \frac{P(AB)}{P(B)}, P(B) > 0 \quad (1.2)$$

Neste caso

$$\begin{aligned} P(A|B) &\geq 0 \\ P(S|B) &= 1 \\ \text{Para } A \cdot C &= \emptyset \quad \Rightarrow P[(A + C)|B] = P(A|B) + P(C|B) \end{aligned} \quad (1.3)$$

Dois eventos A e B são ditos independentes e identicamente distribuídos se a probabilidade de cada evento se mantém a mesma se outro evento ocorrer ou não. Este conceito, nos diz respeito que todos os eventos ocorrem independentes um do outro. E a probabilidade dele ocorrer não se altera. Ou seja,

$$\begin{aligned} P(A \cdot B) &= P(A) \cdot P(B) \\ \text{Generalizando para três eventos } A, B \text{ e } C \end{aligned} \quad (1.4)$$

$$\left. \begin{aligned} P(AB) &= P(A) \cdot P(B) \\ P(AC) &= P(A) \cdot P(C) \\ P(BC) &= P(B) \cdot P(C) \end{aligned} \right\} P(ABC) = P(A)P(B)P(C) \quad (1.5)$$

1.3 Função Distribuição de Probabilidade

$$F(x) = P(X \leq x) = \sum_{x_i \leq x} f(x_i); \text{ onde } -\infty < x < \infty \quad (1.6)$$

A distribuição de probabilidade é um espaço amostral que pode ser finito ou contavelmente infinito. Se uma variável aleatória pode assumir um número contável de valores possíveis ela é dita discreta. De outra forma, existem variáveis aleatórias cujo conjunto de valores possíveis são incontáveis e neste caso elas são chamadas de contínuas [Ross 2010].

1.3.1 Propriedades da Função de Distribuição de Probabilidade

Uma função de distribuição de uma variável aleatória X obedece às seguintes propriedades [Magalhães 2011, DasGupta 2011]:

$$1. \lim_{x \rightarrow -\infty} F(x) = 0 \text{ e } \lim_{x \rightarrow \infty} F(x) = 1 \quad (1.7)$$

$$2. F \text{ é contínua à direita} \quad (1.8)$$

$$3. F \text{ não é decrescente, isto é, } F(x) \leq F(y), \text{ sempre que } x \leq y, \forall x, y \in \mathbb{R} \quad (1.9)$$

1.3.2 Função Densidade e Cumulativa de Probabilidade

Se X for contínuo, então $P(X = x) = 0$. Assim, se $F(X)$ for uma função absolutamente contínua, a função análoga contínua da função densidade de probabilidade discreta é a *função densidade de probabilidade* dada pela equação 1.10

$$f(x) = \frac{dF(x)}{dx} \quad (1.10)$$

Pela propriedade da continuidade absoluta é recíproco afirmar que a equação 1.11 representa *função cumulativa de probabilidade* ou *CDF - cumulative distribution function*, contínua de X , onde o conjunto de valores possíveis é incontável:

$$F(X) = \int_{-\infty}^x f(u)du \quad (1.11)$$

Nas condições da equação 1.11 a probabilidade $P(X \in (-\infty, \infty)) = 1$. Porém, se existirem 2 pontos de interesse $[a, b]$ o cálculo da *função cumulativa de probabilidade* pode ser dado como na equação 1.12

$$P(a \leq X \leq b) = \int_a^b f(x)dx \quad (1.12)$$

A equação 1.12 mostra que se $a = b$ o valor da probabilidade $P(X = a) = 0$. Assim, a probabilidade de uma variável aleatória contínua assumir um valor específico é zero [Ross 2010].

1.3.3 Valor Esperado e Momento de uma Variável Aleatória

Uma variável aleatória X que contém os valores de $x_1, x_2, x_3, \dots, x_n$ com probabilidade definida por $f(x_1), f(x_2), f(x_3), \dots, f(x_n)$, tem média (μ) ou *valor esperado* ou *esperança* de X , notado daqui por diante como $E[X]$, calculada como na equação 1.13 [DasGupta 2011]:

$$E[X] = \sum_{i=1}^n x_i f(x_n) \quad (1.13)$$

Uma variável aleatória que tem valores em $\mathbb{R}$ e distribuição μ , possui um valor esperado de n -ésima potência de X , nomeado $E[X^n]$. Esta n -ésima potência é chamada de n -ésimo momento de X [Cinlar 2010].

Se X é uma variável aleatória contínua com função densidade de probabilidade $f(x)$, então $f(x)dx \approx P(x \leq X \leq x + dx)$ para um dx pequeno. Assim, considerando a propriedade da continuidade absoluta aplicada à equação 1.11, é análogo afirmar que a *esperança* de uma variável aleatória contínua é dada pela equação 1.14, onde $f(x)$ é uma função não negativa definida em todo real $X \in (-\infty, \infty)$.

$$E[X] = \int_{-\infty}^{\infty} xf(x)dx; \quad (1.14)$$

1.3.4 Variança e Desvio Padrão de uma Variável Aleatória

Seja uma variável X com distribuição de probabilidade $f(x_i)$ e $r > 0$, um inteiro. Se existe a *esperança* da variável aleatória X^r então seu valor pode ser calculado como na equação 1.15

$$E[X^r] = \sum x_i^r f(x_i) \quad (1.15)$$

Assim, com a esperança do r -enésimo momento de X relacionado à origem e com seu segundo momento de $r + 1$ pode-se calcular a média μ como: $\mu = E[X]$. Então, a variável aleatória X pode ser redefinida pelo seu desvio da média como $X - \mu$.

Portanto, considerando a propriedade expressa na equação 1.9, e existindo a condição em que $(x - \mu)^2 \leq 2(x^2 - \mu^2)^2$, haverá um segundo momento de $X - \mu$ sempre que que $E[X^2]$ [DasGupta 2011]. Se X é uma variável aleatória com segundo momento $E[X^2]$ e como sua média é um valor dado por $\mu = E[X]$, a *variança* de X pode ser expressa pela equação 1.16

$$Var(X) = E[(X - \mu)^2] = E[X^2] - \mu^2 \quad (1.16)$$

Assim, pode-se simplificar a equação 1.16 substituindo o resultado da μ por seu valor esperado, temos a equação 1.17.

$$Var(X) = E[X^2] - (E[X])^2 \quad (1.17)$$

O conceito da variança estabelece o quanto os valores estão dispersos em torno da média. A raiz quadrada da $Var(X)$ é chamada de *desvio padrão* de X , representado na equação 1.18 [DasGupta 2011].

$$\sigma = \sqrt{Var(X)} \quad (1.18)$$

A variança tem as seguintes propriedades básicas:

1. $Var(cX) = c^2 Var(X)$ para qualquer $c \in \mathbb{R}$.
2. $Var(X + k) = Var(X)$ para qualquer $k \in \mathbb{R}$.
3. $Var(X) \geq 0$ para qualquer variável aleatória X .
4. $Var(X) = 0$ somente se $P(X = c) = 1$, para alguma constante $c \in \mathbb{R}$.
5. $Var(X) = E[X^2] - \mu^2$



1.3.5 Covariança de uma Variável Aleatória e Variável Aleatória Independente

Se duas variáveis aleatórias X e Y estão em um mesmo espaço amostral. Então $X + Y$ e XY são também variáveis aleatórias deste espaço amostral e suas distribuições podem ser obtidas mediante os arranjos das distribuições conjuntas de X e Y . Para determinar o quanto estas variáveis dependem do resultado de uma em relação a outra, deve-se calcular a *covariança* de X e Y da pela equação 1.19.

$$Cov(X, Y) = E[(X - \mu_x)(Y - \mu_y)] \quad (1.19)$$

O valor da média já foi definido anteriormente como sendo $E[X]$. Assim, conclui-se que $\mu_x = E[X]$ e $\mu_y = E[Y]$, e, portanto, a equação 1.19 pode ser reescrita como em 1.20

$$Cov(X, Y) = E[X \cdot Y] - (E[X] \cdot E[Y]) \quad (1.20)$$

A equação 1.20 é importante porque se as variáveis aleatórias X e Y forem independentes então $Cov(X, Y) = 0$. Assim, pode-se assumir que $E[X]$ e $E[Y]$ não são dependentes uma da outra se for verdadeira a equação 1.21 [Ross 2010].

$$P(XY) = P(X) \cdot P(Y) \quad (1.21)$$

1.3.6 Correlação de uma Variável Aleatória

Se houver dependência entre as variáveis aleatórias X e Y é possível calcular-se o nível de associação entre elas. Este nível de associação é conhecido como *correlação*. O cálculo é obtido através da relação entre a *covariança* das variáveis com a medida de seus desvios padrões σ_x e σ_y , como na equação 1.22.

$$Cor(X, Y) = \frac{Cov(X, Y)}{\sigma_x \cdot \sigma_y} \quad (1.22)$$

1.4 Distribuição de Probabilidade Conjunta de Funções

Sejam X_1 e X_2 variáveis aleatórias contínuas independentes com função densidade de probabilidade conjunta f_{X_1, X_2} num mesmo espaço de probabilidade. As variáveis aleatórias Y_1 e Y_2 , que surgem das funções X_1 e X_2 , dadas por $Y_1 = g_1(X_1, X_2)$ e por $Y_2 = g_2(X_1, X_2)$, podem ter função densidade de probabilidade conjunta, desde que g_1 e g_2 satisfaçam as seguintes condições [Ross 2010, Magalhães 2011]:

1. As equações $y_1 = g_1(x_1, x_2)$ e $y_2 = g_2(x_1, x_2)$ são solucionáveis para x_1 e x_2 em termos de y_1 e y_2 dadas por $x_1 = h_1(y_1, y_2)$ e $x_2 = h_2(y_1, y_2)$.
2. As funções g_1 e g_2 têm derivadas parciais contínuas em todos os pontos (x_1, x_2) e são tais que o determinante formado a partir destas seja

$$J(x_1, x_2) = \begin{vmatrix} \frac{\partial g_1}{\partial x_1} & \frac{\partial g_1}{\partial x_2} \\ \frac{\partial g_2}{\partial x_1} & \frac{\partial g_2}{\partial x_2} \end{vmatrix} \equiv \frac{\partial g_1}{\partial x_1} \cdot \frac{\partial g_2}{\partial x_2} - \frac{\partial g_1}{\partial x_2} \cdot \frac{\partial g_2}{\partial x_1} \neq 0$$

em todos os pontos (x_1, x_2) .

Sendo J_x o *Jacobiano* formado pelas derivadas parciais dadas em função de cada uma das variáveis independentes x_n de um conjunto de funções $f_1(x_1, x_2, x_3, \dots, x_n)$, $f_2(x_1, x_2, x_3, \dots, x_n)$, $\dots$, $f_n(x_1, x_2, x_3, \dots, x_n)$, representado pela matriz da equação 1.23.

$$J_x = \begin{vmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \dots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \dots & \frac{\partial f_2}{\partial x_n} \\ \dots & \dots & \dots & \dots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \dots & \frac{\partial f_n}{\partial x_n} \end{vmatrix} \neq 0 \quad (1.23)$$

A **função densidade de probabilidade conjunta** para as variáveis aleatórias Y_1 e Y_2 é dada pela equação 1.24:

$$P\{Y_1 \leq y_1, \dots, Y_n \leq y_n\} = f_{Y_1, \dots, Y_n}(y_1, \dots, y_n) = f_{X_1, \dots, X_n}(x_1, \dots, x_n) |J(x_1, \dots, x_n)|^{-1} \quad (1.24)$$

onde $x_i = h_i(y_1, \dots, y_n)$, $i = 1, 2, \dots, n$.

Assim, considerando a *função densidade de probabilidade cumulativa conjunta* do par de variáveis aleatórias X e Y definida como em 1.25 [Ross 2010]:

$$F(x, y) = P\{X \leq x, Y \leq y\}; \text{ onde } -\infty < x, y < \infty \quad (1.25)$$

Todas as probabilidades relacionadas a esse par de variáveis aleatórias podem ser obtidas de F , através do limite das funções individuais F_X e F_Y

$$F_X(x) = \lim_{y \rightarrow \infty} F(x, y) \quad F_Y(y) = \lim_{x \rightarrow \infty} F(x, y) \quad (1.26)$$

Se as variáveis aleatórias X e Y são conjuntamente contínuas, então existe uma função $f(x, y)$, chamada *função de probabilidade conjunta*, tal que, para qualquer conjunto bidimensional C , é verifica a equação 1.27

$$P\{(X, Y) \in C\} = \iint_C f(x, y) dx dy \quad (1.27)$$

Da equação 1.25 tem-se que $P\{X \leq x + dx, Y \leq y + dy\} \approx f(x, y) dx dy$. Portanto, se X e Y são variáveis conjuntamente contínuas, então elas são individualmente contínuas com função densidade, dada pelas equações em 1.28

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy \quad f_Y(y) = \int_{-\infty}^{\infty} f(x, y) dx \quad (1.28)$$

Assim, se a função de distribuição conjunta puder ser fatorada em uma parte dependente somente de x em outra dependente somente de y , então X e Y são independentes e

$$P\{X \in A, Y \in B\} = P\{X \in A\}P\{Y \in B\} \text{ para todos os conjuntos } A \text{ e } B \quad (1.29)$$

1.5 Convergência de Variáveis Aleatórias

Seja X uma variável aleatória com esperança finita e g uma função convexa, onde na equação 1.30, se verifica a *Desigualdade de Jensen* [Magalhães 2011]:

$$E[g(X)] \leq g(E[X]) \quad (1.30)$$

Existe uma reta que passa no ponto $(x_0, g(x_0))$, conforme é representado na Figura 1.3, adaptado de [Magalhães 2011]. Para o ponto $(x_0, g(x_0)) = (E[X], g(E[X]))$, há uma função $h(x) = ax + b$ que define esta reta. Se $h = g$ no ponto $(E[X], g(E[X]))$ e nos demais pontos $h(x) \leq g(x)$, considerando a *Desigualdade de Jensen* da equação 1.30. Assim, $g(E[X]) = aE[X] + b = E[aX + b]$ onde $E[h(X)] \leq E[g(X)]$. Assim o valor esperado pode ser utilizado para avaliar a amplitude de valores de uma variável.




Figura 1.3: Função Convexa

1.5.1 Desigualdade de Markov

Seja uma variável aleatória X com apenas valores não negativos e $a > 0$. Então a probabilidade de $P(X \geq a)$ pode ser dada pela equação 1.31

$$P(X \geq a) \leq \frac{E[X]}{a} \quad (1.31)$$

Assim, a esperança $E[X]$ existe, porque X não é negativa. Considerando um evento $A = \{X \geq a\}$ e uma variável discreta $Y = aI_A$, tal que para todo w dentro do espaço amostral:

$$Y(w) = \begin{cases} a & \text{se } X(w) \geq a \\ 0 & \text{se } 0 \leq X(w) < a \end{cases} \quad (1.32)$$

Demonstração: Como pela equação 1.32 tem-se $X(w) \geq Y(w)$ então pode-se afirmar que:

$$E[X] \geq E[Y] = aP(A) = aP(X \geq a)$$

e, portanto, demonstra-se a equação 1.31 [Magalhães 2011].



1.5.2 Desigualdade de Chebyshev

Seja X uma variável aleatória com média finita μ e variância σ^2 , então, para qualquer $k > 0$, a probabilidade pode ser dada pela equação 1.33 [Ross 2010]:

$$P\{|X - \mu| \geq k\} \leq \frac{\sigma^2}{k^2} \quad (1.33)$$

Demonstração: Como $(X - \mu)^2$ é uma variável aleatória positiva, aplicando-se a desigualdade de Markov de 1.31 com $a = k^2$ tem-se a equação 1.34.

$$P\{(X - \mu)^2 \geq k^2\} \leq \frac{E[(X - \mu)^2]}{k^2} \quad (1.34)$$

Portanto, como $(X - \mu)^2 \geq \sigma^2$ se o $|X - \mu| \geq k$, a esperança $E[(X - \mu)^2] \approx \sigma^2$, o que demonstra a equação 1.33 [Ross 2010].

A importância das desigualdades de Markov, equação 1.31, e Chebyshev, equação 1.33, está em permitir definir os limites para as probabilidades quando se conhece somente a média ou somente a média e a variância, das distribuições de probabilidade [Ross 2010]. Como não são feitas restrições sobre a variável aleatória X , se μ e σ são finitos a inequação de Chebyshev é aplicável e se μ é finita a inequação de Markov é aplicável. Entretanto, a natureza universal destas inequações também as faz tipicamente conservativas [DasGupta 2011].

Capítulo 2

Tipos de Função de Distribuição

Diversas funções de distribuições são conhecidas e utilizadas para a análise de sistemas. O conhecimento da função de distribuição permite obter qualquer informação sobre uma variável aleatória. Mesmo que a variável só assuma valores em um subconjunto dos reais [Magalhães 2011]. As funções de distribuição são comumente divididas entre discretas e contínuas. Neste capítulo serão avaliados os modelos das distribuições contínuas e seus relacionamentos entre si. Alguns destes modelos de distribuição foram utilizados na descoberta de modelos probabilísticos para avaliação de disponibilidade em sistemas largamente distribuídos, apresentados no capítulos anteriores.

2.1 Distribuição de Pareto

Uma variável aleatória X é dita ter uma função densidade de probabilidade de Pareto com parâmetro θ e α , se ela tem densidade definida como na equação 2.1 [DasGupta 2010].

$$f(x) = \frac{\alpha\theta^\alpha}{x^{\alpha+1}} \text{ onde } x \geq \theta > 0, \alpha > 0 \quad (2.1)$$

A função densidade de probabilidade da distribuição de Pareto, representada na Figura 2.1, é decrescente monoliticamente. Esta função pode ou não ter uma esperança finita, dependendo do valor de α [DasGupta 2010] e sua função cumulativa de distribuição é dada pela equação 2.2 .

$$F(x) = \begin{cases} 1 - (\frac{\theta}{x})^\alpha & x \geq \theta \\ 0 & x < \theta \end{cases} \quad (2.2)$$




Figura 2.1: Função Densidade de Probabilidade de Pareto

O n -ésimo momento existe se e somente se $n < \theta$ e então o valor esperado pode ser dado pela equação 2.3.

$$E[X^n] = \frac{\alpha \theta^n}{\alpha - n} \quad (2.3)$$

A esperança $E[X^n]$ converge se e somente se $\alpha - n > 0 \Leftrightarrow n < \alpha$ e é dada pela equação 2.4. Para $n = 1$, se $\alpha > 1$ existe a média e se $\alpha > 2$ existe a variância, e seus cálculos são dados pela equação 2.5 [DasGupta 2010].

$$E[X^n] = \int_{\theta}^{\infty} x^n \frac{\alpha \theta^{\alpha}}{x^{\alpha+1}} dx = \alpha \theta^{\alpha} \int_{\theta}^{\infty} \frac{1}{x^{\alpha-n+1}} dx \quad (2.4)$$

$$\text{Se } \begin{cases} \alpha > 1, & \text{existe} \\ \alpha > 2, & \text{existe} \end{cases} \quad \begin{cases} E[X] = 1 - \left(\frac{\theta}{x}\right)^{\alpha} \\ \text{Var}(X) = \frac{\alpha \theta^2}{(\alpha-1)^2(\alpha-2)} \end{cases} \quad (2.5)$$

2.2 Distribuição Exponencial

Uma variável aleatória contínua cuja função densidade de probabilidade é dada por algum $\lambda > 0$, sua função é expressa na equação 2.6 e representada pela Figura 2.2.a .

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & \text{se } x \geq 0 \\ 0 & \text{se } x < 0 \end{cases} \quad (2.6)$$

É chamada de variável exponencialmente distribuída com parâmetro λ . A função distribuição cumulativa $F(a)$ é dada pela equação 2.7, com notação $X \sim \text{Exp}(\lambda)$, e representada na Figura 2.2.b. A distribuição exponencial é utilizada como a distribuição da quantidade de tempo até que ocorra algum evento específico [Ross 2010].

$$F(a) = P\{X \geq a\} = \int_0^a \lambda e^{-\lambda x} dx = 1 - e^{-\lambda a} \text{ para } a \geq 0 \quad (2.7)$$

O valor da esperança $E[X]$, para $n > 0$ é dado pela integração por partes da equação 2.8 com $\lambda e^{-\lambda x} = dv$ e $u = x^n$

$$E[X^n] = \int_0^{\infty} \lambda x^n e^{-\lambda x} dx \quad (2.8)$$




Figura 2.2: Função Densidade e Função Cumulativa da Exponencial

$$E[X^n] = \underbrace{-x^n \lambda e^{-\lambda x}}_0 \Big|_0^\infty + \int_0^\infty n x^{n-1} e^{-\lambda x} dx$$

$$E[X^n] = 0 + \frac{n}{\lambda} \underbrace{\int_0^\infty \lambda x^{n-1} e^{-\lambda x} dx}_{E[X^{n-1}]}$$

$$E[X^n] = \frac{n}{\lambda} \cdot E[X^{n-1}]$$

Fazendo-se $n = 1$ e após $n = 2$ tem-se: $E[X] = \frac{1}{\lambda}$ e $E[X^2] = \frac{2}{\lambda} \cdot E[X] = \frac{2}{\lambda^2}$

Assim a variância pode ser determinada como: $\text{Var} = E[X^2] - (E[X])^2 = \frac{1}{\lambda^2}$

2.2.1 Propriedade da Falta de Memória

Seja $X \sim \text{Exp}(\lambda)$ com s e t números positivos. A propriedade da memória de uma distribuição exponencial é dada por $P(X > s + t | X > s) = P(X > t)$. Demonstrada pela resolução da equação em 2.9 em [DasGupta 2011].

$$P(X > s + t | X > s) = \frac{P(X > s + t)}{P(X > s)} = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} \quad (2.9)$$

$$P(X > s + t | X > s) = e^{-\lambda t} = P(X > t)$$

Assim, se X é o tempo de durabilidade em anos de um equipamento que segue uma distribuição exponencial. A probabilidade do equipamento durar mais t anos, sabendo que já tenha durado s anos é a mesma de um equipamento novo durar pelo menos t anos.

2.3 Distribuição Normal

Diz-se que uma variável aleatória X é normalmente distribuída, com parâmetros μ e σ^2 , se a função densidade de X é dada por 2.10

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-(x-\mu)^2/2\sigma^2} \text{ onde } -\infty < x < \infty \quad (2.10)$$

A distribuição normal, representada pela Figura 2.3, foi introduzida pelo matemático francês Abraham DeMoivre em 1733, para obter aproximações probabilísticas associadas a variáveis aleatórias binomiais com parâmetro n grande. Mais tarde o resultado foi estendido por Laplace e está incorporado no teorema do limite central [Ross 2010]. A esperança $E[X] = \mu$ e a variância $\text{Var}(X) = \sigma^2$.




Figura 2.3: Função Densidade de Probabilidade Normal

O teorema do limite central fornece a base teórica para a observação empírica de que os fenômenos aleatórios obedecem pelo menos aproximadamente, a uma distribuição normal. A altura de um homem, a velocidade de uma molécula de gás em qualquer direção e o erro cometido na medição de uma grandeza física são exemplos de comportamentos aleatórios que seguem a distribuição normal [Ross 2010].

2.4 Distribuição Log-normal

A distribuição log-normal é um modelo comum de estudos de variáveis econômicas, como renda e riqueza, porque ela pode descrever a assimetria que se vê nos dados que representam. Se existe uma variável aleatória X em que há distribuição normal $N(\mu, \sigma^2)$, então $Y = e^X$ é chamada uma *distribuição log-normal* com parâmetros μ, σ .

Desde que $Y = e^X$ é estritamente uma função monotônica de X , a função densidade de probabilidade da log-normal com parâmetros μ, σ^2 pode ser dada pela equação 2.11. Desde que uma variável log-normal seja definida como e^X para uma variável normal X . Assim a esperança $E(Y)$ e a variância $\text{Var}(Y)$ são calculadas por 2.12.

$$f_Y(y) = \frac{1}{y\sigma\sqrt{2\pi}} e^{-\frac{(\log y - \mu)^2}{2\sigma^2}}, y > 0 \quad (2.11)$$

$$E(Y) = e^{(\mu + \frac{\sigma^2}{2})} \text{ e } \text{Var}(Y) = (e^{\sigma^2} - 1)e^{2\mu + \sigma^2} \quad (2.12)$$

A densidade da log-normal é extremamente assimétrica para valores grande de σ e o coeficiente de assimetria pode ser dados pela equação 2.13. Quando $\sigma \rightarrow \infty$, a densidade de log-normal para $\mu = 0$ e $\sigma = 1$ é apresentada como a Figura 2.4.

$$\beta = (2 + e^{\sigma^2})\sqrt{e^{\sigma^2}-1} \quad (2.13)$$




Figura 2.4: Função Densidade da Log-normal

2.5 Distribuição Gama

Uma variável aleatória tem distribuição gama com parâmetros (α, λ) , $\lambda > 0$, $\alpha > 0$ e sua função densidade de probabilidade é dada por 2.14 [Magalhães 2011].

$$f(x) = \begin{cases} \frac{\lambda e^{-\lambda x} (\lambda x)^{\alpha-1}}{\Gamma(\alpha)} & \text{se } x \geq 0 \\ 0 & \text{se } x < 0 \end{cases} \quad (2.14)$$

onde $\Gamma(\alpha)$ é conhecida como *função Gama* definida como

$$\Gamma(\alpha) = \int_0^{\infty} e^{-y} y^{\alpha-1} dy \quad (2.15)$$

Integrando-se por partes temos $\Gamma(\alpha)$ como

$$\begin{aligned} \Gamma(\alpha) &= e^{-y} y^{\alpha-1} \Big|_0^{\infty} + \int_0^{\infty} e^{-y} (\alpha - 1) y^{\alpha-2} dy \\ \Gamma(\alpha) &= (\alpha - 1) \underbrace{\int_0^{\infty} e^{-y} y^{\alpha-2} dy}_{\Gamma(\alpha-1)} \\ \Gamma(\alpha) &= (\alpha - 1) \Gamma(\alpha - 1) \end{aligned} \quad (2.16)$$

Considerando $\alpha = n$, n inteiro e positivo, tem-se uma série dada por

$$\Gamma(n) = (n - 1) \underbrace{\Gamma(n - 1)}_{(n-2)\Gamma(n-2)}$$



$$\Gamma(n) = (n-1)(n-2) \underbrace{\Gamma(n-2)}_{(n-3)\Gamma(n-3)}$$

$$\Gamma(n) = (n-1)(n-2)(n-3) \dots 2\Gamma(1)$$

Como $\Gamma(1) = \int_0^\infty e^{-x} dx = 1$ então

$$\Gamma(n) = (n-1)!$$

Quando α é um inteiro positivo, a distribuição Gama com parâmetros (α, λ) é uma função que determina a quantidade de tempo que se deve esperar até que um total de n eventos ocorra, desde que sejam verdadeiros os três axiomas de Poisson [Ross 2010]:

1. A probabilidade de que exatamente 1 evento ocorra em um dado intervalo com extensão h é igual a $\lambda h + o(h)$, onde $o(h)$ representa qualquer função $f(h)$ no qual o $\lim_{h \rightarrow 0} \frac{f(h)}{h} = 0$
2. A probabilidade de que 2 ou mais eventos ocorram em um intervalo com extensão h é igual a $o(h)$
3. Para qualquer inteiro $j_1, j_2, j_3, \dots, j_n$ em quaisquer conjuntos de intervalos que não se sobrepõem, os eventos E_i são independentes.

Sua esperança $E[X]$ e a variância $Var(X)$ são dados por:

$$E[X] = \frac{\alpha}{\lambda} \quad e \quad Var(X) = \frac{\alpha}{\lambda^2}$$

Assim, o tempo esperado T_n para que todos os n eventos aconteçam até o instante t , com $N(t)$ eventos igual número de eventos entre $[0, t]$ é dado por

$$\begin{aligned} P\{T_n \leq t\} &= P\{N(t) \geq n\} \\ P\{T_n \leq t\} &= \sum_{j=n}^{\infty} P\{N(t) = j\} \\ P\{T_n \leq t\} &= \sum_{j=n}^{\infty} \frac{e^{-\lambda t} (\lambda t)^j}{j!} \end{aligned} \tag{2.17}$$

A equação 2.17 é uma identidade final, porque o número de eventos em $[0, t]$ segue uma distribuição Poisson com parâmetro λt . Assim, derivando-se 2.17 obtêm-se a função identidade de T_n .

$$\begin{aligned} f(t) &= \sum_{j=n}^{\infty} \frac{e^{-\lambda t} j (\lambda t)^{j-1} \lambda}{j!} - \sum_{j=n}^{\infty} \frac{\lambda e^{-\lambda t} (\lambda t)^j}{j!} \\ f(t) &= \sum_{j=n}^{\infty} \frac{\lambda e^{-\lambda t} (\lambda t)^{j-1}}{(j-1)!} - \sum_{j=n}^{\infty} \frac{\lambda e^{-\lambda t} (\lambda t)^j}{j!} \\ f(t) &= \frac{\lambda e^{-\lambda t} j (\lambda t)^{n-1}}{(n-1)!} \end{aligned} \tag{2.18}$$

A distribuição gama com parâmetros (n, λ) na equação 2.18 é também conhecida como *distribuição Erlang*.

Assim, a *função densidade de probabilidade Gama* dependendo dos parâmetros de (α, λ) pode assumir a funcionalidade de outras distribuições conforme a Tabela 2.1 adaptada de [Magalhães 2011] e tem representação conforme a Figura 2.5.

Tabela 2.1: Distribuição Gama versus outras distribuições

Parâmetros	Nome	Notação
$\alpha = 1, \lambda > 0$	Exponencial	$\exp(\lambda)$
$\alpha = \frac{n}{2}, \lambda = \frac{1}{2}, n$ inteiro	Qui-quadrado com n graus de liberdade	$\chi^2(n)$
$\alpha = k, \lambda > 0, k > 0$ inteiro	Erlang de ordem k	$Erl_k(\lambda)$




Figura 2.5: Função Densidade de Probabilidade Gama

2.6 Distribuição Beta

Diz-se que uma variável aleatória tem *distribuição beta* se sua densidade for dada pela equação 2.19

$$f(x) = \begin{cases} \frac{1}{B(a,b)} x^{a-1} (1-x)^{b-1} & \text{se } 0 < x < 1 \\ 0 & \text{no caso contrário} \end{cases} \quad (2.19)$$

Onde $B(a, b)$ pode ser dado por

$$B(a, b) = \int_0^1 x^{a-1} (1-x)^{b-1} dx \quad (2.20)$$

A *distribuição beta* é usada para modelar fenômenos aleatórios em que os seus valores possíveis estão em um conjunto $[c, d]$, onde c é a origem e $d - c$ uma unidade de medida. Portanto, existe uma relação entre a integral 2.20 e a função gama 2.16, chamada de *fator de normalização da densidade de beta* como mostra a equação 2.21. A função densidade de probabilidade tem o formato representado pela Figura 2.6 adaptada de [Magalhães 2011].




Figura 2.6: Função Densidade de Probabilidade Beta

$$B(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)} \quad (2.21)$$

Assim, se X é uma variável aleatória beta com parâmetros a e b , tem-se

$$E[X] = \frac{a}{a+b} \quad e \quad Var(X) = \frac{ab}{(a+b)^2 + (a+b+1)}$$

Supondo-se duas variáveis aleatórias gama independentes X e Y . X com parâmetro (α, λ) e Y com parâmetro (β, λ) . O cálculo da função densidade conjunta de $U = X + Y$ e $V = \frac{X}{X+Y}$ pode ser dada tomando-se a função densidade de probabilidade da equação 2.14:

$$f_{X,Y}(x, y) = \underbrace{\frac{\lambda e^{-\lambda x} (\lambda x)^{\alpha-1}}{\Gamma(\alpha)}}_{f_X} \underbrace{\frac{\lambda e^{-\lambda y} (\lambda y)^{\beta-1}}{\Gamma(\beta)}}_{f_Y} \quad (2.22)$$

$$f_{X,Y}(x, y) = \frac{\lambda^{\alpha+\beta}}{\Gamma(\alpha)\Gamma(\beta)} e^{-\lambda(x+y)} x^{\alpha-1} y^{\beta-1} \quad (2.23)$$

Considerando-se $g_1(x, y) = x + y$ e $g_2 = \frac{x}{x+y}$ e tomando-se o Jacobiano da equação 1.23 para a solução de g_1 e g_2 tem-se que:

$$\frac{\partial g_1}{\partial x} = \frac{\partial g_1}{\partial y} = 1 \quad \frac{\partial g_2}{\partial x} = \frac{y}{(x+y)^2} \quad \frac{\partial g_2}{\partial y} = -\frac{x}{(x+y)^2}$$

Assim o $J(x, y)$ é:

$$J(x, y) = \begin{vmatrix} \frac{\partial g_1}{\partial x_1} & \frac{\partial g_1}{\partial x_2} \\ \frac{\partial g_2}{\partial x_1} & \frac{\partial g_2}{\partial x_2} \end{vmatrix} = \begin{vmatrix} 1 & 1 \\ \frac{y}{(x+y)^2} & -\frac{x}{(x+y)^2} \end{vmatrix} = -\frac{1}{x+y}$$

$$\text{Como } \begin{cases} u = x + y \\ v = \frac{x}{x+y} \end{cases} \quad \text{Então } x \text{ e } y \text{ são: } \begin{cases} x = uv \\ y = u(1-v) \end{cases}$$

e substituindo-se em 2.23:

$$f_{U,V}(u, v) = f_{X,Y}[uv, u(1-v)]u = \underbrace{\frac{\lambda e^{-\lambda u} (\lambda u)^{\alpha+\beta-1}}{\Gamma(\alpha+\beta)}}_{Dist.Gama} \underbrace{\frac{v^{\alpha-1} (1-v)^{\beta-1} \Gamma(\alpha+\beta)}{\Gamma(\alpha)\Gamma(\beta)}}_{Dist.Beta} \quad (2.24)$$

Assim, U e V são independentes entre si, com U tendo distribuição gama com parâmetros $(\alpha + \beta, \lambda)$ e V tendo distribuição beta com parâmetros (α, β) .

2.7 Distribuição Weibull

A distribuição de Weibull é amplamente utilizada na prática para avaliar a vida útil de algum objeto, interpretando os dados da degradação física como uma função do tempo. Em outras aplicações a degradação física não pode ser observada diretamente, entretanto representa uma medida do produto da degradação de desempenho, também referenciada como degradação de dados [Rinne 2009]. É possível mostrar (tanto teórica quanto empiricamente) que a distribuição Weibull fornece uma boa aproximação para a distribuição da vida útil do objeto [Ross 2010]. A função distribuição cumulativa de Weibull tem a forma representada por 2.25:

$$F(x) = \begin{cases} 0 & \text{se } x \leq v \\ 1 - \exp\left\{-\left(\frac{x-v}{\alpha}\right)^\beta\right\} & \text{se } x > v \end{cases} \quad (2.25)$$

Derivando-se 2.25 tem-se a *função densidade de probabilidade de Weibull* com parâmetros v, α e β representada por 2.26. O significado de cada parâmetro é apresentado na Tabela 2.2 , adaptada de [Rinne 2009].

$$f(x) = \begin{cases} 0 & \text{se } x \leq v \\ \frac{\beta}{\alpha} \left(\frac{x-v}{\alpha}\right)^{\beta-1} \exp\left\{-\left(\frac{x-v}{\alpha}\right)^\beta\right\} & \text{se } x > v \end{cases} \quad (2.26)$$

Tabela 2.2: Interpretação dos Parâmetros de Weibull

Parâmetro	Variação	Significado
v	$-\infty < v < \infty$	medida de tempo (<i>threshold</i>), <i>delay</i> . Parâmetro de deslocamento da função.
β	$0 < \beta < \infty$	Weibull-slope, parâmetro de forma, aparência. Com $\beta < 1$ a parte exponencial é mais acentuada e com $\beta > 1$ a parte polinomial é mais pronunciada.
α	$0 < \alpha < \infty$	parâmetro de escala, chamado de característica de vida.

A Tabela 2.3, inspirada em [Dodson 2006], apresenta as variações do parâmetro β para uma aproximação de formato entre as demais distribuições, conforme pode ser verificado na Figura 2.7, onde foram plotadas as variações conforme consta nesta tabela.



Tabela 2.3: Distribuição Weibull versus outras distribuições

Parâmetro	Aproximação da Distribuição de <i>Weibull</i>
$\beta = 1$	Equivale à distribuição exponencial.
$1 < \beta < 3,6$	Aproxima à distribuição log-normal.
$3 < \beta < 4$	Aproxima à distribuição normal. Com $\beta = 3,6$ tem-se a melhor aproximação.
$\beta = 5$	Aproxima o pico da distribuição normal.




Figura 2.7: Função Densidade de Probabilidade Weibull

2.8 Distribuição Uniforme

Uma variável aleatória com distribuição uniforme é contínua para uma população finita. Um exemplo típico é a escolha de uma fração aleatória. Pequenas medidas de erros muitas vezes são aproximadamente uniformemente distribuídas. Em estatística Bayesiana uma distribuição uniforme muitas vezes reflete a falta de conhecimento sobre um parâmetro desconhecido. Sendo uma variável aleatória X com função densidade de probabilidade dada pela equação 2.27, onde $-\infty < a < b < \infty \in \mathbb{R}$ [DasGupta 2010].

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{se } a \leq x \leq b \\ 0 & \text{se fora deste intervalo} \end{cases} \quad (2.27)$$

A Figura 2.8 representa a função densidade de probabilidade para o intervalo $[a, b]$. A função densidade cumulativa de probabilidade $F(x)$ é dada pela equação 2.28.




Figura 2.8: Função Densidade de Probabilidade Normal

$$F(x) = \begin{cases} 0 & \text{se } x < a \\ \frac{x-a}{b-a} & \text{se } a \leq x \leq b \\ 1 & \text{se } x > b \end{cases} \quad (2.28)$$

A esperança do “*n*-ésimo” momento da distribuição uniforme (a, b) é dado pela equação 2.29 e a média $E[X]$ e a variância $Var(X)$ são apresentados em 2.30

$$E[X^n] = \frac{b^{n+1} - a^{n+1}}{(b-a)(n+1)} \quad (2.29)$$

$$E[X] = \frac{a+b}{2} \quad e \quad Var[X] = \frac{(b-a)^2}{12} \quad (2.30)$$

2.9 Relação entre Distribuições Contínuas

Na Figura 2.9, adaptada de [Jain 1991], tem-se as relações entre as funções contínuas estudadas neste trabalho. O símbolo x é usado para denotar variações da distribuição onde a seta inicia. A variação dos parâmetros da distribuição de origem, onde a seta origina-se, aproxima a forma da distribuição de destino.




Figura 2.9: Relação entre Distribuições Contínuas

Capítulo 3

Predição e Inferência

3.1 Método de Bayes

A *probabilidade incondicional* ou *a priori* está associada a uma proposição a uma variável X com um grau de crença acordado para a proposição na ausência de quaisquer outras informações. O conjunto de informações de uma *probabilidade a priori* definem uma *distribuição de probabilidade a priori* para uma variável aleatória. Seja duas ou mais variáveis aleatórias $X_1, X_2, \dots, X_n$ diz-se que a probabilidade pode ser escrita de forma conjunta para explicar um evento qualquer com a seguinte notação $P(X_1, X_2, \dots, X_n)$ também chamada de *probabilidade conjunta total*.

Uma vez que se obtenha alguma evidência relativa às variáveis aleatórias anteriormente desconhecidas que constituem o domínio, as probabilidades *a priori* não são mais aplicáveis. Ao invés, utiliza-se as *probabilidades condicionais* ou *a posteriori*. Assim, sejam duas variáveis aleatórias X, Y denota-se a *probabilidade a posteriori* como $P(X|Y)$ e lê-se a probabilidade de ocorrer X dada o conhecimento da probabilidade de Y ocorrer e seu cálculo se dá como em 3.1, desde que $P(Y) > 0$ [Russel and Norving 2004].

$$P(X|Y) = \frac{P(X, Y)}{P(Y)} \quad (3.1)$$

A equação 3.1 pode também ser se reescrita como em 3.2.

$$P(X, Y) = P(X|Y)P(Y) \quad (3.2)$$

A equação 3.2 é também conhecida como *regra do produto* e pode ser entendida que para X e Y serem verdadeiros é necessário que X seja verdadeiro e também que Y seja verdadeiro. Assim, pode-se reescrever 3.2 em sentido contrário como em 3.3

$$P(X, Y) = P(Y|X)P(X) \quad (3.3)$$

Igualando-se os termos de 3.2 e 3.3 tem-se a equação 3.4 também conhecida como **Teorema de Bayes**. O cálculo das probabilidades condicionais através do *Teorema de Bayes* não depende das probabilidades conjuntas [Russel and Norving 2004].

$$P(Y|X) = \frac{P(X|Y)P(Y)}{P(X)} \quad (3.4)$$

A regra da soma das probabilidades define que $P(X) = \sum_Y P(X, Y)$, assim, considerando a equação 3.3 o teorema pode ser expresso em termos das quantidades como na equação 3.5 e reescrever-se a 3.3 como em 3.6 [Bishop 2009].

$$P(X) = \sum_Y P(X|Y)P(Y) \quad (3.5)$$

$$P(Y|X) = \frac{P(X|Y)P(Y)}{\sum_Y P(X|Y)P(Y)} \quad (3.6)$$

Então sempre que avaliar-se a incerteza de uma variável Y após ter-se observado X na forma da probabilidade a posteriori $P(Y|X)$.

3.2 Processos Estocásticos

Uma definição genérica de um processo estocástico (*stochastic process*) é qualquer família de variáveis aleatórias. Mais precisamente pode-se definir como:

Dado $[\Omega, A, P]$ ser um espaço de probabilidade e $\mathbb{T} \in \mathbb{R}$ determinado ao acaso, mas um conjunto não aleatório. Uma função X que representa $\Omega \times \mathbb{T}$ em $\mathbb{R}$, ou seja, uma função $X : \Omega \times \mathbb{T} \rightarrow \mathbb{R}$, isto é chamado de valor real de um processo estocástico. O conjunto de uma instância de X , $\{X(t, w) | w \in \Omega, t \in \mathbb{T}\}$ é limitado a um **espaço de estado**, ao mesmo tempo que $\mathbb{T}$ é chamado de **espaço de parâmetros** [Rinne 2009].

Duas classificações relativamente simples aderem a estes dois espaços. Onde:

- Um **processo pontual** para um espaço de estado contável e
- Um **processo difuso** (processo real valorado) para um espaço de estado iniciando em $\mathbb{R}$ ou qualquer subconjunto compacto de $\mathbb{R}$.

Com respeito ao espaço de parâmetros $\mathbb{T}$, tem-se:

- Um **processo de parâmetros discreto**, também chamado de *Séries Estocásticas* ou *Cadeia Estocástica* para $\mathbb{T}$ sendo capaz de ser contável e
- Um **processo de parâmetros contínuos** ou *processo contínuo* para limitar quando $\mathbb{T}$ é não contável.

Tem-se então:

- Um número fixo $X(t^*, w^*)$ para um t^* e w^* fixos;
- Uma variável aleatória $X(t^*, w)$ para um t^* com uma função de distribuição geralmente dependente de t^* ;
- Uma trajetória $X(t, w^*)$ do processo para um w^* fixo em uma seção longitudinal;
- O processo completo para t e w ambos variando.

Um processo estocástico é assim interpretado por duas maneiras, ou como uma coleção, com um conjunto de funções $(X_t)_{t \in \mathbb{T}}$, a partir do qual é escolhido aleatoriamente pela trajetória de um w^* especial, ou como no caso de $\mathbb{T}$ ser contável, uma série de variáveis aleatórias $X_1, X_2, \dots, X_t, \dots$. Na maioria das aplicações t representa o tempo, mas também pode ser qualquer outra variável contável [Rinne 2009].

As características de um processo estocástico $\{X_t\}$ são as relações entre as variáveis aleatórias $X_t, t \in \mathbb{T}$. Estes relacionamentos são especificados dando o conjunto de uma função de distribuição de toda a família finita de $X_{t_1}, \dots, X_{t_n}$ das variáveis do processo. A distribuição conjunta pode muitas vezes ser especificada em termos de outras distribuições associadas com o processo. Um processo estocástico pode ser considerado como bem definido uma vez que seu estado de espaço, parâmetros de índice e família de distribuições conjuntas são percebidas.

3.2.1 Processos de Markov

Um processo de Markov é um processo com a propriedade que, dadoum valor de X_t , o valor de $X_s, s > t$, não depende do valor de $X_u, u < t$, i.e., a probabilidade de qualquer comportamento particular futuro do processo, quando este presente estado é conhecido exatamente, não é alterado por qualquer conhecimento adicional do passado deste comportamento [Rinne 2009].

Definição: Uma sequência de variáveis aleatórias $\{X_n\}, n \geq 0$ é dito ser uma *Cadeia de Markov*, se para algum conjunto contável $S \subseteq \mathbb{R}$ e em qualquer valor de $n \geq 1, x_{n+1}, x_n, \dots, x_0 \in S$, a probabilidade pode ser dada pela equação 3.7. O conjunto S é chamado de *espaço de estado* da cadeia. Se S é um conjunto finito, a cadeia é chamada *Cadeia de estados finitos de Markov*. X_0 é chamado de estado inicial [DasGupta 2010, Ross 2010].

$$P(X_{n+1} = x_{n+1} | X_0 = x_0, \dots, X_n = x_n) = P(X_{n+1} = x_{n+1} | X_n = x_n) \quad (3.7)$$

Uma cadeia de Markov é dita homogênea ou estacionária se $P(X_{n+1} = y | X_n = x)$ é independente de n para quaisquer x, y . As probabilidades $p_{ij} = P(X_{n+1} = j | X_n = i)$ são chamadas de *etapas da probabilidade de transição* ou simplesmente *probabilidades de transição* e a matriz $P = ((p_{ij}))$ é chamada de *matriz probabilidade de transição* [DasGupta 2010].

Definição: Se $\{X\}$ é uma cadeia estacionária de Markov. Então, as probabilidades $p_{ij}(n) = P(X_{n+m} = j | X_m = i) = P(X_n = j | X_0 = i)$ são chamadas de *probabilidades de n-estados de transição* e a matriz $P^{(n)} = ((p_{ij}(n)))$, onde tem-se $0 \leq i \leq M, 0 \leq j \leq M$ é chamada de *matriz de probabilidades de n-estados de transição*. Assim, a matriz P , também chamada de *matriz estocástica*, é uma matriz $t \times t$ e o $\sum_{j \in S} P_{ij} = 1$ onde $P_{ij} \geq 0$ pode ser arranjada da seguinte forma como em 3.8 [Ross 2010].

$$P^{(n)} = \begin{pmatrix} P_{00} & P_{01} & \dots & P_{0M} \\ P_{10} & P_{11} & \dots & P_{1M} \\ \vdots & \vdots & \ddots & \vdots \\ P_{M0} & P_{M1} & \dots & P_{MM} \end{pmatrix} \quad (3.8)$$

Em termos formais, um processo é dito se **Markoviano** se

$$Pr(a < X_t \leq b | X_{t_1} = x_1, X_{t_2} = x_2, \dots, X_{t_n} = x_n) = Pr(a < X_t \leq b | X_{t_n} = x_n) \quad (3.9)$$



Sempre que $t_1 < t_2 < \dots < t_n < t$. Seja A um intervalo na linha real. A função representada pela equação 3.10 é chamada *função transição de probabilidade* [Rinne 2009], que é a base para o estudo da estrutura dos processos de Markov, e pode ser reescrita como na equação 3.11.

$$P(x, s; t, A) = Pr(X_r \in A | X_s = x), t > s \quad (3.10)$$

$$Pr(a < X_t \leq b | X_{t_1} = x_1, X_{t_2} = x_2, \dots, X_{t_n} = x_n) = Pr(x_n, s_n; t, A) \quad (3.11)$$


Quando $A = \{\xi | a < \xi \leq b\}$, a distribuição de probabilidade de $(X_{t_1}, X_{t_2}, \dots, X_{t_n})$ pode ser computada em termos da função de transição de probabilidade 3.10 e a função distribuição inicial de X_{t_1} .

3.2.2 Equação de Chapman-Kolmogorov

A equação de Chapman-Kolmogorov fornece uma método simples para obter as probabilidades de transição de maior ordem da cadeia de Markov em termos de probabilidades de transição de menor ordem. A equação 3.12 descreve um método simples para calcular a probabilidade de transição de maior ordem em termos de um passo da probabilidade de transição [DasGupta 2011]. Tomando-se $\{X_n\}$ uma cadeia estacionária de Markov com o espaço de estado S e com $n, m \geq 1$ então:

$$P_{ij}(m+n) = P(X_{m+n} = j | X_0 = i) = \sum_{k \in S} P_{ik}(m)P_{kj}(n) \quad (3.12)$$

Exemplo: Considere que a previsão do tempo siga uma cadeia de Markov de dois estados, seja $\alpha = 0,6$ e $\beta = 0,2$, onde 0 = chove e 1 = não chove. Qual a possibilidade de chover daqui a 4 dias ? Adaptada de [DasGupta 2011].



$$P = \begin{vmatrix} \alpha & 1-\alpha \\ \beta & 1-\beta \end{vmatrix} = \begin{vmatrix} 0,6 & 0,4 \\ 0,2 & 0,8 \end{vmatrix}$$

Pela equação de Chapman-Kolmogorov tem-se:

$$P^4 = P^2 \cdot P^2 \Rightarrow P^2 = \begin{vmatrix} 0,6 & 0,4 \\ 0,2 & 0,8 \end{vmatrix} \cdot \begin{vmatrix} 0,6 & 0,4 \\ 0,2 & 0,8 \end{vmatrix} = \begin{vmatrix} 0,44 & 0,56 \\ 0,28 & 0,72 \end{vmatrix}$$

$$P^4 = P^2 \cdot P^2 = \begin{vmatrix} 0,44 & 0,56 \\ 0,28 & 0,72 \end{vmatrix} \cdot \begin{vmatrix} 0,44 & 0,56 \\ 0,28 & 0,72 \end{vmatrix} = \begin{vmatrix} 0,3504 & 0,6496 \\ 0,3248 & 0,6752 \end{vmatrix}$$

Então $p_{00}^4 = 0,3504$.

Para um grande número de cadeias de Markov, $P_{ij}^{(n)}$ converge a medida que $n \rightarrow \infty$ para um valor π_j que depende somente de j . Para que uma cadeia de Markov possua essa propriedade para $n > 0$ se verifica a equação 3.13.

$$P_{ij}^{(m)} > 0, \quad \forall i, j = 0, 1, 2, \dots, M \quad (3.13)$$

A cadeia de Markov em 3.14, que satisfaz esta probabilidade, recebe o nome de *ergódica* [Ross 2010].

$$P_{ij}^{(n+1)} = \sum_{k=0}^M P_{ik}^{(n)} P_{kj} \quad (3.14)$$

3.2.3 Processos Estacionários

Um processo estacionário $\{X\}$ para $t \in \mathbb{T}$, onde $\mathbb{T}$ pode ser um conjunto $(-\infty, \infty)$, $[0, \infty)$, $\{\dots, -1, 0, 1\}$ ou $\{1, 2, \dots\}$ é dito ser *estritamente estacionário* se a função distribuição conjunta da família de variáveis aleatórias $(X_{t_1+h}, X_{t_2+h}, X_{t_3+h}, \dots, X_{t_n+h})$ e $(X_{t_1}, X_{t_2}, X_{t_3}, \dots, X_{t_n})$ é a mesma para todo $h > 0$, com seleções arbitrárias $t_1, t_2, t_3, \dots, t_n$ de $\mathbb{T}$. As funções distribuição são invariantes com respeito à translação para todo o tempo. Esta condição afirma que em essência o processo tem equivalência probabilística e que o tempo particular para qual o processo é examinado não é relevante [Rinne 2009].

Um processo estocástico $\{X_t\}$ é dito ser *altamente estacionário* ou *covariante estacionário* se processa segundos momentos finitos e se 3.15 depende somente de h para todo $t \in \mathbb{T}$

$$Cov(X_t, X_{t+h}) = E(X_t X_{t+h}) - E(X_t)E(X_{t+h}) \quad (3.15)$$

Processo Ponto

Um processo ponto é obtido quando considera-se uma sequência de eventos ocorrendo em tem contínuo, eventos individuais, *e.g.* falhas do sistema, sendo distinguido somente sua posição no tempo. Seja $T_n; n = 1, 2, \dots$ uma sequência positiva de variáveis aleatórias onde:

$$T_0 = 0; T_n < T_{n+1} \text{ e } T_n \rightarrow T_\infty \leq \infty$$

T_n representa uma instância de ocorrência do n -ésimo evento. O número total de eventos no intervalo de 0 a t é uma variável aleatória N_t que pode ser escrita na forma da equação 3.16:

$$N_t = \sum_{n=0}^{\infty} I_{\{T_n \leq t\}} \quad (3.16)$$

Onde I_A é o indicador do conjunto A e a família $N = (N_t, 0 \leq t \leq \infty)$ é um processo contínuo, onde $N_t = n$ se $T_n \leq t \leq T_{n+1}$ [Rinne 2009]. Ou seja, N é um processo incremental e sua trajetória é uma função escada contínua à direita com pulos para cima de magnitude 1.

3.3 Inferência e Decisão

A a teoria da probabilidade fornece um *framework* com consistência matemática para quantificar e manipular incertezas. O reconhecimento de padrões envolve tomar decisões ótimas sobre situações que envolvam incertezas.

Suponha existir um vetor de entradas x junto com uma vetor correspondente t de variáveis de saídas, e o objetivo é prever t dado um novo valor para x . Pelo problema de regressão, t irá abranger variáveis contínuas, ao passo que pelo problema de classificação, t irá representar uma classe de classificação. A união da distribuição de probabilidade conjunta $P(x, t)$ fornece um resumo completo da incerteza associada com estas variáveis. A determinação de $P(x, t)$ forma um conjunto de treinamento de dados em um exemplo de *inferência*, sua determinação é tipicamente

um problema muito difícil, entretanto uma predição específica para um valor de t , fornece uma ação específica baseada na compreensão do significado do valor que t representa. A *teoria da decisão* diz como deve-se tomar uma decisão ótima dada uma probabilidade [Bishop 2009].

3.3.1 Minimização da Taxa de Erros de Classificação

Quando delimita-se um grande problema, com a finalidade de simplificar sua avaliação, é possível que alguns erros de classificação sejam cometidos. Portanto, será necessário definir uma regra para indicar cada valor de x a uma determinada classe disponível, como por exemplo, dividir-se o espaço da entrada em regiões R_k para definir C_k classes, neste caso, deve-se estabelecer uma *região de decisão*. A fronteira entre as regiões de decisão são chamadas de *fronteira de decisão* ou *superfície de decisão*. Cada região de decisão necessita não ser contínua, mas pode comprometer algum número de regiões disjuntas. Sejam, duas regiões C_1 e C_2 que representam a definição de regiões de um problema qualquer, um erro ocorre quando a algum vetor de entradas pertencente à classe C_1 é indicado para a classe C_2 ou vice-versa. A probabilidade desta ocorrência $P(\text{erro})$ pode ser dada pela equação 3.17 [Bishop 2009].

$$\begin{aligned} P(\text{erro}) &= P(x \in R_1, C_2) + P(x \in R_2, C_1) \\ P(\text{erro}) &= \int_{R_1} P(x, C_2) dx + \int_{R_2} P(x, C_1) dx \end{aligned} \quad (3.17)$$

Para minimizar o erro de classificação deve-se obter o menor valor para o valor da integrado na equação 3.17. Assim, $P(x, C_1) > P(x, C_2)$ para um valor dado de x , onde possa ser indicado um x para a classe C_1 . Pela regra do produto tem-se em 3.18 [Bishop 2009].

$$P(x, C_k) = P(C_k|x)P(x) \quad (3.18)$$

Como o fator $P(x)$ é igual em ambos os termos, pode-se dizer que a probabilidade mínima de se ter um erro ocorre quando a probabilidade a posteriori $P(C_k|x)$ é maior, como ilustra a Figura 3.1 adaptada de [Bishop 2009], para duas probabilidades $P(x, C_1)$ e $P(x, C_2)$, junto com a decisão de fronteira $x = \hat{x}$. Os valores de $x \geq \hat{x}$ são classificados como classe de C_2 pertencentes a R_2 , os pontos de $x < \hat{x}$ são classificados como C_1 , pertencentes a região R_1 .




Figura 3.1: Probabilidade do erro de classificação

Erros surgem da interseção das duas regiões $P(x, C_1)$ e $P(x, C_2)$, nas áreas 1, 2 e 3 da Figura 3.1. Os valores na região entre $x < \hat{x}$ são devido aos ponto da classe C_2 originados de erros de classificação como C_1 representado nas áreas 1 e 2, consequentemente formados por valores da classe C_1 entre $x \geq \hat{x}$ originados por erros de classificação em C_2 representado pela área 3. Assim, considerando a ótima escolha para $\hat{x}$ é onde as curvas de $P(x, C_1)$ e $P(x, C_2)$ cruza, correspondendo a $\hat{x} = x_0$, que faz com que a região 1 desapareça, equivalendo ao menor erro de classificação. Portanto, maximizando a probabilidade de forma mais genérica em K tem-se a equação 3.19.

$$P(\text{erro}) = \sum_{k=1}^K P(x \in R_k, C_k) \quad (3.19)$$

$$P(\text{erro}) = \sum_{k=1}^K \int_{R_k} P(x, C_k) dx$$

A equação 3.19 é maximizada quando as regiões R_k são escolhidas através do conjunto de cada x indicado para uma determinada classe, onde o valor da probabilidade $P(x, C_k)$ tem o maior valor.

3.3.2 Minimização da Perda Esperada

Se serão escolhidos valores de x com um certo grau de incerteza, deve-se então formalizar o problema com uma *função de perda* ou seja associar-se uma *função de custo*, a qual é uma *medida de perdas indesejadas* ao escolher uma das opções. O objetivo é minimizar esta perda total. Suponha que para um novo valor de x , a classe real seja C_k e que é indicado um valor x para uma classe C_j (onde j pode ser ou não igual a k). Relaciona-se um nível de perda que é denotado por L_{kj} , a qual é denotada como os k, j elementos de um *matriz de perda*.

A solução ótima é um valor que minimiza a função de perda. Entretanto, a função de perda depende da verdadeira classe, a qual é desconhecida. Para um dado vetor de entradas $\vec{x}$, nossa incerteza na verdadeira classe é expressa sobre a união das funções de probabilidades $P(x, C_k)$. Busca-se minimizar a média da perda, quando a variação é computada com respeito a esta distribuição, dada pela esperança de perda na equação 3.20.

$$E[L] = \sum_k \sum_j \int_{R_j} L_{kj} P(x, C_k) dx \quad (3.20)$$

Cada x pode ser indicado independentemente da decisão de qual região R_j se escolher. O objetivo é escolher a região R_j a fim de minimizar a esperança de perda em 3.20, a qual implica que para cada x seja minimizada $\sum_k L_{kj} P(x, C_k)$. Pela regra do produto $P(x, C_k) = P(C_k|x)P(x)$ para eliminar o fator comum de $P(x)$. Assim a regra de decisão que minimiza o esperança de perda é aquela na qual o novo x para a classe j para o qual a equação 3.21 é um mínimo [Bishop 2009].

$$E[L] = \sum_k L_{kj} P(C_k|x) \quad (3.21)$$

3.3.3 Métodos para Decisão e Inferência

O problema da decisão pode ser dividido em dois estágios: O *estágio de inferência* na qual é utilizado dados de treinamento para aprender o modelo para $P(C_k|x)$ e o *estágio da decisão* onde é utilizada as probabilidades a posteriori para tomar-se ótimas classes. Uma probabilidade alternativa seria solucionar ambos os problemas juntos e simplesmente aprender uma função que mapeia as entradas diretamente dentro das regiões de decisões, também chamada de *função discriminante*. Pode-se identificar três diferentes abordagens para solucionar o problema da decisão:

(a) **Modelo generativo**: Primeiro solucionar o problema da inferência determinando a classe densidade condicional definida por $P(x|C_k)$ para cada classe C_k individualmente. Inferir separadamente a probabilidade $P(C_k)$, dada pelo teorema de Bayes pela equação 3.22:

$$P(C_k|x) = \frac{P(x|C_k)P(C_k)}{P(x)} \quad (3.22)$$

para encontrar a probabilidade da classe a posteriori $P(C_k|x)$. O teorema de Bayes também define que pode-se determinar o denominador como em 3.23

$$P(x) = \sum_k P(x|C_k)P(C_k) \quad (3.23)$$

Pode-se modelar a distribuição conjunta $P(x, C_k)$ diretamente e normalizar para obter as probabilidades a posteriori. Tendo-se as probabilidades a posteriores, usando a teoria da decisão determina-se os membros das classes para cada nova entrada x .

(b) **Modelo discriminativo**: Primeiro soluciona-se o problema da inferência por determinar as classes de probabilidades posteriores $P(C_k|x)$ e então subsequentemente usa-se a teoria da decisão para indicar um novo x para uma das classes.

(c) Encontrar uma função $f(x)$, chamada *função discriminante*, a qual mapeia cada entrada de x diretamente dentro de uma classe. Por exemplo no caso de um problema de duas classes, $f(\cdot)$ pode ter um valor binário como $f = 0$ para representar a classe C_1 e $f = 1$ para representar a classe C_2



A abordagem (a) é mais custosa pois envolve encontrar a distribuição disjunta sobre ambos x e C_k . Em muitos casos, x poderá ser multidimensional e necessitará de muito processamento para serem determinadas as classes com possibilidade de ter-se problemas de acurácia. Entretanto, se somente escolher tomar a decisão por classificação (b), então pode-se ter desperdício de recursos computacionais e demandar uma quantidade excessiva de dados, para encontrar a distribuição conjunta $P(x, C_k)$ quando de fato raramente será necessário as probabilidades a posteriori $P(C_k|x)$. De fato, as classes densidade condicional podem conter muitas das estruturas que tem pouco efeito probabilidades posteriores. Uma abordagem ainda mais simples é usada em (c) quando o dados de treinamento encontram uma combinação de estágios de inferência e decisão dentro de um simples problema de aprendizagem. Nesta abordagem não calcula-se probabilidades a posteriori $P(C_k|x)$. Entretanto existem fortes razões para se calculá-las com por exemplo minimizar os riscos, rejeitar opções e identificar classes a priori [Bishop 2009, Lasserre et al. 2006].

Capítulo 4

Técnicas e Modelos de Predição

A predição do comportamento de variáveis aleatórias exige a utilização de métodos que, dada uma entrada, possam quantificar uma saída de dados. O método *linear* tem sido utilizado como uma abordagem estatística a várias décadas. Uma abordagem mais precisa é obtida com o método dos *k-vizinhos*, entretanto este modelo apresenta problemas de instabilidade. A regressão é um método muito utilizado para modelar a predição de eventos que relaciona o valor médio de uma variável aleatória com o valor correspondente de uma ou mais variáveis independentes.

Algumas abordagens recursivas são apresentadas devido a sua larga escala de utilização, porém o desempenho deste métodos só é evidente quando tem-se grandes tempos de identificação. A Máxima Verossimilhança ou *Maximum Likelihood* é o método mais geral para a estimação de parâmetros, foi desenvolvida por Ronald Fischer (1912-1921), baseado nas ideias de Gaus. O principal atrativo para alguns métodos como o da Máxima Verossimilhança podem estar relacionados abaixo [DasGupta 2008], [SEARLE et al. 2006]:

1. Não são viciados, pois o valor da esperança do estimador será o próprio parâmetro $E[\hat{\beta}] = \beta$.
2. Tem consistência, ou seja, uma amostra de tamanho crescente na fronteira do parâmetro $\hat{\beta}$ convergirá para a probabilidade β .
3. Tem mínima variância, pois a estimativa é escolhida a partir daquele que tem menor variância entre os possíveis estimadores.

Uma das desvantagens do uso da abordagem da Máxima Verossimilhança está relacionada com o alto custo computacional para um grande conjunto de dados. Assim, neste capítulo serão apresentados diferentes métodos que foram combinados com as técnicas mais conhecidas para proporcionar predições com maior desempenho computacional mantendo a acurácia destes métodos.

4.1 Métodos de Predição Simples

O método linear faz diversas restrições sobre a estrutura dos dados, porém pode gerar predições imprecisas. Outro método utilizado é os *k-vizinhos mais próximos* que faz poucas restrições sobre a estrutura dos dados suas predições são acuradas, mas podem tornar-se instáveis. Estes métodos também são utilizados em modelos de regressão linear.

A regressão linear é um modelo de predição que assume que a função de regressão $E(X|Y)$ é linear com uma entrada $X_1, X_2, \dots, X_p$. São simples e muitas vezes provêm uma descrição

adequada e interpretável de como as entradas afetam a saída. Para o propósito de previsão eles podem muitas vezes superar os modelos não lineares mais extravagantes, especialmente em situações com pequeno número de casos de treinamento, baixa relação sinal/ruído e dados esparsos [Hastie et al. 2011].

4.1.1 Método dos Mínimos Quadrados

O modelo linear é uma das ferramentas mais importantes da estatística. Dado uma matriz de entradas $X^T = (X_{11}, X_{12}, X_{21}, X_{22}, \dots, X_{1n}, X_{2n})$, a saída $\hat{Y}$ pode ser expressa como um valor que conterà uma variação ou erro em relação ao valor $\hat{y}_i$ real, como demonstra a figura 4.1. Assim, o ponto real $(x_{1i}, x_{2i}, \hat{y})$ é originado a partir de $(x_{1i}, x_{2i}, y_i) + e_i$, onde este e_i é o erro associado.




Figura 4.1: Distribuição de resultados de um experimento qualquer

O somatório ao quadrado de todos dos erros e_i associados é um valor que não é um valor nulo e se seu valor for mínimo conterà os parâmetros da lei de formação. Tomando-se os resultados da Figura 4.1 tem-se a relação em forma matricial, onde $\hat{Y}$ é o vetor de resultados experimentais, $\underline{X}$ é a matriz de variáveis experimentais independentes, $\hat{\beta}$ é o vetor de variáveis, n é o número de amostras e p o número de parâmetros.

$$\underbrace{\begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}}_{\hat{Y}_{(n,1)}} = \underbrace{\begin{pmatrix} x_{11} & x_{12} \\ x_{12} & x_{22} \\ \vdots & \vdots \\ x_{1n} & x_{2n} \end{pmatrix}}_{\underline{X}_{(n,p)}} \cdot \underbrace{\begin{pmatrix} a \\ b \end{pmatrix}}_{\hat{\beta}_{(p,1)}} \quad (4.1)$$

Assim, pode-se reescrever 4.1 como em 4.2 e após multiplicando-se ambos os lados pela matriz transposta $\underline{X}^T$ temos 4.3

$$\hat{Y} = \underline{X} \cdot \hat{\beta} \quad (4.2)$$

$$\underline{X}^T \hat{Y} = \underline{X} \underline{X}^T \cdot \hat{\beta} \quad (4.3)$$

Supondo-se que o $\det \underline{X} \underline{X}^T \neq 0$ então esta matriz pode ser invertida. Portanto em 4.4, tem-se na multiplicação de $|\underline{X} \underline{X}^T|^{-1} \underline{X} \underline{X}^T$ uma matriz identidade I . Assim o vetor de parâmetro $\hat{\beta}$ pode ser reescrito com em 4.5. O vetor $\hat{\beta}$ é conhecido como estimador de Gaus ou estimador de Mínimos Quadrados [Hastie et al. 2011].

$$|\underline{X} \underline{X}^T|^{-1} \underline{X}^T \hat{Y} = \underbrace{|\underline{X} \underline{X}^T|^{-1} \underline{X} \underline{X}^T}_I \cdot \hat{\beta} \quad (4.4)$$

$$\hat{\beta} = |\underline{X} \underline{X}^T|^{-1} \underline{X}^T \hat{Y} \quad (4.5)$$

O modelo da regressão linear é aquele que envolve uma combinação linear das variáveis da entrada como em 4.6 onde $x = (x_1, x_2, \dots, x_D)^T$, também conhecido como *regressão linear*. O ponto chave das propriedades deste modelo é ser uma função linear de parâmetros $w_0, w_1, \dots, w_D$ com uma entrada de variáveis x_i . Entretanto, a entrada variável impõe limitações ao modelo.

$$y(x, w) = w_0 + w_1 x_1 + \dots + w_D x_D \quad (4.6)$$

Seja a combinação linear de funções não lineares invariantes contendo entradas variáveis, pode-se reescrever a equação 4.6 como em 4.7. Onde $\phi_j(x)$ é conhecida como uma *função básica*.

$$y(x, w) = w_0 + \sum_{j=1}^{M-1} w_j \phi_j(x) \quad (4.7)$$

O parâmetro w_0 desempenha o papel de *offset* da entrada de dados, também conhecido como *parâmetro bias*. O *parâmetro bias* pode assumir uma função básica $w_0 = 1$, neste caso, temos a equação 4.8

$$y(x, w) = \sum_{j=1}^{M-1} w_j \phi_j(x) = w^T \phi(x) \quad (4.8)$$

Onde $w = (w_0, w_1, \dots, w_{M-1})^T$ e $\phi = (\phi_0, \phi_1, \dots, \phi_{M-1})^T$. Em muitas aplicações práticas de reconhecimento de padrões são aplicadas algumas formas de pre-processamento fixos de extração de características, para as variáveis de dados originais [Bishop 2009].

4.1.2 Método dos K-vizinhos Mais Próximos

O método dos *k-vizinhos mais próximos* considera que existem regiões onde pode ocorrer sobreposições, sendo assim as predições irão também refletir esta sobreposição. Um treinamento de um conjunto fechado τ da entrada do espaço x para uma saída $\hat{Y}$ é definida como em 4.9, dado pelos *k-vizinhos mais próximos*. Onde $N_k(x)$ é a vizinhança de x definida pelos k pontos de x_i na região de treinamento fechado τ . Assim, implica em existir uma métrica de distância euclidiana entre estes pontos, ou seja, que a distância d entre dois pontos (a, b) pode ser dada por $d^2 = a^2 + b^2$, onde a é ortogonal a b .

$$\hat{Y}(x) = \frac{1}{k} \sum_{x_i \in N_k(x)} y_i \quad (4.9)$$

A ideia-chave do modelo de *k-vizinhos mais próximos* é que as propriedades de qualquer ponto da entrada x específico têm probabilidade de serem semelhantes às propriedades de pontos na vizinhança de x . Na prática um valor entre 5 e 10 fornece bons resultados para a maioria dos conjuntos de dados de baixo número de dimensões. Outro problema a considerar está relacionado à métrica da distância euclidiana, que não é apropriada quando cada dimensão do espaço está medindo propriedades distintas, como por exemplo altura e peso [Russel and Norving 2004].

4.2 Máxima Verossimilhança

A Máxima Verossimilhança ou *Maximum Likelihood* é o método mais geral para a estimação de parâmetros. Foi desenvolvida por Ronald Fischer (1912-1921), baseado nas ideias de Gaus. A Função de Verossimilhança é essencialmente a densidade de probabilidade das observações. Para determiná-la é necessário um conhecimento a priori que torne possível a descrição da condição da densidade de probabilidade das observações. A determinação das condições de distribuição é essencialmente um problema de predição e a *função de verossimilhança* pode ser expressa como um produto das condições das densidades de probabilidade e da predição de erro. Uma das razões de seu uso deve-se ao fato de possuir boas propriedades assintóticas [DasGupta 2008].

Seja Y uma variável aleatória com densidade de probabilidade $P(Y, \beta)$, β um parâmetro qualquer, frequentemente interpretado como um vetor. Calcula-se β para maximizar a *função de verossimilhança* com em 4.10 para as observações dos eventos de Y .

$$L(Y, \beta) = P(Y, \beta) \quad (4.10)$$

Desde que os eventos $Y_1, Y_2, \dots, Y_n$ sejam independentes e identicamente distribuídos (iid), a *função de verossimilhança* será o produto da densidade de probabilidade de Y_n e a equação 4.10 pode ser dada por 4.11:

$$L(Y_1, Y_2, \dots, Y_n; \beta) = \prod_{i=1}^n P_i(Y_i, \beta) \quad (4.11)$$

No caso especial em que $Y_1, Y_2, \dots, Y_n$ segue uma distribuição normal $N(\mu, \sigma^2)$, μ um inteiro positivo, e substituindo em 4.11 tem-se a *função de verossimilhança*, como a equação 4.13 [DasGupta 2008].

$$P(Y, \beta) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(y-\mu)^2} \quad (4.12)$$

$$L(Y_1, Y_2, \dots, Y_n; \beta) = \left(\frac{1}{\sqrt{2\pi}\sigma}\right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (y-\mu)^2} \quad (4.13)$$

Da distribuição normal tem-se $P(Y, \beta) \simeq N(\bar{Y}, \sigma^2)$ com um erro $e \simeq N(0, V)$, onde a $Var(e) = I\sigma^2$ ou seja os eventos iid são homogêneos e possuem mesma variância. Onde $\underline{V}$ é a matriz de variâncias como em 4.14 [SEARLE et al. 2006].

$$\underline{V} = \begin{vmatrix} 1 & & & \\ & 1 & & \\ & & 1 & \\ & & & \ddots \\ & & & & 1 \end{vmatrix} \sigma^2 \quad (4.14)$$

A variância mínima $Var(e)$ denotada como $\underline{V}$, e os dados como um vetor $\vec{y} \sim N_N(X\beta, V)$, pode-se reescrever 4.13 como 4.15:

$$L(\beta, V|y) = \frac{1}{(\sqrt{2\pi})^n |\underline{V}|^{\frac{1}{2}}} e^{-\frac{1}{2}[(Y - \underline{X}\beta)^T \cdot \underline{V}^{-1} \cdot (Y - \underline{X}\beta)]} \quad (4.15)$$

Onde $|\underline{V}|$ é a norma da matriz de variância.

O estimador de máxima verossimilhança (MLE) usa os valores de β e V para maximizar a função de verossimilhança. Assim, aplicando o logaritmo natural em 4.15 e derivando em relação ao vetor de parâmetros $\underline{\beta}$, para maximizar L . Isto significa fazer $\frac{\partial \ln(L)}{\partial \underline{\beta}} = 0$. O resultado em 4.16 é a matriz do estimador de parâmetros de verossimilhança, com a distribuição de probabilidade do erro $e \simeq (0, I\sigma^2)$ [SEARLE et al. 2006].

$$\underline{\beta} = (\underline{X}^T \cdot V^{-1} \cdot \underline{X})^{-1} (\underline{X}^T \cdot V^{-1} \cdot \underline{Y}) \quad (4.16)$$

Um princípio geral para MLE é que se verifique $\frac{\partial \ln(L)}{\partial \underline{\beta}} = 0$. Entretanto, esta solução pode não ser necessariamente o máximo estimador de β mas meros candidatos [SEARLE et al. 2006]. Outro problema em potencial é que o MLE pode não existir. Assim, é necessário estabelecer-se uma lista de restrições [DasGupta 2008].

4.3 Maximum Likelihood e Mínimos Quadrados

Uma abordagem a ser explorada é o uso do estimador de MLE com mínimos quadrados. Assim, assume-se que um variável alvo t é dada por uma função determinística $y(x, w)$ com distribuição Gaussiana dada pela equação 4.17

$$t = y(x, w) + \varepsilon \quad (4.17)$$

onde ε é zero significa de a média Gaussiana da variável randômica com variância inversa β , de forma que se pode escrever 4.17 a distribuição como em 4.18

$$P(t|x, w, \beta) = N(t|y(x, w), \beta^{-1}) \quad (4.18)$$

Se assume-se uma função de mínimos quadrados, então a predição opcional, para o novo valor de x irá ser dado pela media condicional da variável alvo. No caso da condicional ter a forma 4.18, pode-se ter que a esperança $E[t|x]$ pode ser calculada como na equação 4.19. Esta restrição do uso de uma distribuição normal, implica em ter-se uma condição unimodal, a qual pode não ser apropriada para algumas aplicações [Bishop 2009].

$$E[t|x] = \int tP(t|x)dt = y(x, w) \quad (4.19)$$

Seja um conjunto de dados $X = \{x_1, x_2, \dots, x_N\}$ com correspondente alvo em um conjunto vetor denotado por $T^T = (t_1, t_2, \dots, t_N)$. Os pontos dos dados são independentes da distribuição 4.18, obtêm-se a seguinte função de Máxima Verossimilhança em 4.20, para ajuste dos parâmetros w e β , usando as definições da equação 4.8.

$$P(T^T|X, w, \beta) = \prod_{n=1}^N N(t_n|w^T \phi(x_n), \beta^{-1}) \quad (4.20)$$



Quando considera-se uma distribuição normal $N(\mu, \sigma^2)$, para uma Gaussiana invariante, tem-se

$$\ln P(T^T|w, \beta) = \sum_{n=1}^N \ln N(t_n|w^T \phi(x_n), \beta^{-1}) \quad (4.21)$$

$$\ln P(T^T|w, \beta) = \frac{N}{2} \ln \beta - \frac{N}{2} \ln(2\pi) - \beta E_D(w)$$

Onde a função de soma dos quadrados do erro é definida como em 4.22 [Bishop 2009].

$$E_D(w) = \frac{1}{2} \sum_{n=1}^N \{t_n - w^T \phi(x_n)\}^2 \quad (4.22)$$

Então, a função de erro total torna-se

$$\frac{1}{2} \sum_{n=1}^N \{t_n - w^T \phi(x_n)\}^2 + \frac{\lambda}{2} w^T w \quad (4.23)$$

Com a função de ML *Maximum Likelihood* podemos determinar os valores para w e β . Em um modelo linear esta função com uma distribuição Gaussiana é equivalente a minimizar uma função de erro da soma dos quadrados por $E_D = (w)$. Assim o gradiente da função log *likelihood* tem a forma da equação 4.24. Se o gradiente for zero, então tem-se a equação 4.25.

$$\nabla P(T^T|w, \beta) = \beta \sum_{n=1}^N \{t_n - w^T \phi(x_n)\} \phi(x_n)^T \quad (4.24)$$

$$0 = \sum_{n=1}^N t_n \phi^T(x_n) - w^T \left(\sum_{n=1}^N \phi(x_n) \phi(x_n)^T \right) \quad (4.25)$$

A equação 4.25 pode ser solucionada por x onde tem-se 4.26, que é também conhecida como *equação normal* para o problema dos mínimos quadrados. Aqui Φ é uma matriz $N \times M$ também conhecida como *matriz de projeto*, com elementos dados por $\Phi_{nj} = \phi_j(x_n)$ como representado em 4.27 [Bishop 2009].

$$w_{ML} = (\Phi^T \Phi)^{-1} \Phi^T t \quad (4.26)$$

$$\Phi = \begin{pmatrix} \phi_0 x_1 & \phi_1 x_1 & \dots & \phi_{M-1} x_1 \\ \phi_0 x_2 & \phi_1 x_2 & \dots & \phi_{M-1} x_2 \\ \vdots & \vdots & \vdots & \vdots \\ \phi_0 x_N & \phi_1 x_N & \dots & \phi_{M-1} x_N \end{pmatrix} \quad (4.27)$$

4.4 Método de Lasso

Os modelos de regressão linear tem como entrada um vetor $X^T = (X_1, X_2, X_3, \dots, X_n)$, para a predição de um valor real com saída Y . O modelo da regressão linear tem a forma expressa pela equação 4.28. O modelo linear ou assume que a função de regressão $E[Y|X]$ é linear ou que o modelo é razoavelmente aproximado. A variável aleatória X_j pode assumir diferentes formas e o B_j é um parâmetro ou um conjunto de coeficientes de erro [Hastie et al. 2011].

$$f(X) = \beta_0 + \sum_{j=1}^p X_j \beta_j \quad (4.28)$$

Tipicamente tem-se um conjunto de dados $(x_1, y_1) \dots (x_N, y_N)$ para os quais estima-se os parâmetros β . Cada $x_i = (x_{i1}, x_{i2}, \dots, x_{ip})^T$ é um vetor de características mensuráveis. O mais popular método é o dos *mínimos quadrados*, na qual toma-se os coeficientes de $\beta = (\beta_0, \beta_1, \beta_2, \dots, \beta_p)^T$ para minimizar a soma residual dos quadrados ou seja $RSS(\beta) = \sum_{i=1}^N (y_i - f(x_i))^2$ [Hastie et al. 2011].

Do ponto de vista estatístico, este critério é razoável se as observações (x_i, y_i) são independentes e identicamente distribuídas. Na Figura 4.2, adaptada de [Hastie et al. 2011], observa-se a representação *N-dimensional* da regressão dos mínimos quadrados com 2 predições. O vetor ortogonal y é projetado sobre o hiperplano formado pelas entradas dos dois vetores x_1 e x_2 . A projeção $\hat{y}$ representa o vetor da predição de mínimos quadrados.




Figura 4.2: Regressão dos Mínimos Quadrados

Os valores inferidos para um vetor de entrada x_0 são dados por $\hat{f}(x_0) = (1 : x_0)^T \hat{\beta}$. Os valores ajustados para a entrada candidata são dados na equação 4.29 onde $\hat{y} = \hat{f}(x_i)$. A matriz $H = X(X^T X)^{-1} X^T$ é chamada de matriz de “hat”.

$$\hat{y} = X\hat{\beta} = X(X^T X)^{-1} X^T y \quad (4.29)$$

O Método de Lasso (*Least Absolute Shrinkage and Selection Operator*) é uma técnica de penalização onde ocorre o “encolhimento” do conjunto de valores possíveis para o parâmetro $\hat{\beta}$. O estimador Lasso é definido pela equação 4.30 sujeito à $\sum_{j=1}^p |\beta_j| \leq t$ [Hastie et al. 2011].

$$\hat{\beta}^{lasso} = \underset{\beta}{\operatorname{argmin}} \sum_{i=1}^N (y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j)^2 \quad (4.30)$$

A constante β_0 pode ser reparametrizada para padronização das predições, assim pode ser reescrito com o equivalente à forma de *Lagrangian* em 4.31.

$$\hat{\beta}^{lasso} = \underset{\beta}{\operatorname{argmin}} \left\{ \sum_{i=1}^N (y_i - \beta_0 - \sum_{j=1}^p x_{ij})^2 + \lambda \sum_{j=1}^p |\beta_j| \right\} \quad (4.31)$$

A penalização de Lasso cria uma solução não linear em y_i como representado na Figura 4.3 adaptada de [Hastie et al. 2011]. No estimador β_j na coluna ortogonal de X , onde M (tamanho) e λ são constantes escolhidas pelas fórmulas $\hat{\beta}_j \cdot I[\operatorname{rank}(|\hat{\beta}_j| \leq M)]$ e $\operatorname{sign}(\hat{\beta}_j)(|\hat{\beta}_j| - \lambda)_+$. Assim, *sign* denota que o argumento é (± 1) e x_+ que é a parte positiva de x .




Figura 4.3: Penalização de Lasso

4.5 Método dos Mínimos Ângulos de Regressão

O método dos Mínimos Ângulos de Regressão ou LAR (Least Angle Regression) é uma variação da versão da regressão *forward stepwise*, sua metodologia está intimamente conectada ao método do Lasso, fornecendo um algoritmo extremamente eficiente sob o ponto de vista computacional. O método *Forward stepwise* é um modelo sequencial, adicionando uma variável de cada vez. A cada passo, identifica a melhor variável para incluir em conjunto de variáveis ativas, e, em seguida, atualiza o cálculo dos mínimos quadrados para incluir todas as variáveis ativas calculadas.

O método LAR identifica na primeira etapa a variável mais correlacionada com a resposta. Ao invés de ajustar esta variável completamente, o LAR move o coeficiente desta variável continuamente em direção ao seu valor de mínimos quadrados (produzindo um efeito de diminuir o valor absoluto, através da correlação de seu valor residual). Assim que uma outra variável fixa em termos de sua correlação com o restante, o processo é interrompido. A segunda variável, em seguida, junta-se ao conjunto ativo, e seus coeficientes são movidos juntos em uma maneira que mantém suas correlações amarrando e diminuindo. Este processo continua até que todas as variáveis estão no modelo e finaliza com o ajuste dos mínimos quadrados [Hastie et al. 2011].

Algoritmo do Mínimo Ângulo de Regressão

1. Padroniza as predições para ter média zero e norma unitária. Inicia com o valor residual $y = y - \bar{y}, \beta_1, \beta_2, \dots, \beta_p = 0$.
2. Encontra o predito x_j mais correlacionado com r .

3. Move β_j para 0 em direção aos coeficientes de mínimos quadrados $\langle x_j, r \rangle$, até algum outro competidor x_k tenha uma maior correlação com o valor residual corrente de x_j .
4. Mova β_j e β_k na direção definida pelos seus coeficientes conjuntos de mínimos quadrados do valor residual corrente em (x_j, x_k) , até que algum outro competidor x_l tenha mais correlação com o valor residual corrente.
5. Continue até que todos os p preditores tenham sido iterados. Após $\min(N - 1, p)$ passos, se encontra a solução para todos os mínimos quadrados.

Seja A_k um conjunto ativo de variáveis para iniciar do k -ésimo passo e β_{A_k} ser o vetor de coeficientes para estas variáveis neste passo, haverá $k - 1$ valores não zeros e uma exata entrada será zero. Se $r_k = y - X_{A_k} \beta_{A_k}$ é o corrente valor residual, então a direção para estes passos é dado pela equação 4.32

$$\delta_k = (X_{A_k}^T X_{A_k})^{-1} X_{A_k}^T r_k \quad (4.32)$$

O perfil do coeficiente evolui como $\beta_{A_k}(\alpha) = \beta_{A_k} + \alpha \cdot \delta_k$. Se o vetor de ajuste neste inicio de passos é $\hat{f}_k$, então isto evolui como $\hat{f}_k(\alpha) = \hat{f}_k + \alpha \cdot u_k$, onde $u_k = X_{A_k} \delta_k$ é o novo ajuste de direção. O nome *último ângulo* origina-se da forma geométrica da interação com demonstra a Figura 4.4 adaptada de [Hastie et al. 2011].




Figura 4.4: Progressão das Correlações durante cada passo do Algoritmo LAR

4.5.1 Mínimo Ângulo de Regressão - Modificado pelo Método de Lasso

O método de Lasso introduz uma sutil, mas eficaz modificação no Algoritmo do Mínimo Ângulo de Regressão, por introduzir:

Algoritmo do Mínimo Ângulo de Regressão - Modificado pelo Método de Lasso



1. Padroniza as predições para ter média zero e norma unitária. Inicia com o valor residual $y = y - \bar{y}, \beta_1, \beta_2, \dots, \beta_p = 0$.
2. Encontra o predito x_j mais correlacionado com r .
3. Move β_j para 0 em direção aos coeficientes de mínimos quadrados $\langle x_j, r \rangle$, até algum outro competidor x_k tenha uma maior correlação com o valor residual corrente de x_j .
4. Mova β_j e β_k na direção definida pelos seus coeficientes conjuntos de mínimos quadrados do valor residual corrente em (x_j, x_k) , até que algum outro competidor x_l tenha mais correlação com o valor residual corrente.
 - (a) Se um coeficiente diferente de zero atinge zero, pegue esta variável do conjunto ativo de variáveis e recalcule a atual direção pelo conjunto de mínimos quadrados.
5. Continue até que todos os p preditores tenham sido iterados. Após $\min(N - 1, p)$ passos, se encontra a solução para todos os mínimos quadrados.

O algoritmo LAR - Lasso é extremamente eficiente, necessitando da mesma ordem de computação como que um único ajuste de mínimos quadrados utilizando p preditores. O ângulo de Lasso sempre toma p medidas para obter o estimador de mínimos quadrados completo. O caminho de Lasso pode obter mais que p passos, embora os dois são muito similares. O algoritmo modificado de Lasso é um caminho eficiente de solução computacional para qualquer problema especificamente quando $p \gg N$ [Hastie et al. 2011].

4.6 Método de Suavização de *Kernel*

O método de suavização de *kernel* é uma técnica de regressão que apresenta flexibilidade na estimação da regressão de funções $f(X)$ sobre o domínio $\mathbb{R}^p$, porque ajusta o modelo separadamente para cada busca do ponto x_0 . Isto é feito por usar somente as observações fechadas para um ponto alvo x_0 ajustando o modelo, de tal modo que a função de estimada resultante $\hat{f}(X)$ é suavizada em $\mathbb{R}^p$. Esta localização é obtida via uma *função de ponderação* ou *Kernel* $K_\lambda(x_0, x_i)$ a qual designa um peso para x_i baseada na distância de x_0 .

Os *Kernels* K_λ são tipicamente indexados por um parâmetro λ que dita a largura da vizinhança. Este método é baseado em memória requer em princípio pouco ou nenhum treinamento. Todo trabalho é feito no momento da avaliação. O único parâmetro que deve ser determinado a partir de treinamento de dados é λ [Hastie et al. 2011].

Em geral pode-se definir uma estimativa de uma regressão local de $f(x_0)$ como $f_\theta(x_0)$, onde θ minimiza o quadrado da soma residual (RSS) dado como na equação 4.33

$$RRS(f_\theta, x_0) = \sum_{i=1}^N K_\lambda(x_0, x_i)(y_i - f_\theta x_i)^2 \quad (4.33)$$

A função f_θ é alguma função parametrizada, como uma função polinomial de baixa-ordem. O método dos *vizinhos mais próximos* pode ser pensado como o método do *Kernel* tendo uma métrica mais dependente dos dados. A métrica para *k-vizinhos* mais próximos pode ser dada por 4.34:

$$K_k(x, x_0) = I(\|x - x_0\| \leq \|x_{(k)} - x_0\|) \quad (4.34)$$

Onde x_k é a k -ésima classificação de observação de treinamento na distância de x_0 e $I(S)$ é o indicador do conjunto de treinamento. Assim, a variação de k -vizinhos mais próximos pode ser modificada para a equação 4.35, como um estimador da função de regressão $E[Y|X = x]$. Uma vez que N_k é o conjunto de pontos de k mais próximos de x no quadrado da distância e Ave denota a média

$$\hat{f}(x) = \text{Ave}(y_i | x_i \in N_k(x)) \quad (4.35)$$

A Figura 4.5, adaptada de [Hastie et al. 2011] apresenta 100 pares x_i, y_i separados aleatoriamente por uma curva $Y = \sin(4X) + \varepsilon$, $X \sim U[0, 1]$, com erro Gaussiano $\varepsilon \sim N(0, 1/3)$. O ponto $\hat{f}(x_0)$ indica uma constante com ajustes fixados em torno de x_0 para um conjunto de observações e a região sinalizada pelo retângulo indica o tamanho destas observações.




Figura 4.5: Vizinho Próximos rodando média-suavizada

A ideia é simplificar a definição de esperança condicional e computar a média em uma vizinhança do ponto alvo. Neste caso foi utilizado 30 vizinhos ajustados para x_0 , movendo-se a esquerda ou a direita $\hat{f}(x)$, que representa os k -vizinhos mais próximos de x_0 se mantém constante, até que um ponto x_i a direita de x_0 se torna mais estreito do que o ponto x_i mais distante na vizinhança à esquerda de x_0 , até que x_i seja substituído por x'_i .

4.6.1 Regressão Local em $\mathbb{R}^p$

A suavização de *Kernel* e regressão local generalizam, muito naturalmente, duas ou mais dimensões. A suavização do *kernel Nadaraya-Watson* ajusta uma constante localmente com pesos fornecidos por um *kernel* p -dimensional. A regressão linear local vai ajustar-se a um

hiperplano localmente em X , por mínimos quadrados ponderados, com pesos fornecidos por um *kernel* p -dimensional. Isto é simples de implementar e é geralmente preferido para o ajuste de constantes locais devido a seu desempenho superior nas extremidades das fronteiras [Hastie et al. 2011].

Seja $\hat{b}(X)$ um vetor de termos polinomiais em X com grau máximo d . Por exemplo, com $d = 1$ e $p = 2$ obtêm-se $\hat{b}(X) = (1, X_1, X_2)$, com $d = 2$ obtêm-se $\hat{b}(X) = (1, X_1, X_2, X_1^2, X_2^2, X_1X_2)$ e com $d = 0$, $\hat{b}(X) = 1$. Assim para cada $x_0 \in \mathbb{R}^p$ pode-se escrever a seguinte equação 4.36

$$\min_{\beta(x_0)} \sum_{i=1}^N K_{\lambda}(x_0, x_i) (y_i - \hat{b}^T(x_i) \beta(x_0))^2 \quad (4.36)$$

Então produz-se o ajuste $\hat{f}(x_0) = \hat{b}^T(x_0) \hat{\beta}(x_0)$. Tipicamente o *Kernel* será um função radical, como um radical Epanechnikov ou *Kernel* tri-cubo dado em 4.37 onde $\|\cdot\|$ é uma norma Euclidiana.

$$K_{\lambda}(x_0, x) = D \frac{\|x - x_0\|}{\lambda} \quad (4.37)$$

Embora os efeitos de fronteira sejam um problema na suavização unidimensional, são um problema muito maior em duas ou mais dimensões, uma vez que a fração de pontos na fronteira é maior. Uma das restrições da utilização de dimensionalidade é que a fração de pontos próximos da fronteira aumente para uma dimensão cresce. Modificações diretamente sobre o *Kernel* para acomodar os limites bidimensionais torna-se muito confuso, especialmente para as fronteiras irregulares. A *Regressão polinomial local* executa estas correções para a ordem desejada em todas as dimensões [Hastie et al. 2011]. A Figura 4.6 adaptada de [Hastie et al. 2011] apresenta dados tri-dimensionais, onde a resposta é a medida de velocidade em uma galaxia e a predição de duas posições em uma esfera celestial.




Figura 4.6: Representação Geométrica de Kernel em $\mathbb{R}^p$

4.7 Método de Regressão Linear Bayesiana

O ML para um conjunto de parâmetros de um modelo de regressão linear é governado por um número de funções básicas, que necessitam ser controladas conforme o tamanho dos dados. Entretanto adicionar uma regularização em termos de *log likelihood* cria uma complexidade e possivelmente uma sobrecarga do sistema conforme for a escolha a quantidade e a forma das funções básicas.

4.7.1 Distribuição dos Parâmetros

O tratamento Bayesiano para a regressão linear necessita da definição de uma distribuição de probabilidade prévia sobre o modelo dos parâmetros de w . Inicialmente, considera-se a precisão do ruído β como uma constante. A função de Máxima Verossimilhança da equação 4.38 definida anteriormente em 4.20 é a exponencial da função quadrática de w . Assim, a distribuição de probabilidade prévia será definida por uma distribuição Gaussiana na forma como da equação 4.39, com média m_0 e covariância S_0 .

$$P(T^T|X, w, \beta) = \prod_{n=1}^N N(t_n|w^T \phi(x_n), \beta^{-1}) \quad (4.38)$$

$$P(w) = N(w|m_0, S_0) \quad (4.39)$$

Uma vez encontrada a normalização dos coeficientes usando resultados padrões para a normalização Gaussiana, deve-se reescrever a equação da distribuição a posterior como em 4.40. Isto quer dizer que, como a distribuição posterior segue uma Gaussiana, sua moda coincide com sua média. Assim o comprimento máximo do vetor é simplesmente dado por $w_{MAP} = m_N$. Se considerar-se uma prévia infinitamente ampla $S_0 = \alpha^{-1}I$ com $\alpha \rightarrow 0$, a média m_N da distribuição posterior se reduz ao *maximum likelihood* dado em 4.26.

$$P(w|T^T) = N(w|m_N, S_N) \quad (4.40)$$

Onde

$$m_N = S_N(S_0^{-1}m_0 + \beta\Phi^T T^T) \quad (4.41)$$

$$S_N^{-1} = S_0^{-1} + \beta\Phi^T \Phi \quad (4.42)$$

Ao computar a distribuição posterior, observa-se que ela também tem a forma Gaussiana, em função da distribuição de probabilidade prévia o ter. Assim, o log da distribuição posterior é dada pela soma da *log likelihood* e da *log prévia*, como uma função de w como na equação 4.43:

$$\ln P(w|T^T) = -\frac{\beta}{2} \sum_{n=1}^N \{t_n - w^T \phi(x_n)\}^2 - \frac{\alpha}{2} w^T w + \text{const.} \quad (4.43)$$

A maximização da distribuição posterior com respeito a w é portanto equivalente a minimização da soma dos quadrados da função de erro com a adição de uma regularização quadrática em termos, correspondente à equação 4.23 com $\lambda = \alpha/\beta$ [Bishop 2009].

4.7.2 Distribuição Preditiva

Usualmente não se está interessado no valor de w em si, mas em se fazer a predição de t para um novo valor de x . Isto requer a avaliação da função distribuição preditiva definida como

$$P(t|T^T, \alpha, \beta) = \int P(t|w, \beta)P(w|T^T, \alpha, \beta)dw \quad (4.44)$$

A distribuição condicional $P(t|x, w, \beta)$ do alvo variável é dado por 4.18 e o comprimento da distribuição posterior é dada por 4.40. Assim, pode-se definir a distribuição preditiva como a equação 4.45.

$$P(t|x, T^T, \alpha, \beta) = N(t|m_N^T \phi(x), \sigma_N^2(x)) \quad (4.45)$$

Onde a variância σ_N^2 da distribuição preditiva é dada pela equação 4.46, onde o primeiro termo correspondente ao ruído dos dados, o segundo termo representa a incerteza associada ao parâmetro w . Porque, os valores do ruído e da distribuição são independentes, então as variâncias se somam [Bishop 2009].

$$\sigma_N^2(x) = \frac{1}{\beta} + \phi(x)^T S_N \phi(x) \quad (4.46)$$

4.8 Método de Amostragens

Embora para algumas aplicações a distribuição posterior sobre variáveis não observadas será de discreto interesse, para muitas situações a distribuição posterior é requerida primeiramente para o propósito de avaliar a esperanças, *e.g.* com objetivo de fazer predições. O problema envolve encontrar alguma função $f(z)$ que represente uma distribuição de probabilidade $P(z)$. Os componentes de z podem abranger variáveis discretas ou contínuas, ou uma combinação das duas [Bishop 2009]. Para o caso de variáveis contínuas, pode-se avaliar a esperança $E[f]$, através da equação 4.47, para uma função $f(z)$ através de uma distribuição de probabilidade conhecida $P(z)$, como ilustra a Figura 4.7, adaptada de [Bishop 2009].




Figura 4.7: Exemplo de função $f(x)$ dada uma Probabilidade $P(z)$

$$E[f] = \int f(z)P(z)dz \quad (4.47)$$

Entretanto, as esperanças podem ter uma avaliação muito complexa usando-se técnicas analíticas. A ideia geral por trás do método de amostragem é obter um conjunto de amostragem z^l , onde $l = 1, 2, \dots, L$ independente da distribuição $P(z)$, assim a equação 4.47, poderá ser considerada aproximadamente finita como na equação 4.48

$$\hat{f} = \frac{1}{L} \sum_{l=1}^L f(z^{(l)}) \quad (4.48)$$

Como as amostras são tiradas da distribuição $P(z)$, então $E[\hat{f}] = E[f]$ e o estimador $\hat{f}$ tem média correta e sua variância pode ser dada pela equação 4.49. A acurácia do estimador não

depende da dimensionalidade de z . Isto implica, que na prática 10 ou 30 amostras independentes podem ser suficientes para estimar uma esperança com acurácia aceitável. O problema é que as amostras $\{z^{(l)}\}$ podem não ser suficientemente independentes e, assim, ser necessário um tamanho maior de amostras que o tamanho adotado inicialmente [Bishop 2009].

$$\text{var}[\hat{f}] = \frac{1}{L} E[(f - E[f])^2] \quad (4.49)$$

Na Figura 4.7 $f(z)$ é pequena em regiões onde $P(z)$ é grande e vice-versa, então a esperança pode ser dominada por regiões com baixa probabilidade, o que implica em ter-se uma grande quantidade de amostras para uma acurácia suficiente. Em muitos modelos, a distribuição conjunta de $P(z)$ é especificada em termos de um modelo gráfico. Para o caso de DAG (*directed acyclic graph*) sem nenhuma variável observada, é fácil provar a partir de uma distribuição conjunta (desde que exista uma amostra de distribuição condicional para cada nó) ter uma abordagem de *amostragem ancestral*, que pode ser obtida através da equação

$$P(z) = \prod_{i=1}^M P(z_i | pa_i) \quad (4.50)$$

Onde z_i são um conjunto de variáveis associadas com o nó i e pa_i é o conjunto de variáveis associadas com os ancestrais do nó i . Para obter uma amostragem de distribuição conjunta, o conjunto de variáveis $z_1, \dots, z_M$ na sua ordem de amostragem são repassadas para uma distribuição condicional $P(z_i | pa_i)$. Isto é possível porque para cada passo todos os valores pais serão instanciados [Bishop 2009]. O seguinte algoritmo para criação de distribuição condicional pode ser aplicado para cada nó em um DAG;

1. Em cada nó para cada valor da amostra obtido para a variável observada z_i , compara-se o valor da amostra com $P(z_i | pa_i)$;
2. Se a amostra combina com $P(z_i | pa_i)$, retem a amostra e processa a próxima variável;
3. Em caso contrário, toda a amostra retida até o momento é descartada;
4. Inicia o algoritmo no próximo nó do grafo.

Entretanto, a probabilidade total de aceitar uma amostra a partir da posterior diminui rapidamente à medida que o número de variáveis observadas aumenta e o número de estados que os aumentos podem tomar, assim esta abordagem é raramente utilizada [Tillé 2006], [Bishop 2009].

A esperança da aproximação da soma finita dada em 4.48 depende da capacidade de retirar-se amostras da $P(z)$. Uma estratégia de simplificação par a avaliação da esperança poderia ser discretizar os z -espaços dentro de uma grade uniforme e avaliar cada integrante com uma soma na forma da equação 4.51

$$E[f] \simeq \sum_{l=1}^L P(z^{(l)}) f(z^{(l)}) \quad (4.51)$$

Um problema desta abordagem é que o número de termos na soma cresce exponencialmente com a dimensionalidade de z . Neste caso, pode-se rejeitar uma amostra baseado no uso de uma

distribuição $Q(z)$ em que seja possível a obtenção da esperança, como ilustra a Figura 4.8, adaptada de [Bishop 2009].




Figura 4.8: Exemplo de função $f(x)$ dada uma Probabilidade $Q(z)$ conhecida

Como no caso de rejeição de amostragem, o uso de uma distribuição de probabilidade conhecida $Q(z)$ nos permite expressar a esperança na forma de uma soma finita sobre as amostras $\{z^{(l)}\}$ adquiridas através de $Q(z)$ como em 4.52

$$\begin{aligned}
 E[f] &= \int f(z)P(z)dz \\
 E[f] &= \int f(z)\frac{P(z)}{Q(z)}Q(z)dz \\
 &\simeq \frac{1}{L} \sum_{l=1}^L \frac{P(z)}{Q(z)} f(z^{(l)})
 \end{aligned} \tag{4.52}$$

As quantidades $r_l = \frac{P(z^{(l)})}{Q(z^{(l)})}$ são conhecidas como *peso de importância* e corresponde a uma restrição introduzida para as amostras de uma distribuição falsa.

4.9 Método de Mistura Finita

Muitos modelos estatísticos envolvem distribuições de mistura finita. Considere uma população formada por K subgrupos, misturados aleatoriamente em proporção para os grupos relativos de tamanho $n_1, n_2, \dots, n_k$. Suponha que o interesse reside em algumas características aleatórias de Y o qual é heterogêneo entre subgrupos e homogêneo dentro destes. Em função da heterogeneidade, Y tem diferentes distribuições de probabilidade em cada grupo. Assim, assumindo que os grupos possuem a mesma família de distribuição condicional $P(y|\theta)$, porém com parâmetro θ diferente entre cada grupo. O grupo pode ser identificado através de uma variável indicadora discreta S contendo valores em um conjunto $\{1, 2, \dots, K\}$. Quando uma amostra randômica é obtida desta população, pode-se identificar não somente por Y , mas também pelo indicador do grupo S . A probabilidade de amostragem do grupo S é igual a n_s , considerando a condição de S , Y é uma variável aleatória seguindo a distribuição $P(y|\theta)_S$, com θ_S sendo um parâmetro do grupo S . A densidade conjunta $P(y, S)$ é dada como na equação 4.53 [Frühwirth-Schnatter 2006].

$$P(y, S) = \frac{P(y|S)}{P(S)} = P(y|\theta_S)n_s \quad (4.53)$$

A distribuição de mistura finita surge quando não é possível registrar um grupo indicador S , assim o que é observado é somente a variável aleatória Y . A densidade marginal $P(y)$ é dada pela seguinte densidade de mistura na equação 4.54

$$P(y) = \sum_{S=1}^K P(y, S) = n_1 P(y|\theta_1) + n_2 P(y|\theta_2) + \dots + n_K P(y|\theta_K) \quad (4.54)$$

A heterogeneidade em uma amostra ocorre sempre que a média de uma característica aleatória de Y é diferente entre os sujeitos observados. Um caminho para tratar a heterogeneidade é assumir que Y seja um distribuição normal com média específica $\mu_i^S, Y \sim N(\mu_i^S, \sigma^2)$. Se o desvio de μ_i^S de uma média comum μ puder ser explicado por um fator observado z_i , como em 4.55

$$\mu_i^S = \beta_1 + z_i \beta_2 \quad (4.55)$$

Então a heterogeneidade observada está presente, e o parâmetro desconhecido pode ser estimado por um modelo de regressão, como na equação 4.56

$$Y = \beta_1 + z_i \beta_2 + \varepsilon_i, \text{ onde } \varepsilon_i \sim N(0, \sigma^2) \quad (4.56)$$

Se o fator z_i é não observado heterogeneidade então tem-se que lidar com categorias discretas de distribuição, sendo $n_1, n_2, \dots, n_k$ a distribuição discreta de z_i . Assim, a mistura finita de uma distribuição normal K tem variância igual à equação 4.57. Portanto, um modelo de mistura finita captura a heterogeneidade não observada causada por uma variável categórica não observa.

$$Y \sim n_1 N(\mu_1, \sigma^2) + \dots + n_k N(\mu_k, \sigma^2) \quad (4.57)$$

4.9.1 Distribuição de Mistura Finita

Considere uma variável aleatória ou vetor randômico $\hat{Y}$, contendo valores em um espaço de amostragem $\mathcal{Y} \subset \mathbb{R}^r$, o qual pode ser discreto ou contínuo, invariante e multivariante. A distribuição de probabilidade de uma variável aleatória Y é geralmente caracterizada por sua função densidade de probabilidade. A função densidade de probabilidade é definida com respeito a medida em $\mathbb{R}^r$ a qual será a medida de Lebesgue, ou uma medida de contagem, ou uma combinação dos dois [Frühwirth-Schnatter 2006].

Y diz-se surgir a partir de uma distribuição de mistura finita, se a função densidade de probabilidade $P(y)$ desta distribuição toma a forma de uma mistura de densidade para todo $y \in \mathcal{Y}$, como na equação 4.58, onde $P_K(y)$ é a função densidade de probabilidade para todo $k = 1, 2, \dots, K$ e $n_1, n_2, \dots, n_k$ são chamados de pesos.

$$P(y) = n_1 P_1(y) + \dots + n_k P_k(y) \quad (4.58)$$

Na maioria das aplicações assume-se que todos os componentes densidade surgem da mesma família de distribuição $\mathcal{T}(\theta)$ com densidade $P(y|\theta)$, indexada por um parâmetro $\theta \in \Theta$. A função densidade mistura é dada pela equação 4.59

$$P(y|\vartheta) = n_1 P(y|\theta_1) + n_2 P(y|\theta_2) + \dots + n_K P(y|\theta_K) \quad (4.59)$$

Referências Bibliográficas

- [Ahn and Jeong 2019] Ahn, D. J. and Jeong, J. (2019). A Bigdata Search Engine Based Cloud Computing Network Architecture in Smart Factory Environment. In *2019 2nd International Conference on Intelligent Autonomous Systems (ICoIAS)*, page 91–95. IEEE Computer Society.
- [Anjos et al. 2020] Anjos, J. C. S. d., Matteussi, K. J., De Souza, P. R. R., Grabher, G. J. A., Borges, G. A., Barbosa, J. L. V., González, G. V., Leithardt, V. R. Q., and Geyer, C. F. R. (2020). Data Processing Model to Perform Big Data Analytics in Hybrid Infrastructures. *IEEE Access*, 8:170281–170294.
- [Assuncao et al. 2015] Assuncao, M. D., Calheiros, R. N., Bianchi, S., Netto, M. A., and Buyya, R. (2015). Big Data computing and clouds: Trends and future directions. *Journal of Parallel and Distributed Computing*, 79–80:3–15.
- [Bishop 2009] Bishop, C. (2009). *Pattern Recognition and Machine Learning*. Information Science and Statistics. Springer New York, 8th edition.
- [CERN 2022] CERN (2022). European Organization for Nuclear Research.
- [Chen and Zhang 2014] Chen, C. P. and Zhang, C.-Y. (2014). Data-intensive applications, challenges, techniques and technologies: A survey on Big Data. *Information Sciences*, 275:314–347.
- [Cinlar 2010] Cinlar, E. (2010). *Probability and Stochastics*. Graduate Texts in Mathematics. Springer New York.
- [DasGupta 2008] DasGupta, A. (2008). *Asymptotic Theory of Statistics and Probability*. Springer Texts in Statistics. Springer New York.
- [DasGupta 2010] DasGupta, A. (2010). *Fundamentals of Probability: A First Course*. Springer Texts in Statistics Series. Springer New York.
- [DasGupta 2011] DasGupta, A. (2011). *Probability for Statistics and Machine Learning: Fundamentals and Advanced Topics*. Springer Texts in Statistics. Springer New York.
- [Dodson 2006] Dodson, B. (2006). *The Weibull Analysis Handbook*. ASQ - American Society for Quality, 2nd edition.
- [e Albuquerque et al. 2008] e Albuquerque, J. P. d. A., Fortes, J. M. P., and Finamore, W. A. (2008). *Probabilidade, Variáveis Aleatórias e Processos Estocásticos*, volume 1. Editora Interciência.



- [Frühwirth-Schnatter 2006] Frühwirth-Schnatter, S. (2006). *Finite Mixture and Markov Switching Models*. Springer Series in Statistics. Springer New York, 1st edition.
- [Hastie et al. 2011] Hastie, T., Tibshirani, R., and Friedman, J. (2011). *The Elements of Statistical Learning: Data Mining, Inference and Prediction*. Springer Series in Statistics. Springer Science, 5th edition.
- [Jain 1991] Jain, R. (1991). *The art of computer systems performance analysis - techniques for experimental design, measurement, simulation, and modeling*. Wiley professional computing. John Wiley & Sons Inc, Littleton (Massachusetts), USA.
- [Jayalath et al. 2014] Jayalath, C., Stephen, J., and Eugster, P. (2014). From the Cloud to the Atmosphere: Running MapReduce across Data Centers. *Computers, IEEE Transactions on*, 63(1):74–87.
- [Lasserre et al. 2006] Lasserre, J. A., Bishop, C. M., and Minka, T. P. (2006). Principled Hybrids of Generative and Discriminative Models. In *Proceedings of the 2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition - Volume 1*, CVPR '06, page 87–94, Washington, DC, USA. IEEE Computer Society.
- [LSST 2024] LSST (2024). The LSST Overview. Available in <http://www.lsst.org/about/dm/>.
- [Magalhães 2011] Magalhães, M. N. (2011). *Probabilidade e Variáveis Aleatórias*, volume 1. Edusp - Editora, 3rd edition.
- [Rinne 2009] Rinne, H. (2009). *The Weibull Distributions - A Handbook*, volume 1. Chapman & Hall /CRC, 1st edition.
- [Ross 2010] Ross, S. (2010). *Probabilidade: Um Curso Moderno com Aplicações*, volume 1. Bookman Editora, 8th edition.
- [Russel and Norving 2004] Russel, S. and Norving, P. (2004). *Inteligência Artificial*. Elsevier Editora Ltda, 2nd edition.
- [SEARLE et al. 2006] SEARLE, S. R., CASELLA, G., and McCULLOCH, C. E. (2006). *Variance Components*, volume 1. John Wiley & Sons, Inc.
- [Tillé 2006] Tillé, Y. (2006). *Sampling Algorithms*. Springer Series in Statistics. Springer New York, 1st edition.

Índice Remissivo

Arpanet, 6

BBS, 6

Conhecimento, 6

Dado, 6

Http, 6

Informação, 6

Redes Sociais, 7

WWW, 6