



MÉTRICAS - REVISÃO

Prof. Dr. Julio César Santos dos Anjos
Dados e Informação

Pré-Processamento de Dados — 14 de março de 2026

1. Análise Descritiva
2. Transformação dos Dados
 - Normalização de Dados



1. Análise Descritiva
2. Transformação dos Dados



Análise Descritiva

- ✓ Ferramenta capaz de resumir os dados, mostrando seus conjuntos, tipo de distribuição associada e valores mais representativos do conjunto de dados;
- ✓ A **população** é o universo dos dados que compartilham características comuns;
 - Sobre a população é que se desenvolve o estudo da descoberta de padrões;
- ✓ População pode ser finita ou infinita;
- ✓ Caso infinita, faz-se necessário pegar uma **amostra** ou um subconjunto da população;
- ✓ Na estatística descritiva uma **variável** é uma característica associada a elementos de uma população;



Variáveis podem ser:

- **Quantitativas** (variáveis numéricas)
 - **Discretas** → assumem valores dentro de um conjunto finito ou infinito contável. Ex.: Idade do cliente: 5, 10, 25, 57,...
 - **Contínuas** → assumem valores numa escala contínua. Ex.: Peso do corte de carne: 100g, 250g, 510g,...
- **Qualitativas** (variáveis categóricas)
 - **Nominais** → quando não há ordenação entre valores. Ex.: Forma de pagamento: dinheiro, débito, crédito, pix
 - **Ordinais** → quando há uma ordenação entre valores. Ex.: Faixa etária dos clientes: 0 a 17 anos, 18 a 30 anos, 31 a 50 anos, mais que 50 anos



Medidas de posição ou separatriz

✓ Média

$$\mu = \frac{1}{n} \sum_{i=1}^n v_i$$

onde $\vec{v} = \{v_1, v_2, v_3, \dots, v_n\}$ e n é a quantidade de valores do conjunto;

✓ Mediana M é o valor que divide a distribuição de valores exatamente ao meio.

$$M = \begin{cases} v'_i & \text{se } n \text{ é ímpar} & i = \frac{n+1}{2} \\ \frac{1}{2}v'_i + v'_{i+1} & \text{se } n \text{ é par} & i = \frac{n}{2} \end{cases} \quad (1)$$

Onde v' é o elemento central dos elementos ordenados no conjunto $\vec{v}$.

✓ Moda é o valor mais frequente em um conjunto $\vec{v}$.



Medidas de posição ou separatriz

Exemplo:

Analise os valores abaixo e estabeleça, a média, mediana e moda das quantidades.

Item	712	068	002	005	065	112	212	131	067
Quantidade	29	30	32	65	65	65	25	25	90



Medidas de posição ou separatriz

Exemplo:

Analise os valores abaixo e estabeleça, a média, mediana e moda das quantidades.

1º Ordena-se os valores

Item	131	212	712	068	002	065	112	131	067
Quantidade	25	25	29	30	32	65	65	65	90

$$\mu = 47,33$$

$$M = 32$$

$$\text{Moda} = 65$$



Medidas de Dispersão

- ✓ **Amplitude** → é a diferença entre o maior e o menor valor de um conjunto de valores $\vec{v}$;

$$a(\vec{v}) = \max(\vec{v}) - \min(\vec{v})$$

- ✓ **Variância** → é a média dos quadrados das diferenças entre cada valor do conjunto $\vec{v}$ e a média deste conjunto;

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (v_i - \mu(\vec{v}))^2$$

- ✓ **Desvio padrão** → é a raiz quadrada da variância. Só faz sentido quando a média é usada como medida de posição.

$$\sigma = \sqrt{\sigma^2}$$



Medidas de Dispersão

- ✓ **Coeficiente de Dispersão (Coeficiente de variação de Pearson)** → é uma medida que expressa a dispersão relativa dos valores. Útil para comparar duas ou mais distribuições diferentes;

$$CV(\vec{v}) = \frac{\sigma(\vec{v})}{\mu(\vec{v})}$$



Distribuição de frequência

- ✓ **Distribuição de Frequência** → permite a construção de uma visualização dos valores de forma compacta. Se ordenadas em forma decrescente, representam um indicador de qualidade (**Diagrama de Pareto**);
- ✓ **Frequência relativa** → é a representação de valores que aparecem em cada faixa (γ) dividida pela frequência total do conjunto;

$$fr(\gamma) = \frac{f(\gamma)}{\sum_{i=1}^n f(v_i)} * 100$$

- ✓ **Frequência acumulada relativa** → é a frequência relativa acumulada de cada faixa, considerando as frequências acumuladas das faixas anteriores;

$$far(\gamma_i) = \sum_{i=0}^n fr(\gamma_{i+1})$$



Distribuição de frequência - Como calcular?

Faixas	Frequências		Freq. acumuladas	
	Absoluta	Relativa (%)	Absoluta	Relativa (%)
1-10	0			
11-20	0			
21-30	4			
31-40	1			
41-50	0			
51-60	0			
61-70	3			
71-80	0			
81-90	1			
91-100	0			



Distribuição de frequência

Faixas	Frequências		Freq. acumuladas	
	Absoluta	Relativa (%)	Absoluta	Relativa (%)
1-10	0	0		
11-20	0	0		
21-30	4	44,44		
31-40	1	11,11		
41-50	0	0		
51-60	0	0		
61-70	3	33,33		
71-80	0	0		
81-90	1	11,11		
91-100	0	0		



Distribuição de frequência

Faixas	Frequências		Freq. acumuladas	
	Absoluta	Relativa (%)	Absoluta	Relativa (%)
1-10	0	0	0	
11-20	0	0	0	
21-30	4	44,44	4	
31-40	1	11,11	5	
41-50	0	0	5	
51-60	0	0	5	
61-70	3	33,33	8	
71-80	0	0	8	
81-90	1	11,11	9	
91-100	0	0	9	



Distribuição de frequência

Faixas	Frequências		Freq. acumuladas	
	Absoluta	Relativa (%)	Absoluta	Relativa (%)
1-10	0	0	0	0
11-20	0	0	0	0
21-30	4	44,44	4	44,44
31-40	1	11,11	5	55,55
41-50	0	0	5	55,55
51-60	0	0	5	55,55
61-70	3	33,33	8	88,88
71-80	0	0	8	88,88
81-90	1	11,11	9	100
91-100	0	0	9	100



Correlação

- ✓ **Correlação** → é análise da relação entre dois conjuntos de valores;
- ✓ **Correlação de Pearson (r)** → entre dois conjuntos de valores de variáveis $\vec{v}_1$ e $\vec{v}_2$, onde v_{1i} e v_{2i} são os elementos destes conjuntos é dada por:

$$r_{\vec{v}_1, \vec{v}_2} = \frac{\sum_{i=1}^n (v_{1i} - \mu(\vec{v}_1)) * (v_{2i} - \mu(\vec{v}_2))}{\sqrt{\sum_{i=1}^n (v_{1i} - \mu(\vec{v}_1))^2} * \sqrt{\sum_{i=1}^n (v_{2i} - \mu(\vec{v}_2))^2}}$$


ou

$$r_{\vec{v}_1, \vec{v}_2} = \frac{cov(\vec{v}_1, \vec{v}_2)}{\sigma(\vec{v}_1) * \sigma(\vec{v}_2)}, \text{ onde } -1 \leq r_{\vec{v}_1, \vec{v}_2} \leq 1$$




Correlação

- ✓ **Correlação Positiva:** quando os valores de uma das variáveis aumentam/diminuem, os valores da outra variável tendem a aumentar/diminuir.




Correlação

- ✓ **Correlação Negativa:** quando os valores de uma das variáveis aumentam/diminuem, os valores da outra variável seguem uma tendência contrária.





Correlação

- ✓ **Correlação Nula [Caso 1: $\text{var}(X1)=\text{var}(X2)$]:** não há um padrão definido de tendência.



Correlação

- ✓ **Correlação Nula** [[Caso 2: $\text{var}(X1) \neq \text{var}(X2)$]: também ocorre quando ao aumentar um atributo não há mudança significativa nos valores do outro atributo.



Correlação Pearson - Será que existe alguma correlação?

Mes	Feljoada	Caipirinhas
nov	24	10
dez	27	25
jan	29	20
fev	30	36
mar	32	28
abr	58	38
mai	64	50
jun	64	60
jul	65	69



Correlação Pearson

Mes	Feijoada	Caipirinhas
nov	24	10
dez	27	25
jan	29	20
fev	30	36
mar	32	28
abr	58	38
mai	64	50
jun	64	60
jul	65	69




Se usar o R como uma ferramenta de análise, podemos obter a correlação de Pearson.


Tente fazer a análise.



Correlação Pearson



Representação gráfica - Avaliação de quartis (percentil)



Os quartis dividem um determinado conjunto de dados cujo os elementos são números reais em 4 grupos, e cada grupo inclui aproximadamente 25% (ou um quarto) de todos os valores incluídos no conjunto de dados.



Representação gráfica - Avaliação de quartis

✓ Grupos de Quartis

- **Grupo 1:** Do limite inferior até Q1, também conhecido como 25º percentil, porque 25% dos valores do conjunto de dados estão abaixo dele.
 - **Grupo 2:** De Q1 a Q2. Q2 que é chamado de 50º percentil, porque 50% dos valores do conjunto de dados estão abaixo dele.
 - **Grupo 3:** De Q2 a Q3. Q3 que também é chamado de 75º percentil, porque 75% dos valores do conjunto de dados estão abaixo dele.
 - **Grupo 4:** De Q3 ao limite superior.
- ✓ Além disso, esse método proporciona a localização visual da posição, dispersão, simetria, caudas e os valores extremos (outliers) dos dados.



1. Análise Descritiva
2. Transformação dos Dados



Transformação dos Dados

- ✓ Como foi estudado anteriormente, os dados podem vir de diferentes fontes como
 - textos, multimídia (som, imagens, videos), internet (redes sociais), bancos de dados, tabelas, etc.
- ✓ Diferentes medições e caracterizações, possuem domínios de natureza e grandezas bastantes distintas;
- ✓ Para efetuar-se as transformações nos dados necessita-se analisar os possíveis agrupamentos de dados baseados na sua ocorrência (frequencia) por exemplo;
 - Outras transformações podem incluir a substituição de itens como por exemplo, horário de funcionamento das 8-12hs e 14-17hs, para turno de funcionamento manhã e tarde.
 - Fazendo-se isto simplifica-se a identificação de características em uma rede neural por exemplo.



Transformação dos Dados

- ✓ A diferença de domínios em diferentes atributos de um mesmo exemplar dificultam a identificação de padrões por parte dos algoritmos de classificação;
- ✓ A adequação dos tipos de dados em relação o algoritmo utilizado e a dimensionalidade dos dados;
- ✓ Esses procedimentos incluem a normalização e a conversão de dados;
- ✓ A conversão de dados pode ser tanto de dados Numéricos para Categóricos (Discretização) ou vice-versa (Codificação).



Recomendações de uso de métricas

Tipo de Medida	Uso em	Observações
Moda	Dados Categóricos	
Frequencia	Dados Categóricos	
Percentil	Dados Contínuos	
Média	Localização de conjunto de dados	Sensível a Outliers
Mediana	Localização de conjunto de dados	Mais adequada
$var(x)$	Medida de dispersão em relação à média	Mais usada
$\sigma(x)$	RMS da variância	Mais usada



Recomendações para medidas de distância

Ajustes de Ponderação

$$- \mu = 1090K$$

Removendo valores min, max

$$- \mu_{(ponderada)} = 105K$$

$$- M = \frac{(90+100)K}{2} = 95K$$

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	10000K	Yes
6	No	NULL	60K	No
7	Yes	Divorced	220K	NULL
8	No	Single	85K	Yes
9	No	Married	90K	No
10	No	Single	90K	No



Normalização de Dados

- ✓ A Normalização dos Dados advem da necessidade de se equalizar as ordens de grandeza dos atributos usados em um problema de classificação/clusterização.

Métodos de Normalização

- ✓ **Método 1:** Manter constante a norma dos vetores.
- ✓ **Método 2:** Mudança da escala original para os intervalos $[0, 1]$ ou $[-1, +1]$.
- ✓ **Método 3:** Padronização dos dados (*i.e.* média=0, variância=1).



Método 1: Norma Constante

- ✓ Uma das técnicas mais simples de normalização consiste em manter constantes e iguais a 1 as normas dos vetores de atributos x e dos centróides m_i .
 - Este procedimento deve ser aplicado a todos os vetores de atributos e todas os centróides.
 - Para isso, basta dividir cada vetor por sua respectiva norma euclidiana:

$$\vec{x} = \frac{x}{||x||} \text{ e } \vec{m}_i = \frac{m_i}{||m_i||}$$



Método 1: Norma Constante

- ✓ Considere o vetor, que não possui norma unitária:

$$\vec{x} = \begin{bmatrix} \sqrt{3} \\ 3 \\ -2 \end{bmatrix}$$

- ✓ A norma deste vetor é

$$\|\vec{x}\| = \sqrt{(\sqrt{3})^2 + (3)^2 + (-2)^2} = \sqrt{16} = 4$$

- ✓ Assim o vetor normalizado é

$$\vec{x}^* = \frac{\vec{x}}{\|\vec{x}\|} = \frac{1}{4} \begin{bmatrix} \sqrt{3} \\ 3 \\ -2 \end{bmatrix} = \begin{bmatrix} \sqrt{3}/4 \\ 3/4 \\ -2/4 \end{bmatrix}$$



Método 1: Norma Constante

- ✓ A normalização descrita no slide anterior não altera a direção do vetor, apenas muda seu comprimento.
- ✓ Note que a normalização assim realizada depende apenas dos valores das componentes do vetor sendo normalizado.
- ✓ Assim, chamaremos este tipo de procedimento de **normalização local**.




Método 2: Mudança de escala

- ✓ Para classificadores baseados em distância euclidiana, uma normalização que promove uma mudança na escala das variáveis, é mais comum.
- ✓ Este procedimento é realizado variável a variável e requer a determinação do valor mínimo ($x_{\min}$) e do valor máximo ($x_{\max}$) da variável sendo normalizada.
- ✓ Por isso, chamaremos este tipo de procedimento de **normalização global**.



Método 2: Mudança de escala para intervalo [0,1]

$$\vec{x}^* = \left[\frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \right]_{i=1}^N$$




Exercício de Normalização:

Considere o arquivo wine.dat. Foram feitas várias observações nos lotes de produção de vinho de uma vinícola. O teor alcólico é a segunda coluna. Normalie estes dados conforme indicado na fórmula acima.



Método 2: Mudança de escala para intervalo $[-1,+1]$

$$\vec{x}^* = 2 \left[\frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \right]_{i=1}^N - 1$$



Exercício de Normalização:

Considere o arquivo wine.dat. Foram feitas várias observações nos lotes de produção de vinho de uma vinícola. O teor alcólico é a segunda coluna. Normalize pela mudança de escala para o intervalo $[-1,+1]$ para estes dados conforme indicado na fórmula acima.



Método 3: Padronização da variável (média=0, variância=1)

- ✓ Assim como as normalizações descritas no Método 2, devemos aplicar a padronização às variáveis do problema, uma a uma.
- ✓ Este tipo de normalização requer o cálculo da média (μ) e do desvio-padrão (σ_x) da variável x .
- ✓ Por isso, a padronização também pode ser chamada de normalização estatística.
- ✓ Este procedimento também é um tipo de **normalização global**.



Método 3: Padronização da variável (média=0, variância=1)

✓ A normalização estatística é dada por

$$\vec{x}^* = \left[\frac{x_i - \mu}{\sigma_x} \right]_{i=1}^N$$

Com média e desvio padrão amostral de $\vec{x}$ calculado como

$$\mu = \frac{\sum_{i=1}^N x_i}{N} \quad \text{e} \quad \sigma_x = \sqrt{\left(\frac{\sum_{i=1}^N (x_i - \mu)^2}{N - 1} \right)}$$

Tal que (x_i) é a n -ésima observação de $\vec{x}$ e N é o número total de observações de $\vec{x}$.

Exercício de Normalização: Repita a normalização da coluna de teor alcólico do arquivo wine.dat, conforme a fórmula acima.



NORMALIZAÇÃO COMO TRANSFORMAÇÃO LINEAR

Normalização como Transformação Linear

- ✓ As técnicas para normalização de variáveis descritas anteriormente podem ser vistas como uma transformação linear aplicada à variável original.
- ✓ Por exemplo, a normalização via Método 2 pode ser escrita da seguinte forma:

$$\vec{x}^* = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}}$$

$$\vec{x}^* = \left(\frac{1}{x_{\max} - x_{\min}} \right) x - \left(\frac{x_{\min}}{x_{\max} - x_{\min}} \right)$$

$$\vec{x}^* = ax + b$$



Propriedade 1 dos Métodos de Normalização

- ✓ Por serem transformações lineares, as normalizações descritas anteriormente não alteram a distribuição da variável normalizada em relação à variável original não-normalizada.
- ✓ Em outras palavras, o tipo de distribuição da variável permanece o mesmo. Por exemplo, se for gaussiana, continua gaussiana após a transformação.
- ✓ Os parâmetros da distribuição podem mudar, mas a forma dela não.



Propriedade 1 dos Métodos de Normalização

- ✓ Por serem transformações lineares, as normalizações descritas anteriormente não alteram a distribuição da variável normalizada em relação à variável original não-normalizada.
- ✓ Em outras palavras, o tipo de distribuição da variável permanece o mesmo. Por exemplo, se for gaussiana, continua gaussiana após a transformação.
- ✓ Os parâmetros da distribuição podem mudar, mas a forma dela não.

Por quê?



Propriedade 2 dos Métodos de Normalização

- ✓ Como estas técnicas de normalização só utilizam estatísticas descritivas (min, max, média e desvio-padrão) das variáveis, tomadas individualmente, a correlação entre duas variáveis quaisquer permanece a mesma antes e depois da normalização.
- ✓ Variáveis normalizadas pelos métodos descritos anteriormente serão adimensionais.



1. Análise Descritiva
2. Transformação dos Dados
 - Normalização de Dados





MÉTRICAS - REVISÃO

Prof. Dr. Julio César Santos dos Anjos
Dados e Informação

Pré-Processamento de Dados — 14 de março de 2026